PROYECTO DE CURSO

AGROVISION

CLASIFICACIÓN DE ENFERMEDADES EN MAZORCAS DE MAÍZ MEDIANTE REDES NEURONALES DENSAS Y CONVOLUCIONALES

Universidad Industrial de Santander

AGROVISION

EQUIPO

Daniel Badillo

Julio Gutierrez

Luis Toscano

AGROVISION

DIAGNOSTICO TRADICIONAL

PROBLEMÁTICA

La producción de maíz se ve constantemente amenazada por enfermedades que afectan la calidad de las mazorcas y reducen el rendimiento de los cultivos. La detección oportuna de estas patologías es esencial para minimizar pérdidas económicas y preservar la sostenibilidad agrícola. No obstante, los métodos tradicionales de diagnóstico, basados en la inspección visual, resultan limitados, subjetivos y dependientes de la experiencia del evaluador.

EXPERTOS!

AGROVISION

¿CUAL ES NUESTRA **MOTIVACIÓN?**

Ante esta situación, se plantea el uso de técnicas de Inteligencia Artificial para automatizar la identificación de enfermedades en mazorcas de maíz. Este proyecto emplea modelos de Deep Learning, específicamente redes neuronales convolucionales (CNN) y densas (DNN), junto a técnicas de aumento de datos, con el propósito de desarrollar un sistema capaz de clasificar las principales enfermedades del maíz con alta precisión, mejorando la eficiencia y objetividad del diagnóstico agrícola.

AGROVISION

PLANTVILLAGE DATASET

HEALTHY

VIRUS

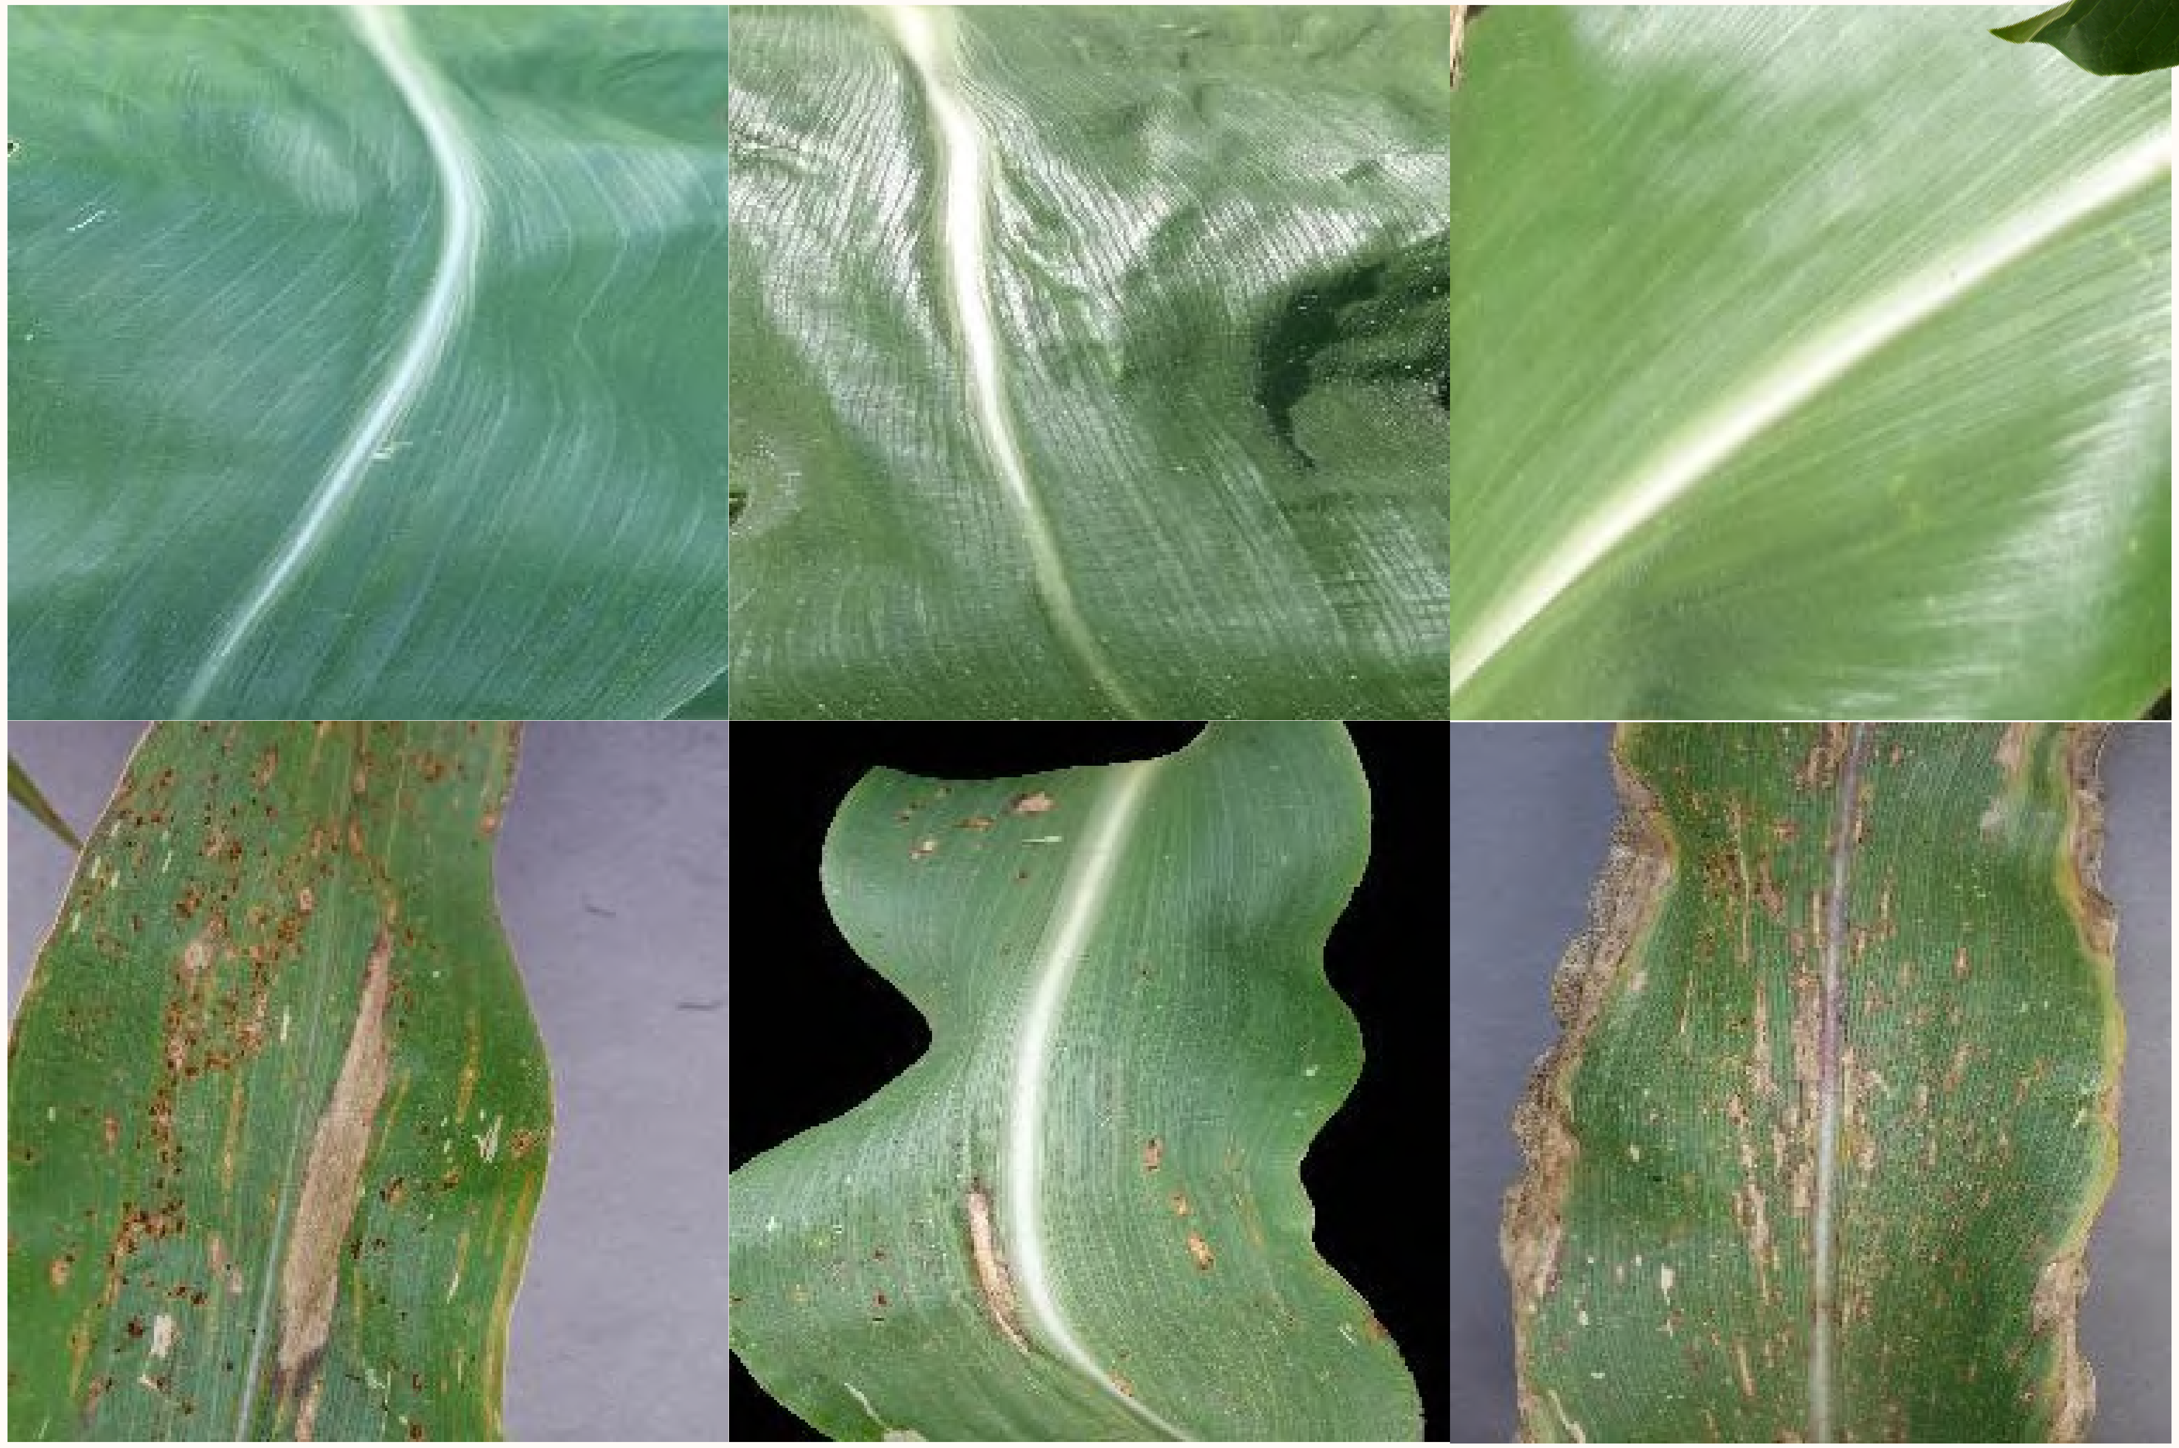

TIZÓN NORTEÑO   OXIDO COMUN   CERCOSPORA

OBJETIVO

DESARROLLAR UN SISTEMA AUTOMATIZADO BASADO EN TÉCNICAS DE INTELIGENCIA ARTIFICIAL, UTILIZANDO MODELOS DE DEEP LEARNING COMO REDES NEURONALES CONVOLUCIONALES (CNN) Y DENSAS (DNN), PARA IDENTIFICAR Y CLASIFICAR DE MANERA PRECISA LAS PRINCIPALES ENFERMEDADES EN MAZORCAS DE MAÍZ, CON EL FIN DE MEJORAR LA EFICIENCIA, OBJETIVIDAD Y OPORTUNIDAD DEL DIAGNÓSTICO AGRÍCOLA, CONTRIBUYENDO ASÍ A LA REDUCCIÓN DE PÉRDIDAS ECONÓMICAS Y AL FORTALECIMIENTO DE LA SOSTENIBILIDAD EN LA PRODUCCIÓN DE MAÍZ.

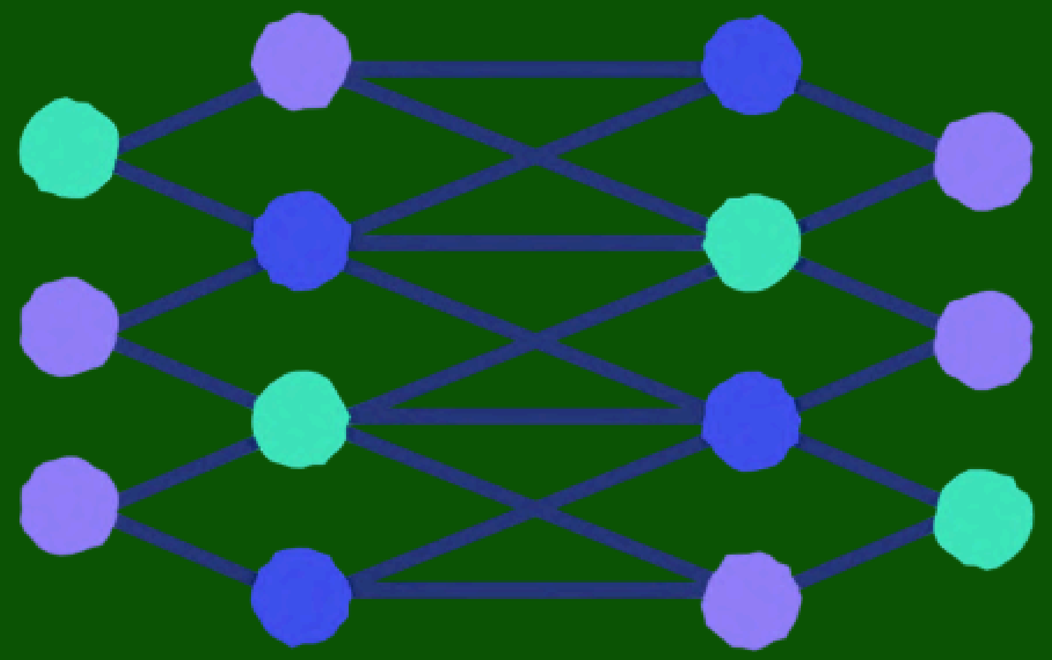

AGROVISION

ANÁLISIS DEL DATASET INICIAL

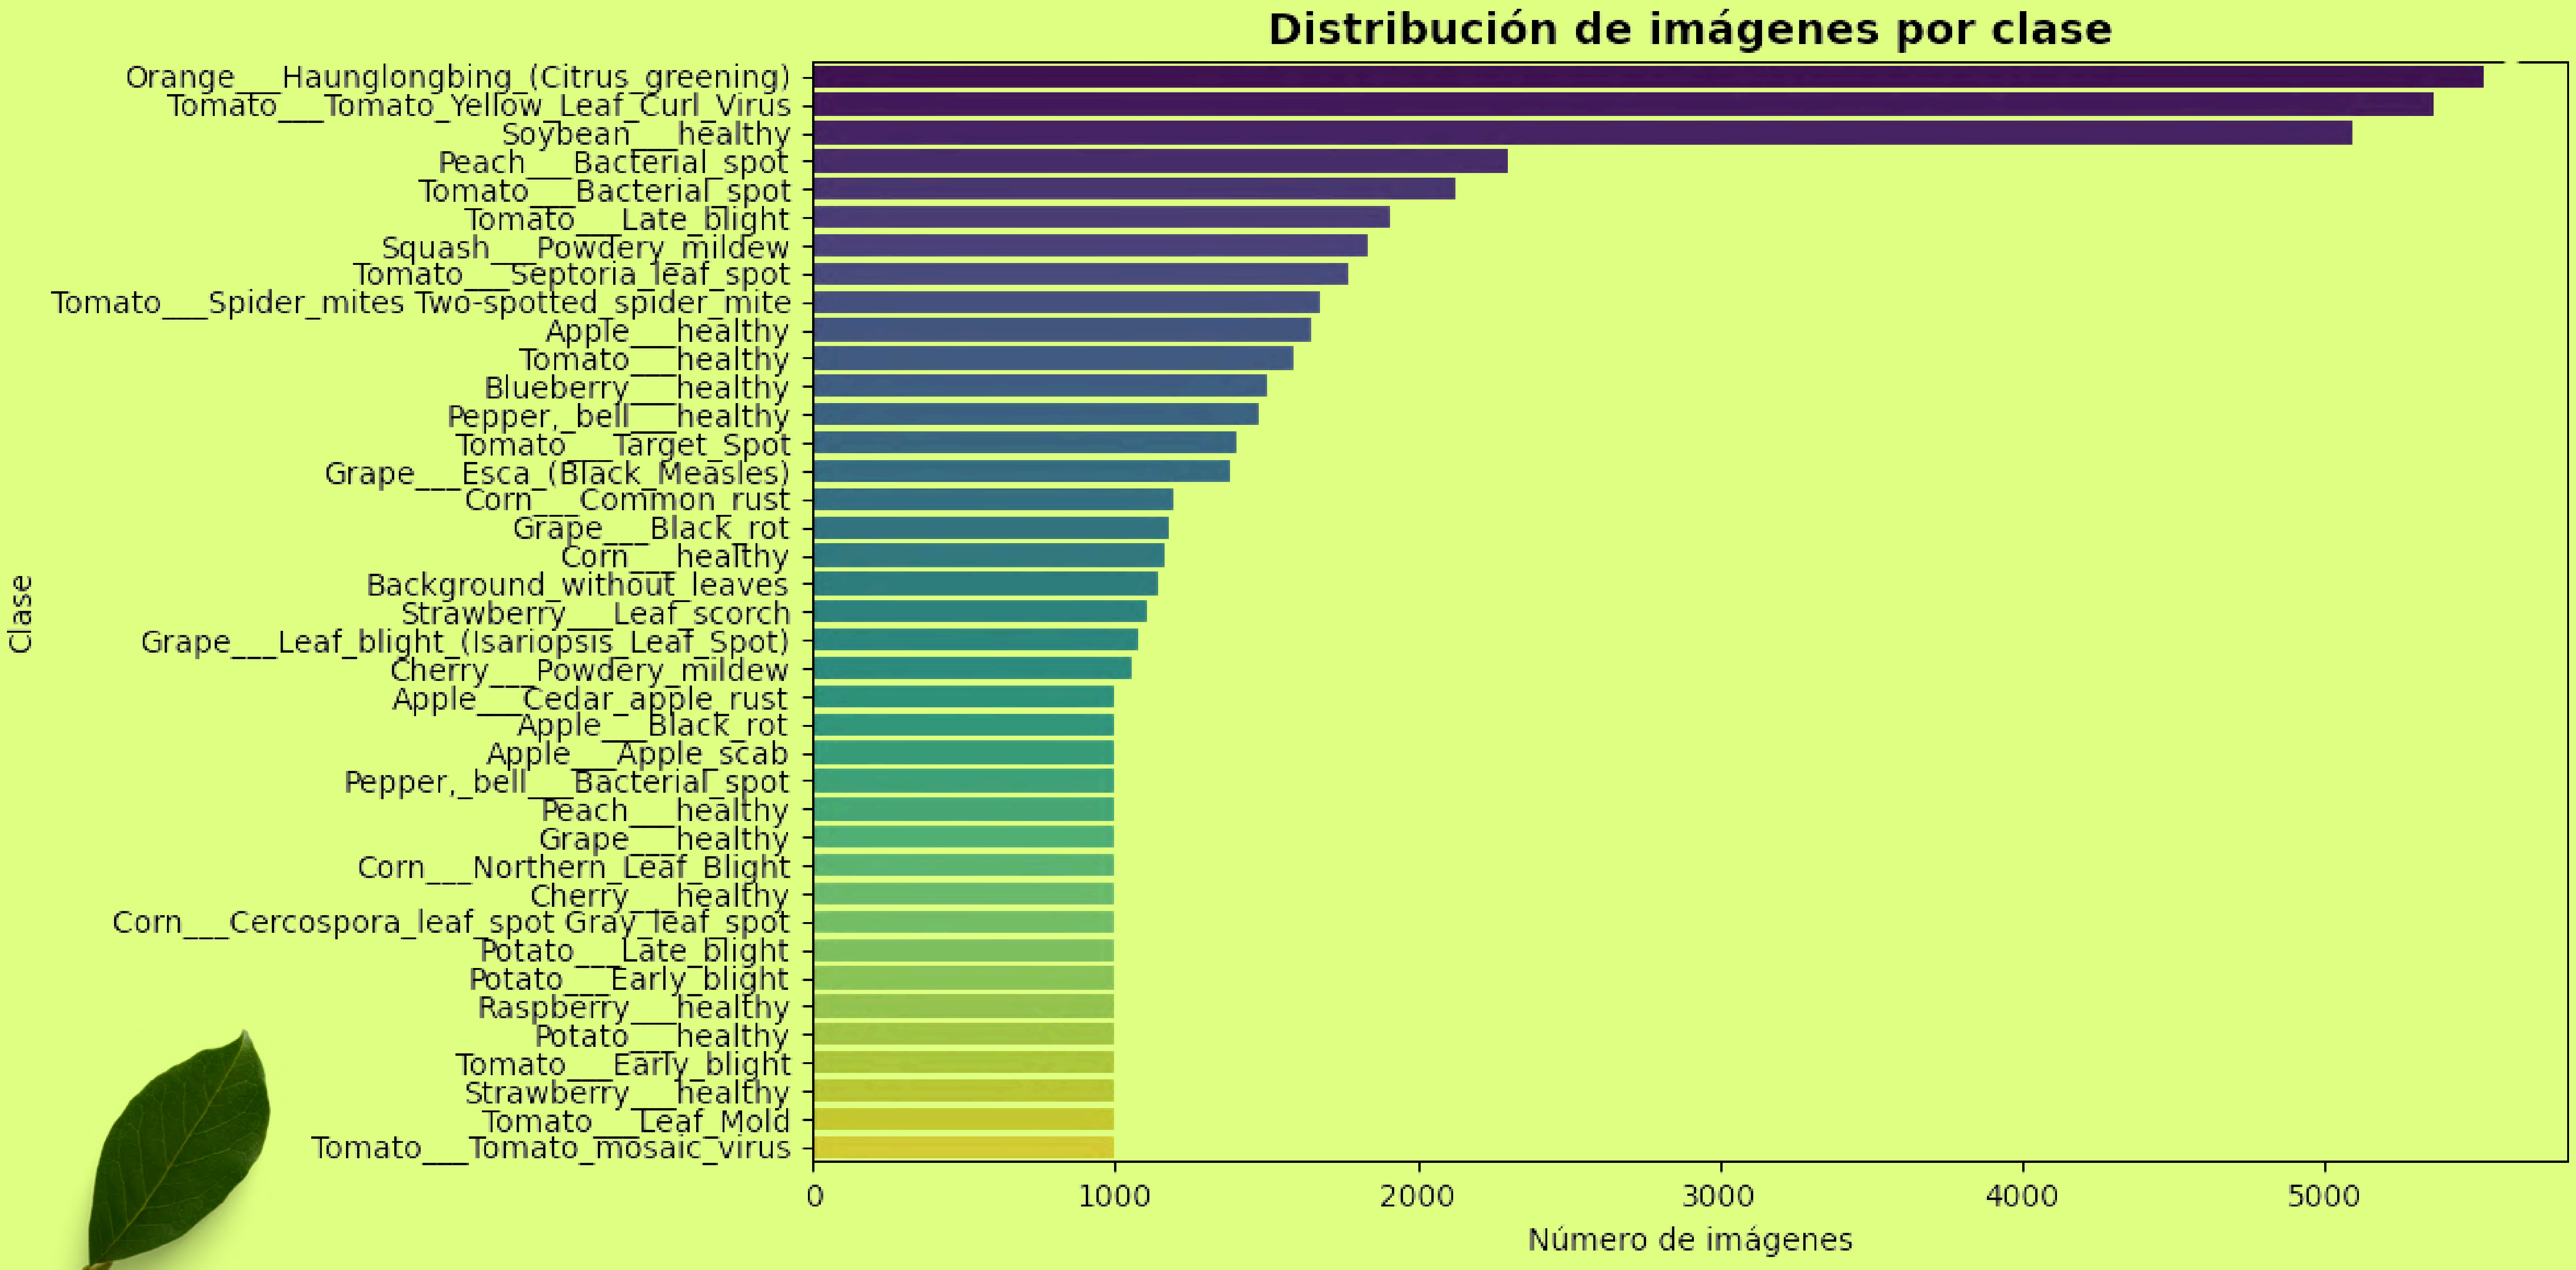

Data

61502 TOTAL IMAGES

39 CLASSES

AGROVISION

ANÁLISIS DEL DATASET ELEGIDO

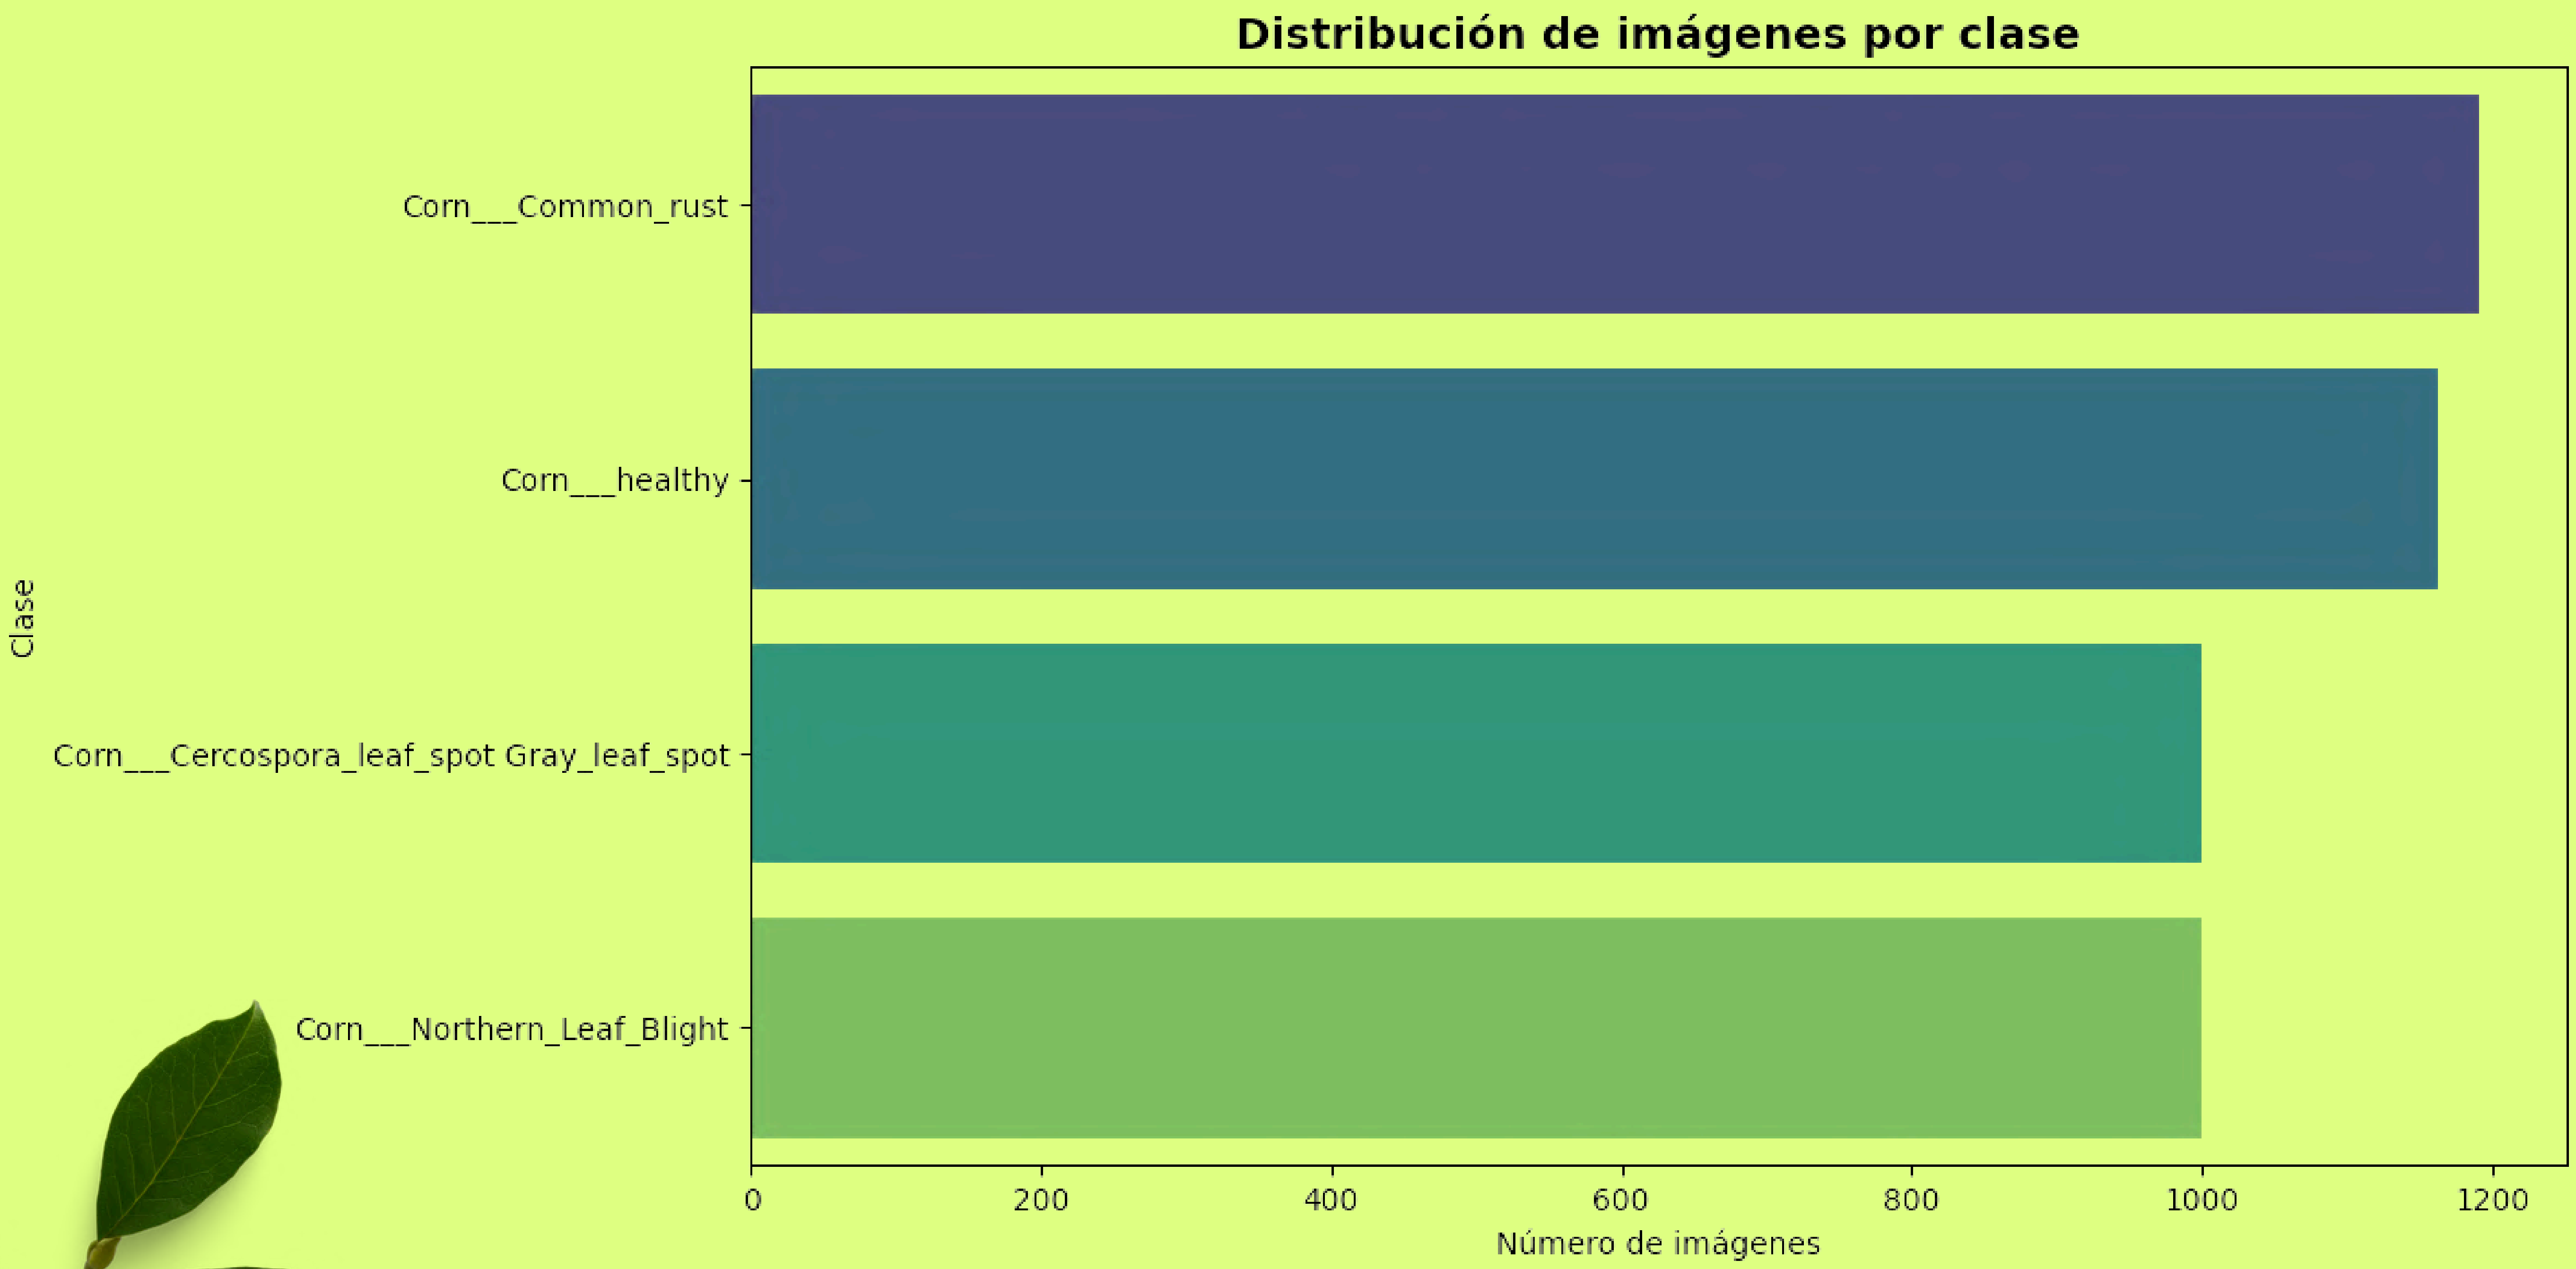

Data

4354 TOTAL IMAGES

3484 TRAINING IMAGES (80% TRAIN, 20% VALIDATION)

870 TEST IMAGES

BALANCED CLASSES

AGROVISION

ESTADO DEL ARTE

Identification of Plant-Leaf Diseases Using CNN and Transfer Learning

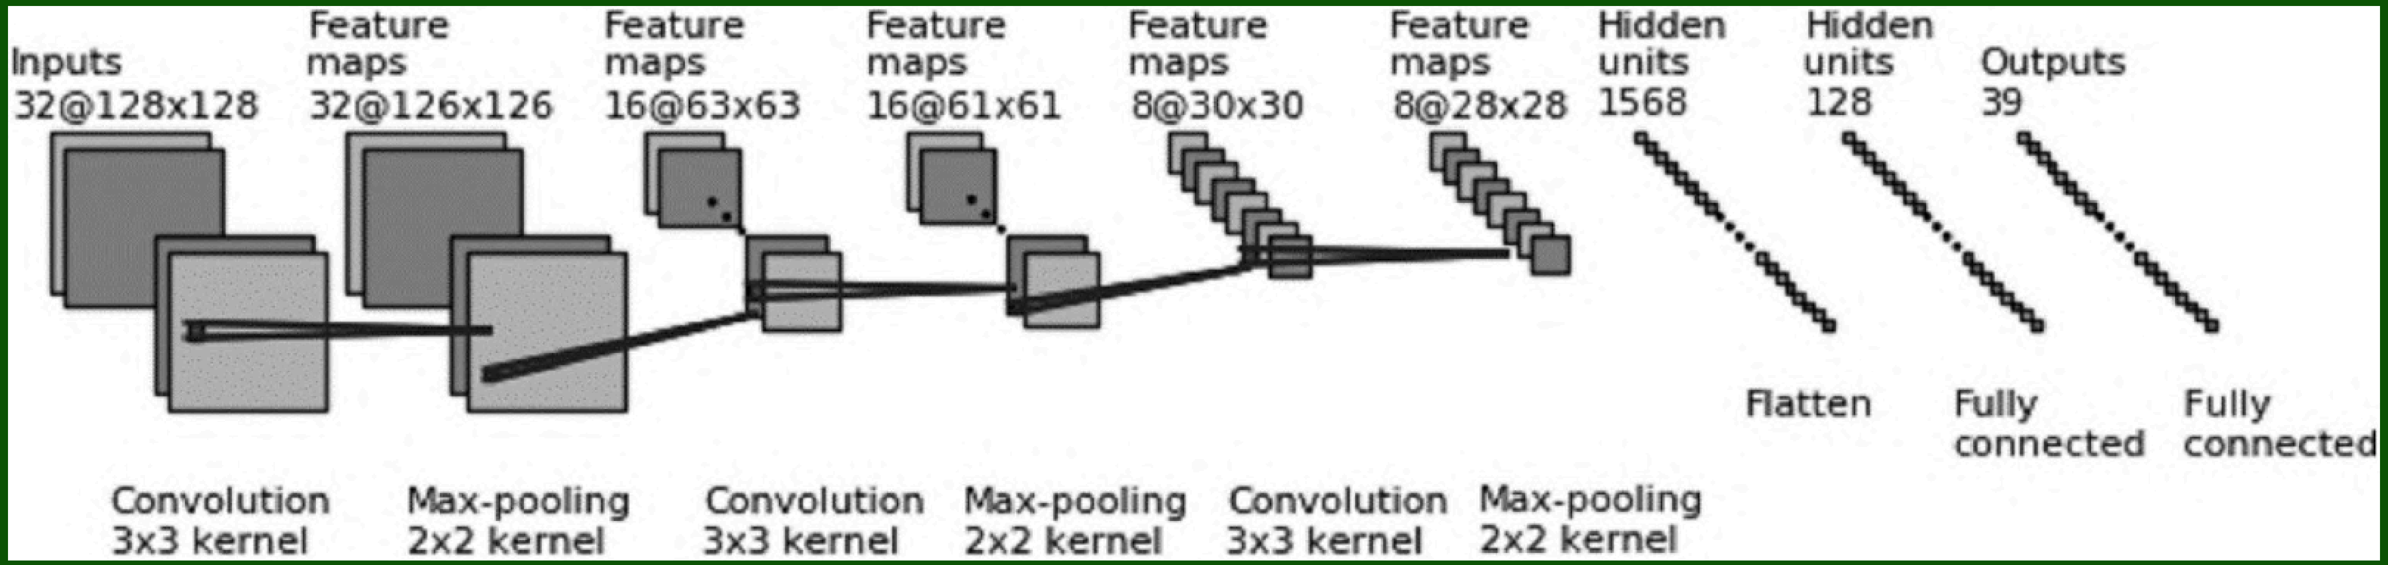

- Dropout progresivo (de 0.2 a 0.8) para evitar sobreajuste.
- Este modelo Deep CNN de nueve capas fue optimizado y evaluado sobre el dataset PlantVillage, logrando un 96.46 % de precisión en la clasificación de 39 tipos de enfermedades y hojas saludables.
- Entrenamiento con mini-batch gradient descent y diferentes tamaños de lote (64–160).
- Diseñada desde cero, no basada en transfer learning

AGROVISION

ESTADO DEL ARTE

Plant Disease Detection Using CNN

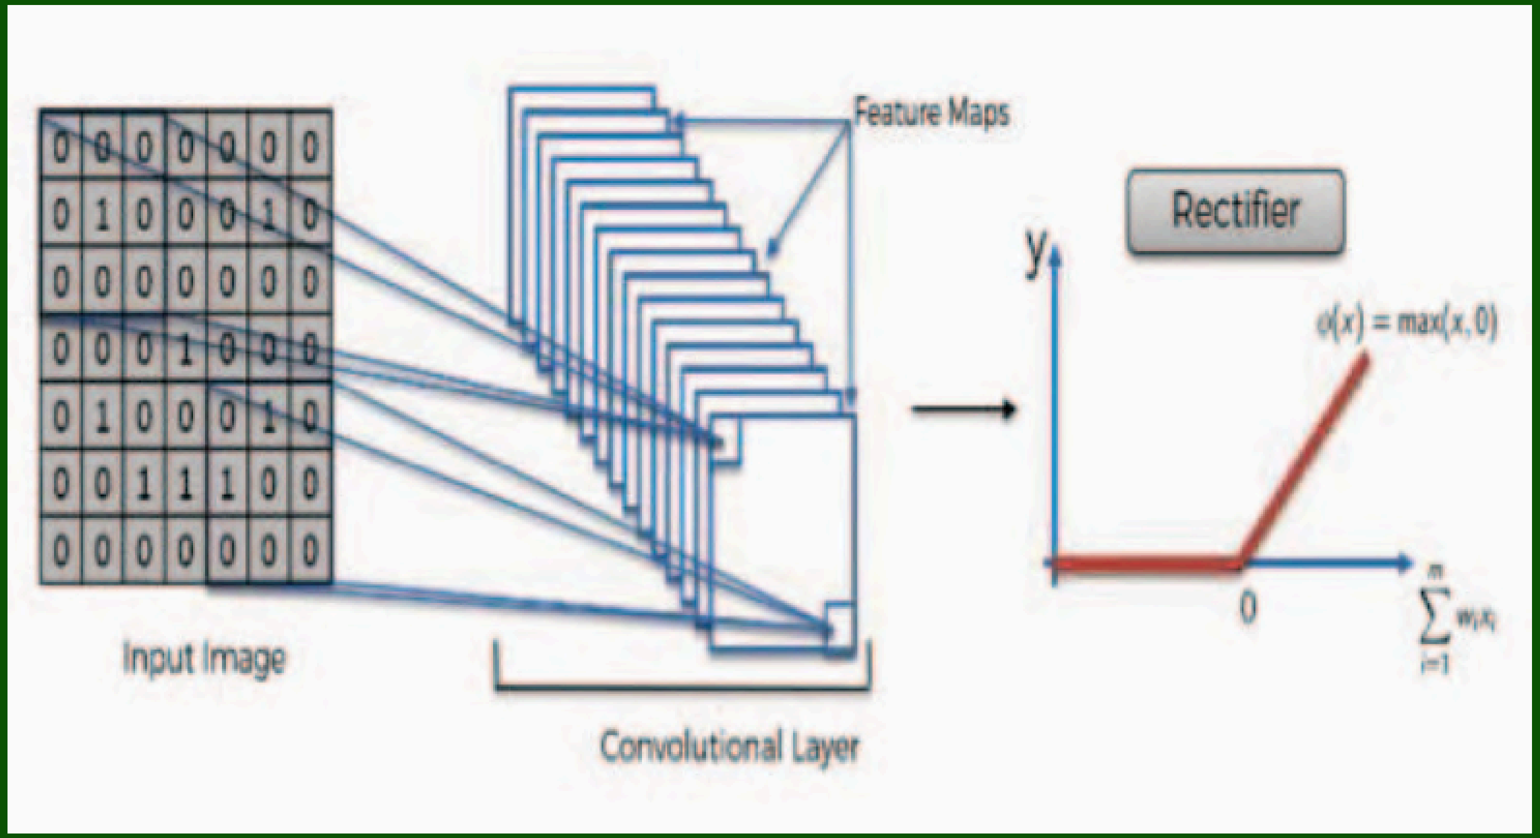

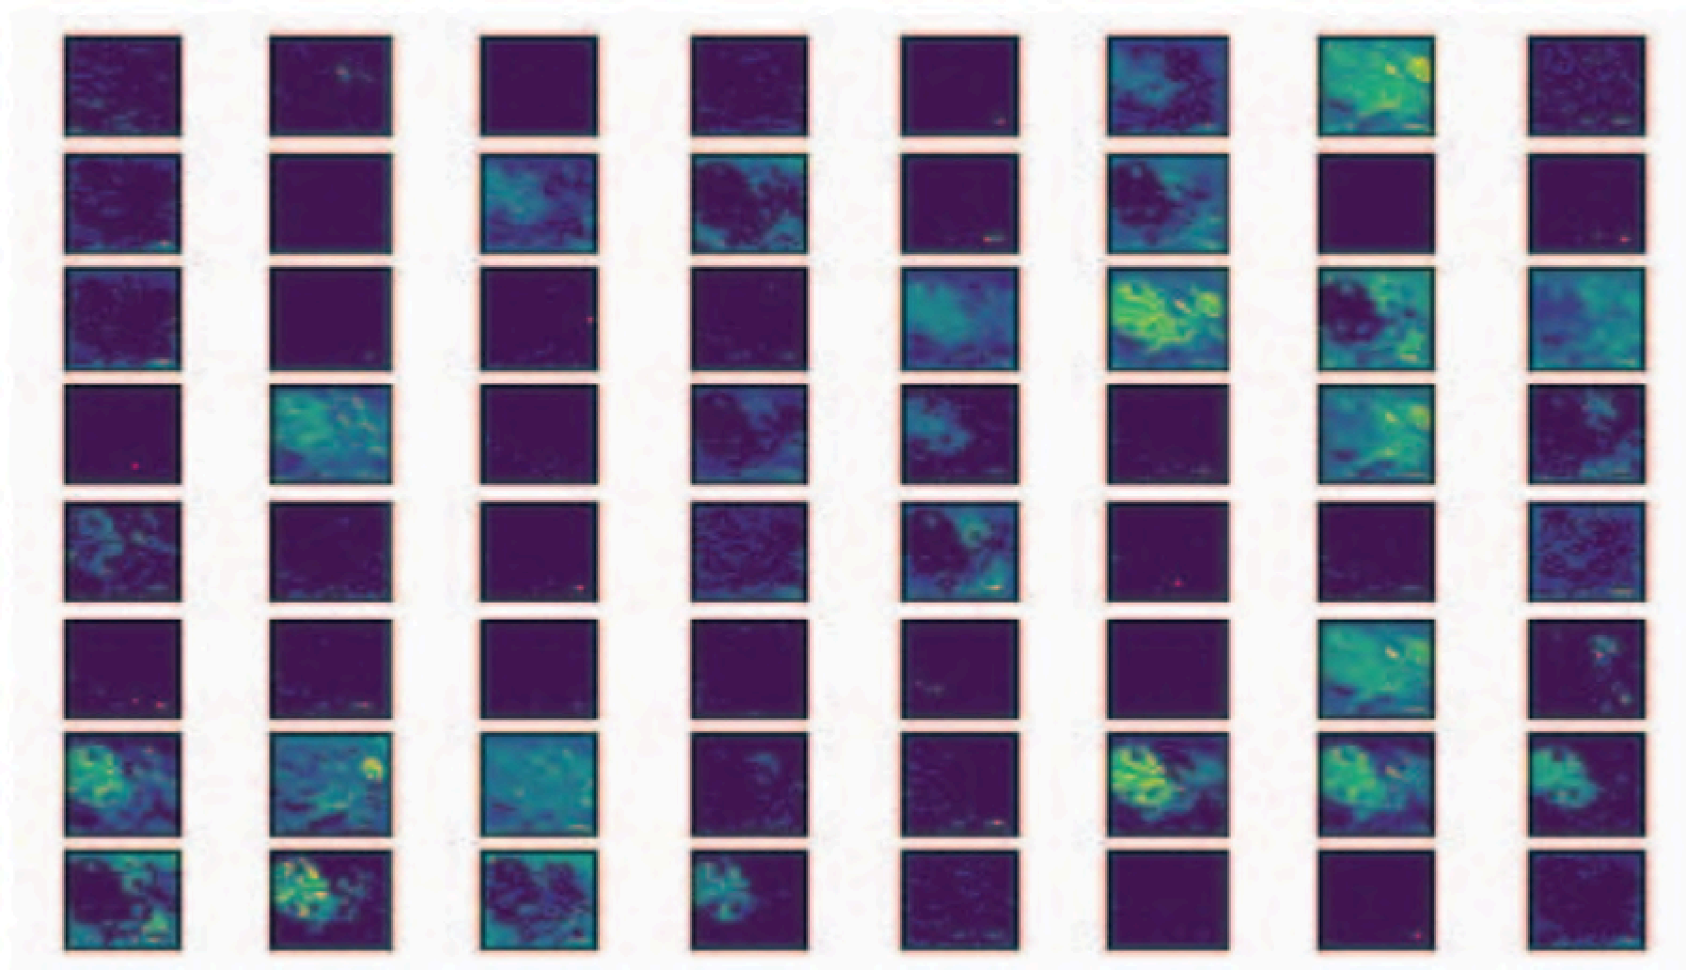

- Usa una CNN (varias conv+BN+pool, Dropout, Flatten y Dense) para clasificar 15 clases de hojas (12 enfermas + 3 sanas). Optimiza con Adam y reporta accuracy de test = 88.8% con train = 97.42%

- Se realizó una visualización de los mapas de características para comprobar qué aprende la red en cada capa convolucional
- Diseñada desde cero, no basada en transfer learning

AGROVISION

ESTADO DEL ARTE

Identification of Plant-Leaf Diseases Using CNN and Transfer Learning

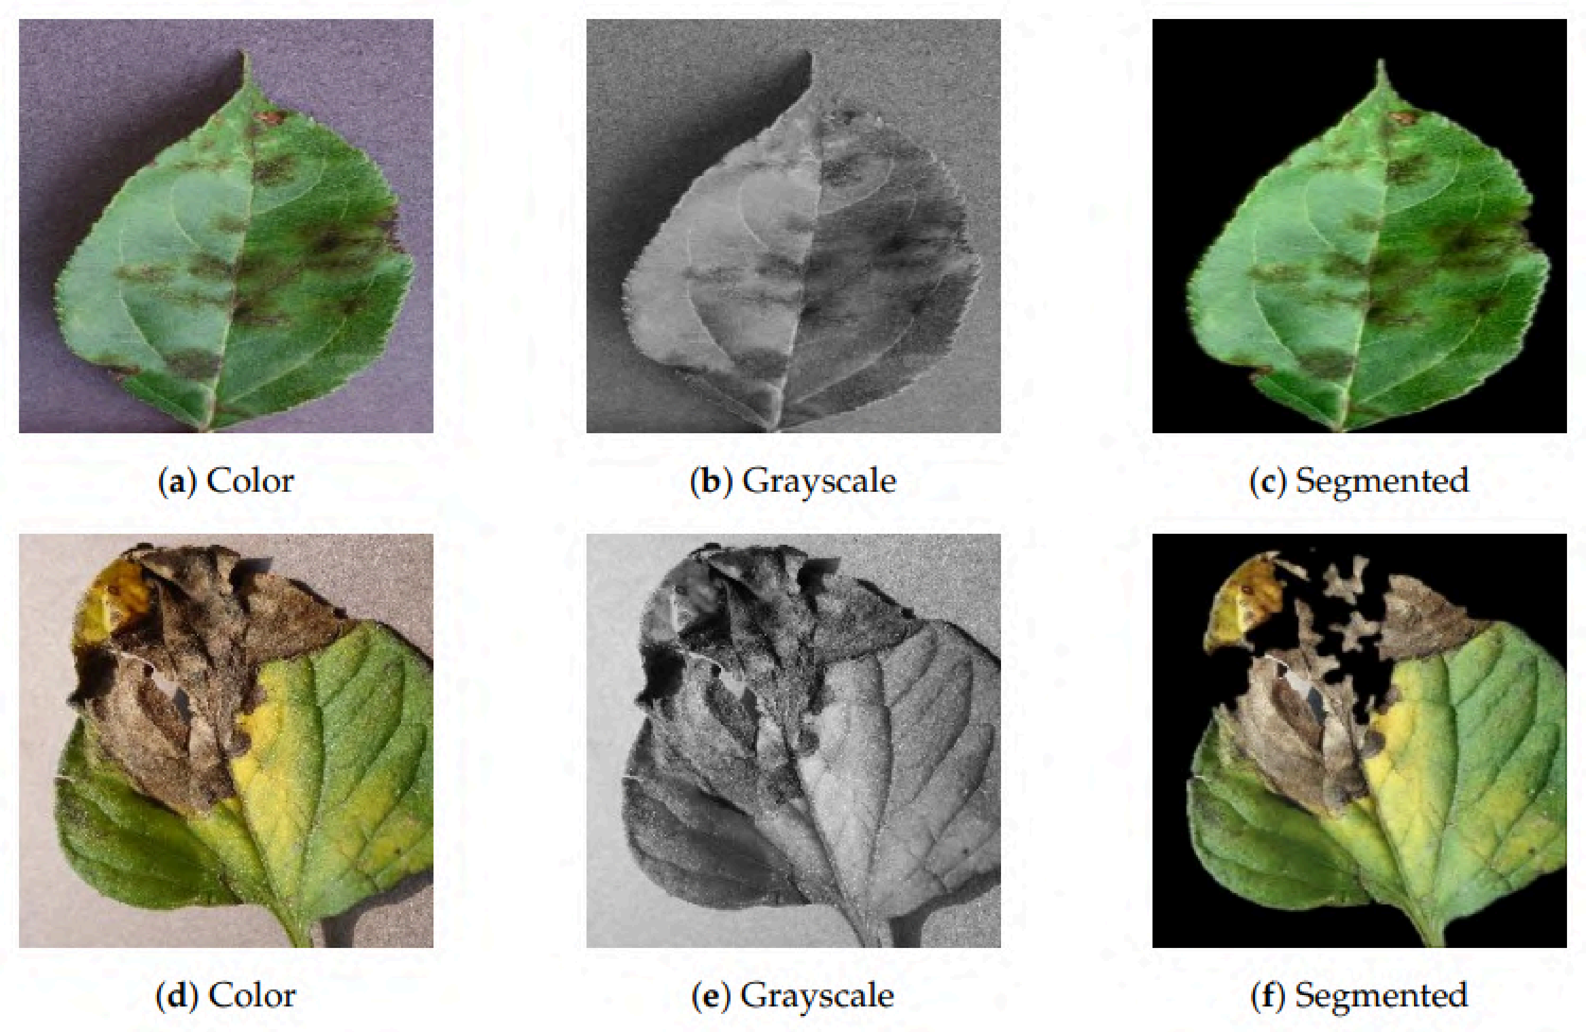

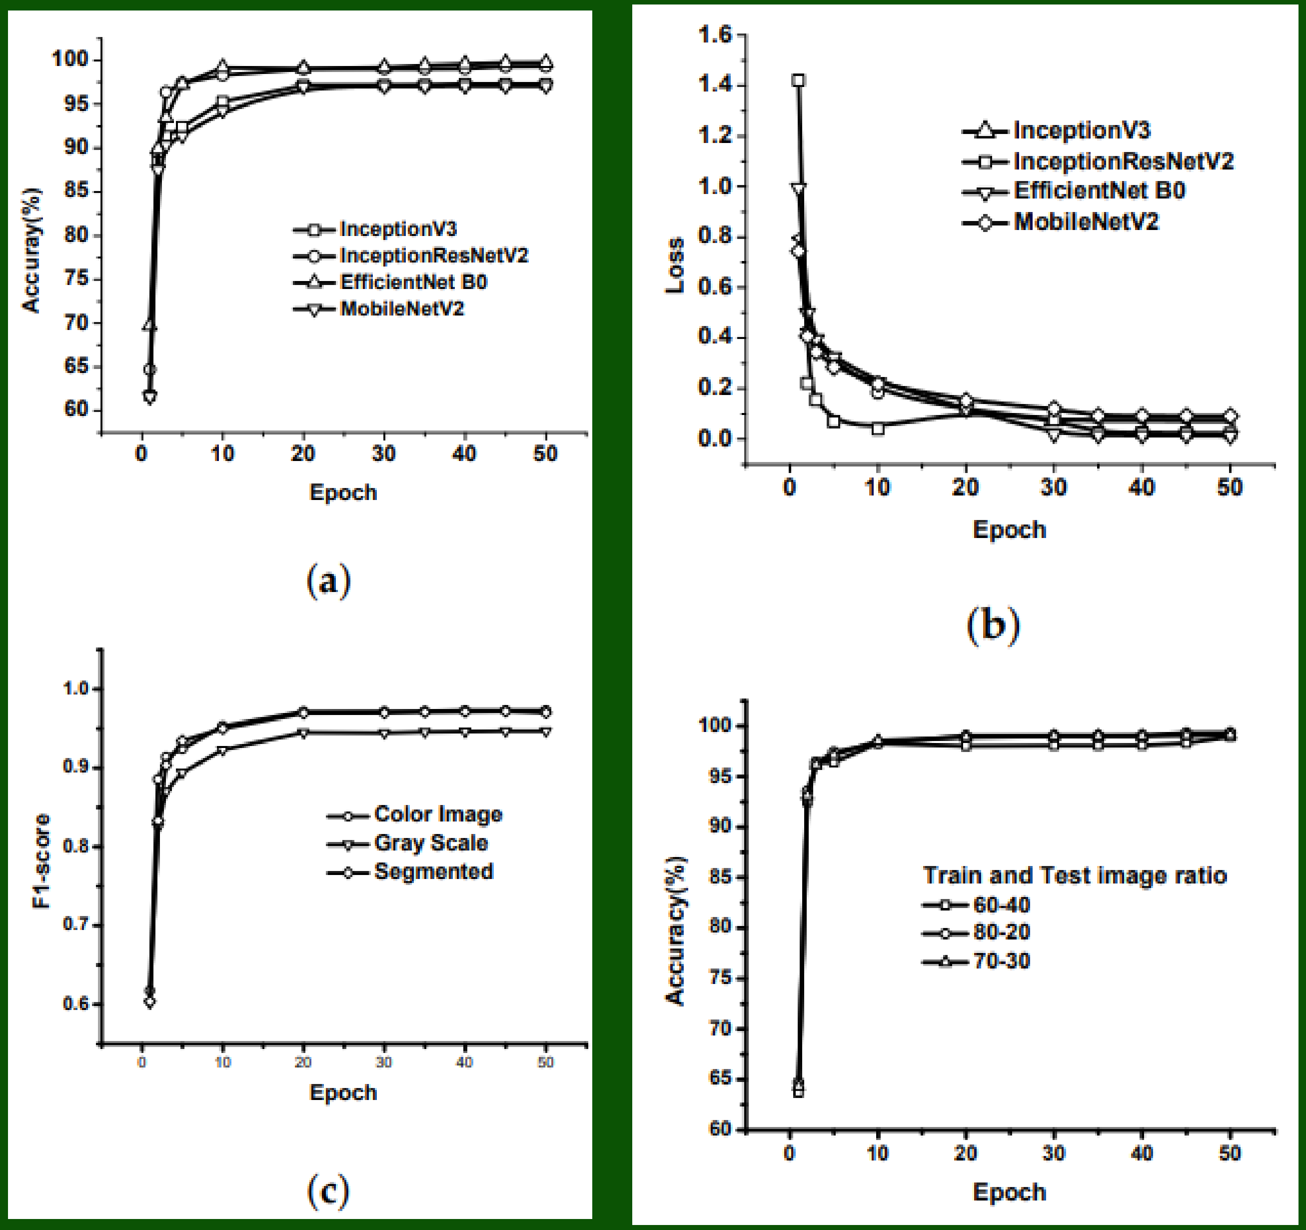

- Compara arquitecturas InceptionV3, InceptionResNetV2, MobileNetV2 y EfficientNetB0 sobre el dataset PlantVillage (54 305 imágenes, 38 clases).

- Basada en transfer learning

AGROVISION

NUETRAS **PROPUESTAS**

AGROVISION

PREPROCESAMIENTO

- Redimensionamiento (64x64)
- Normalización [0,1]
- Division del dataset (Train, Val, Test)

Google Colab
google.com

AGROVISION

DNN

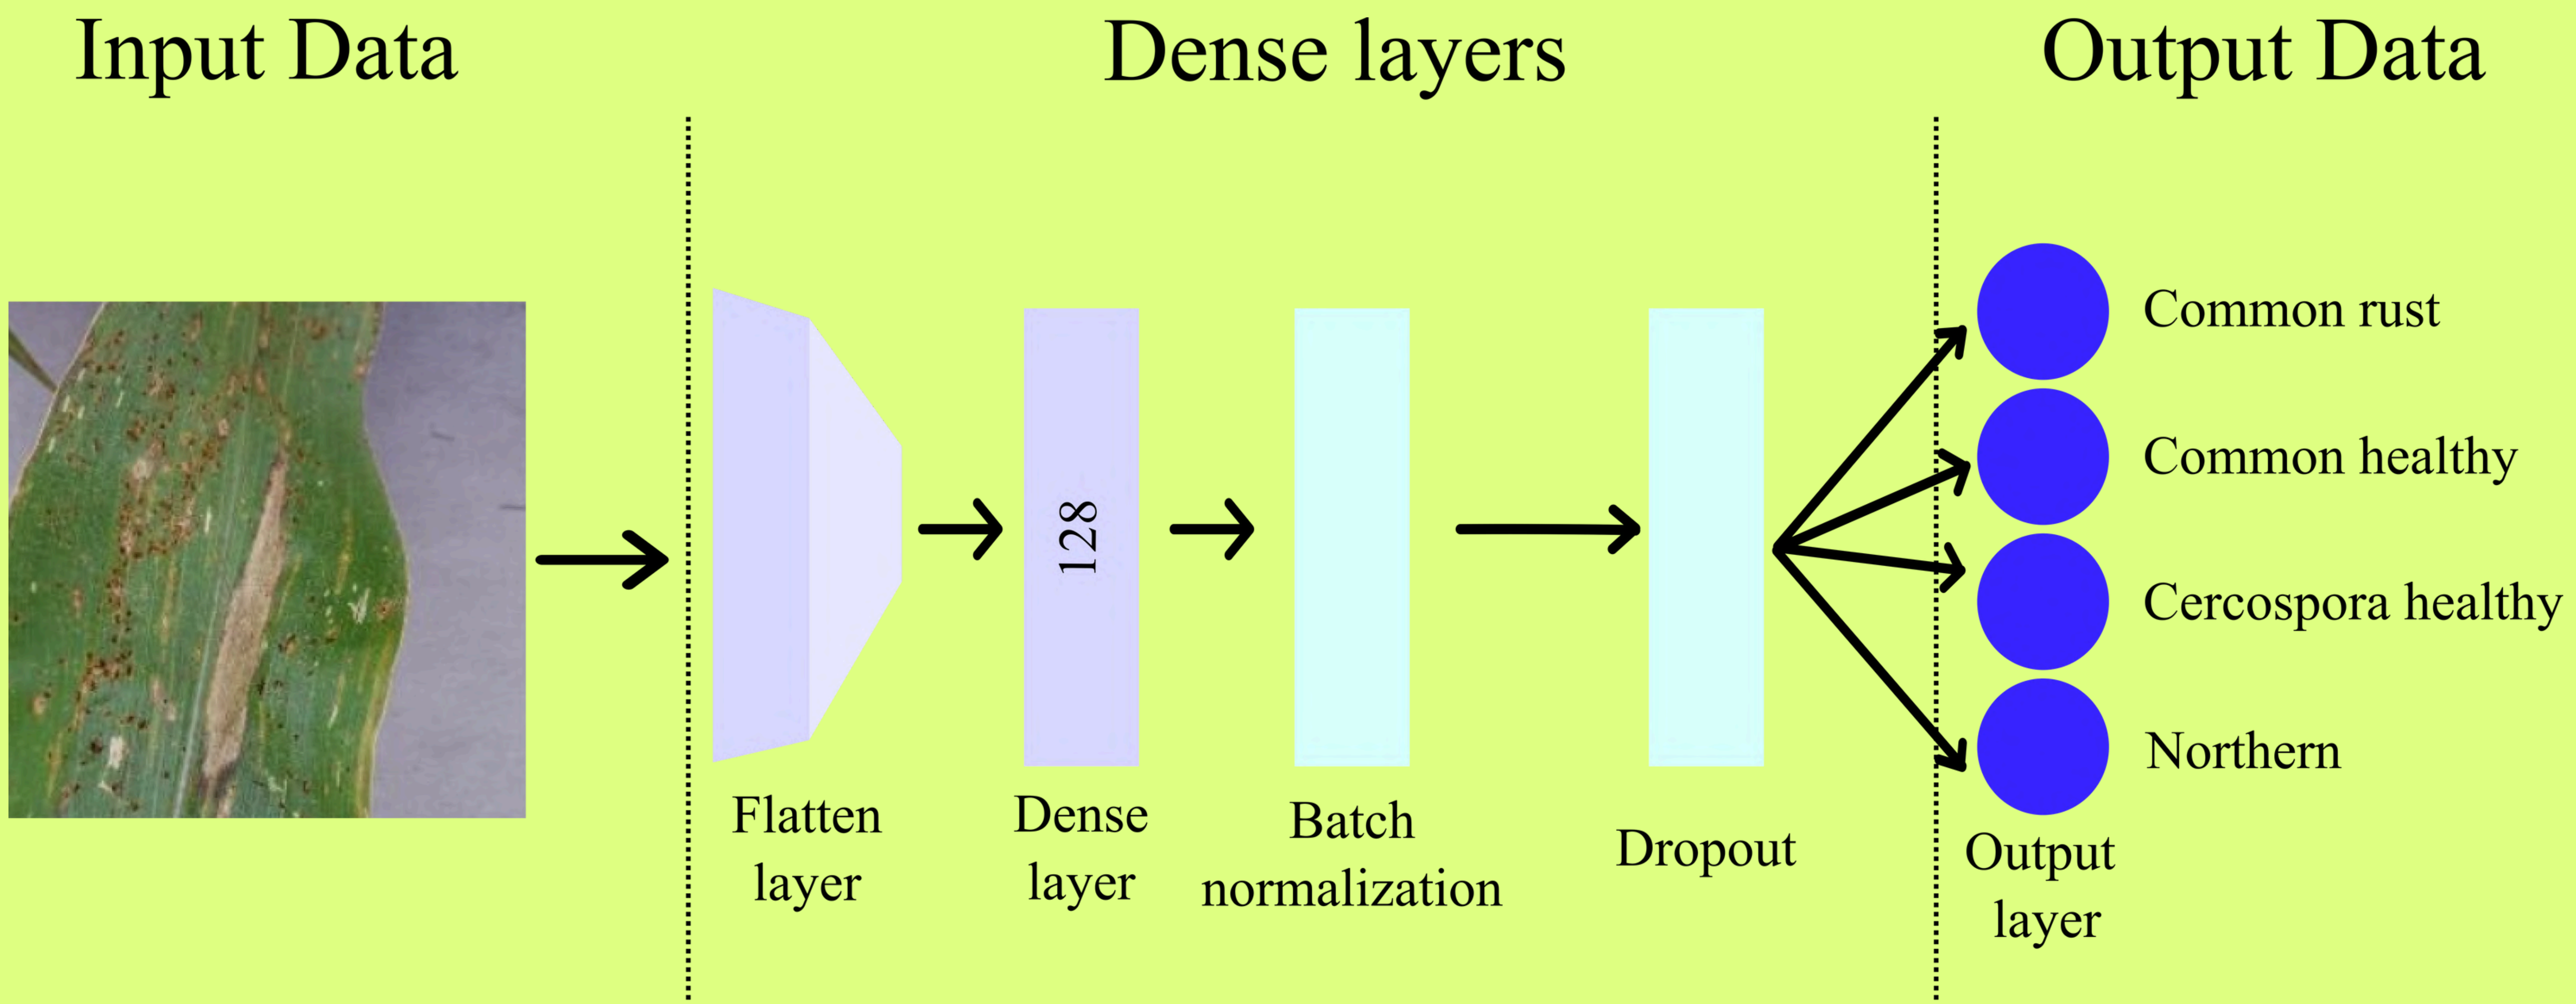

- Adam, LR = 3e-4, EarlyStopping, ReduceLROnPlateau

AGROVISION

DNN

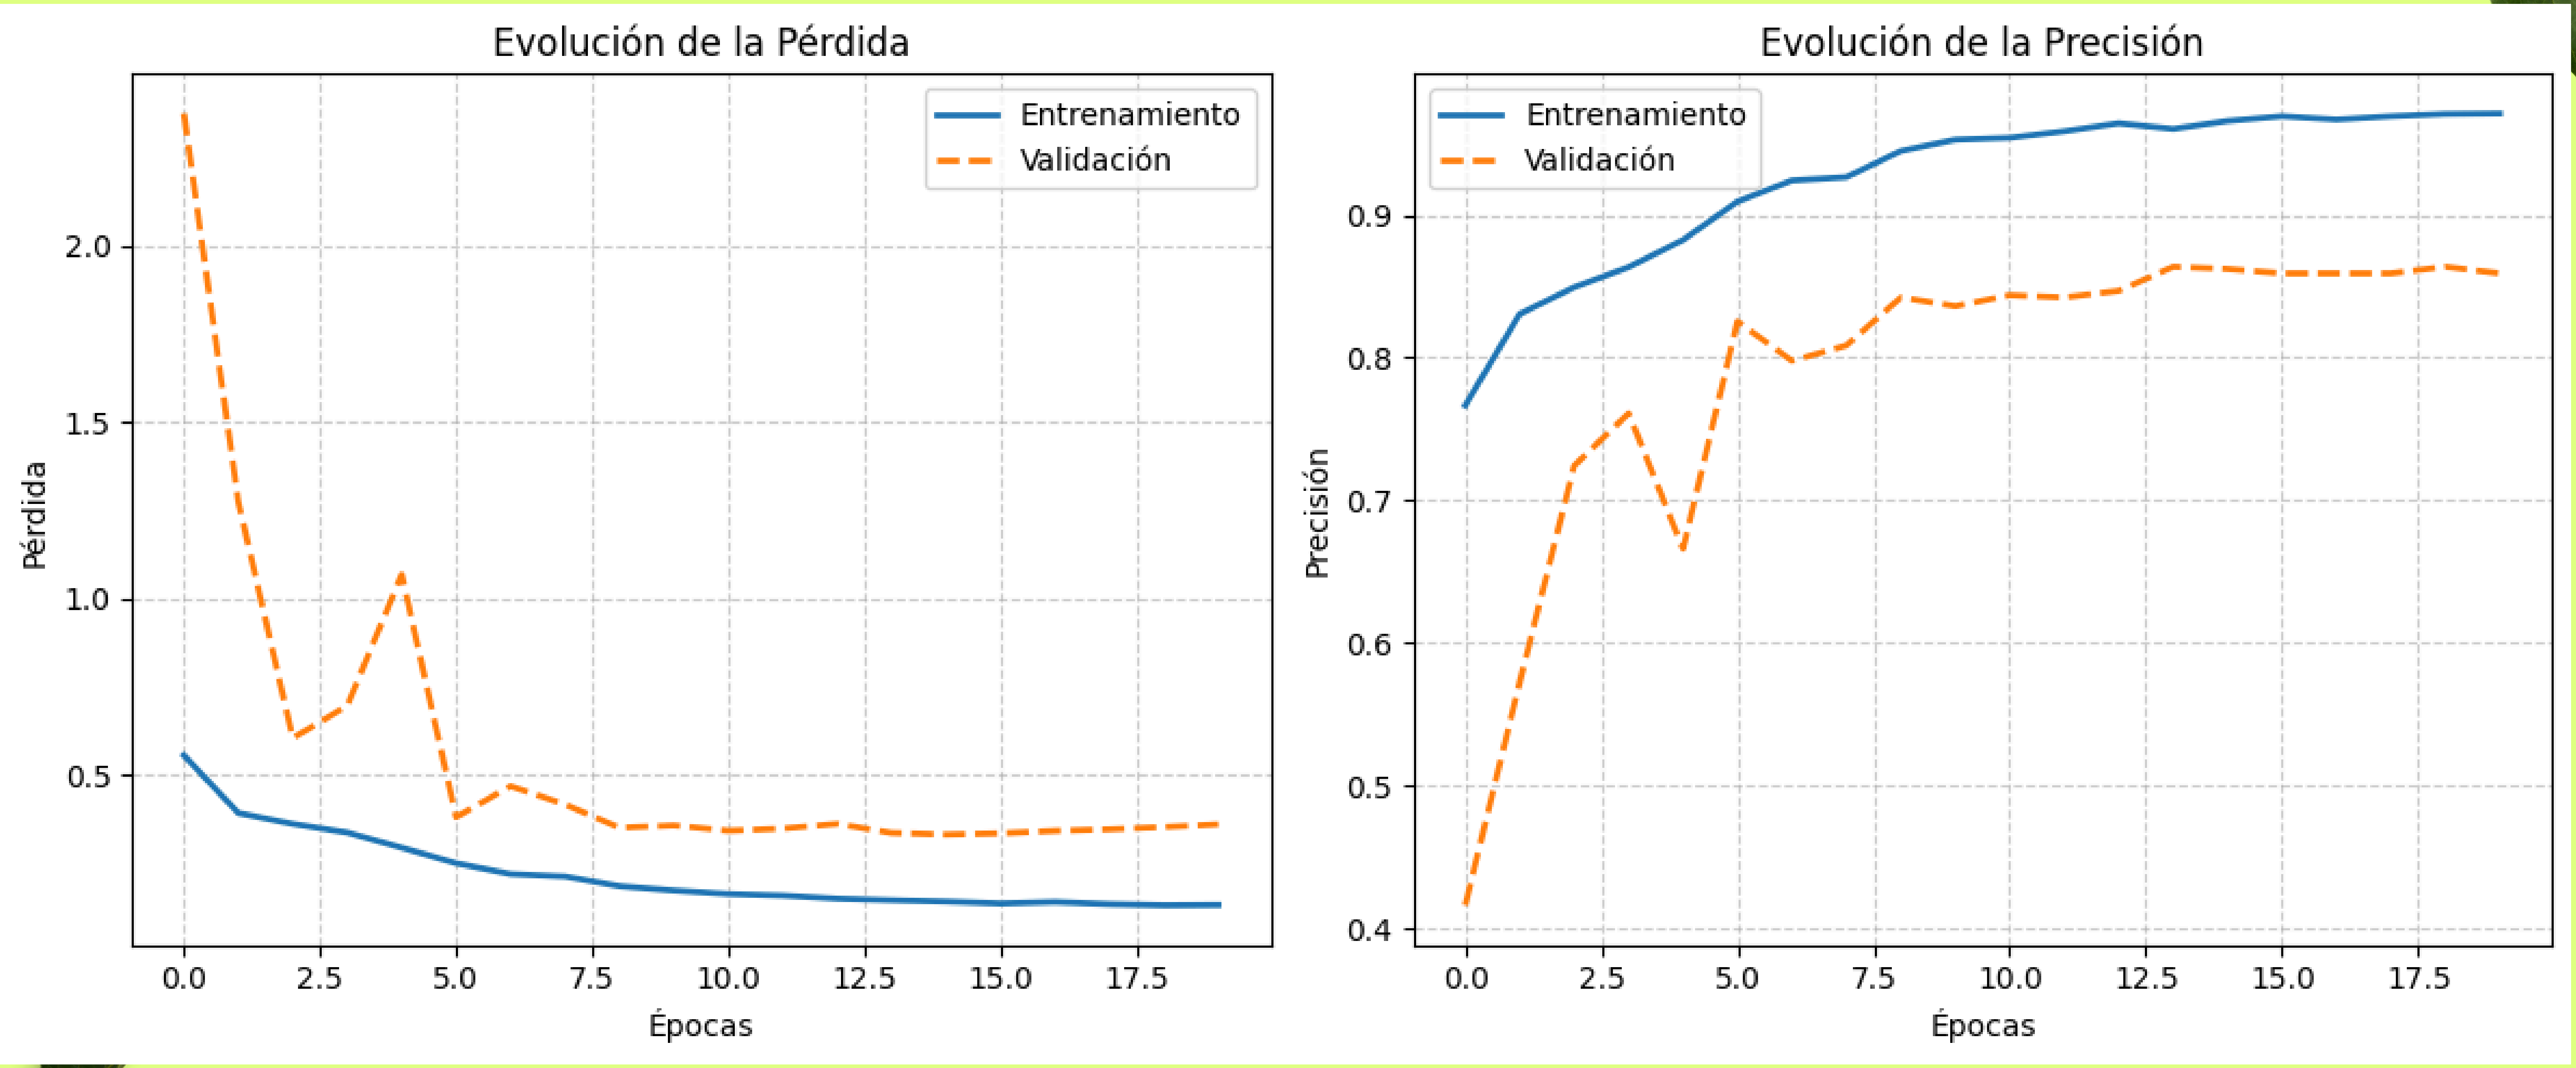

AGROVISION

DNN

Accuracy

0.84

Macro AUC (OvR)

0.96

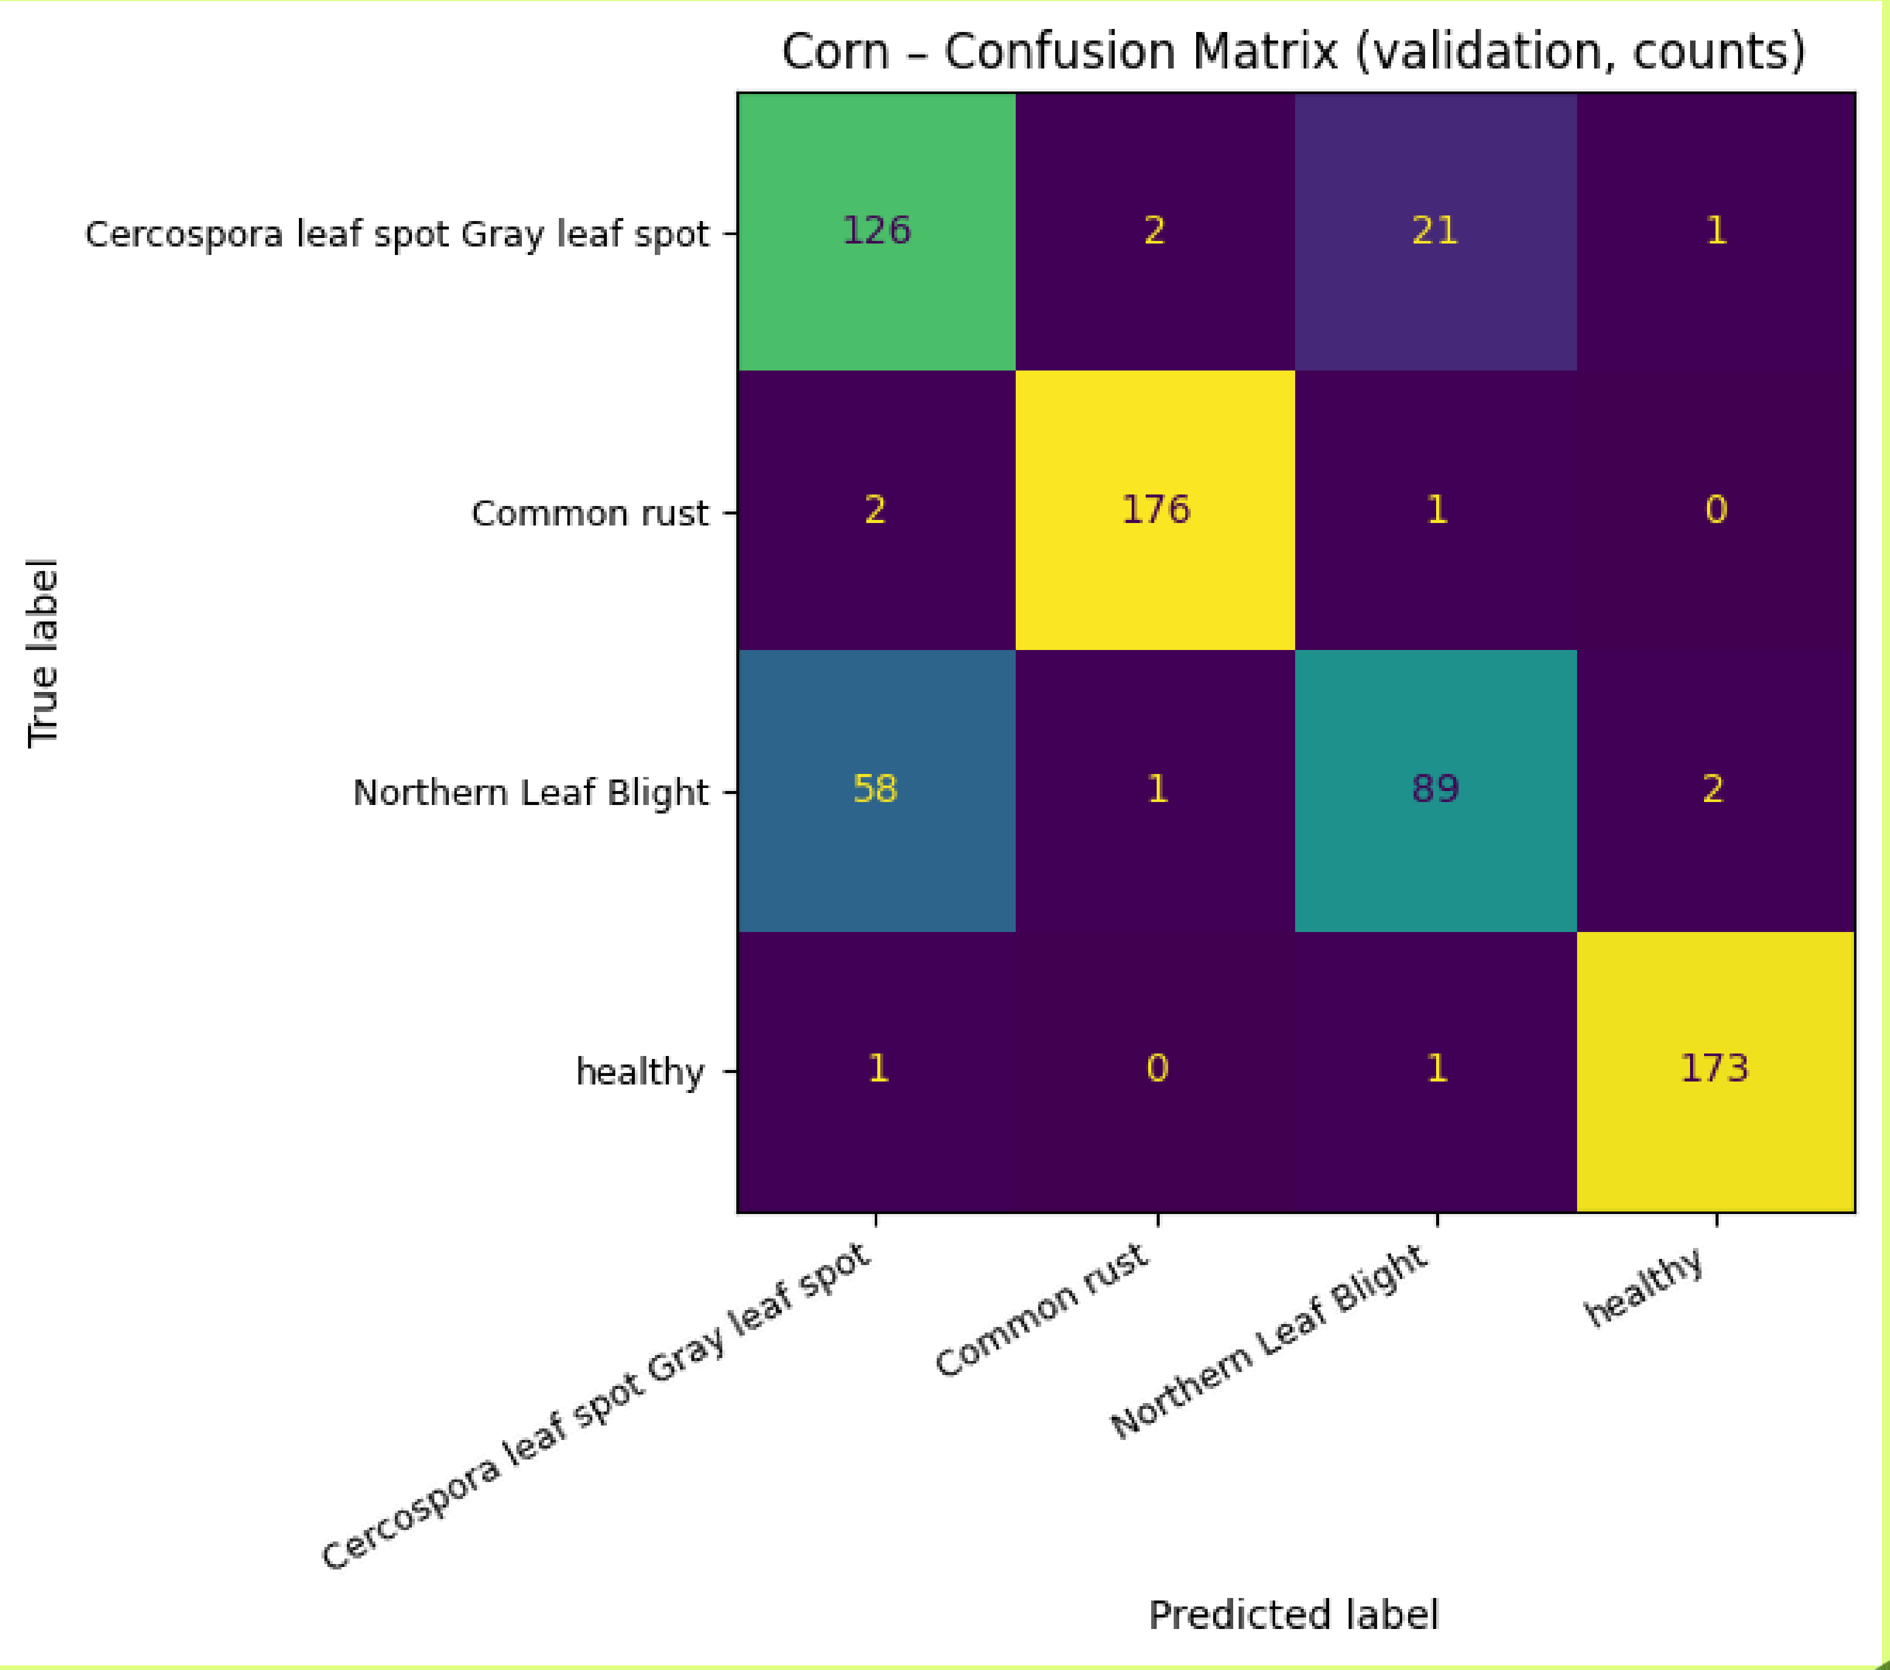

AGROVISION

DATASET

HEALTHY

VIRUS

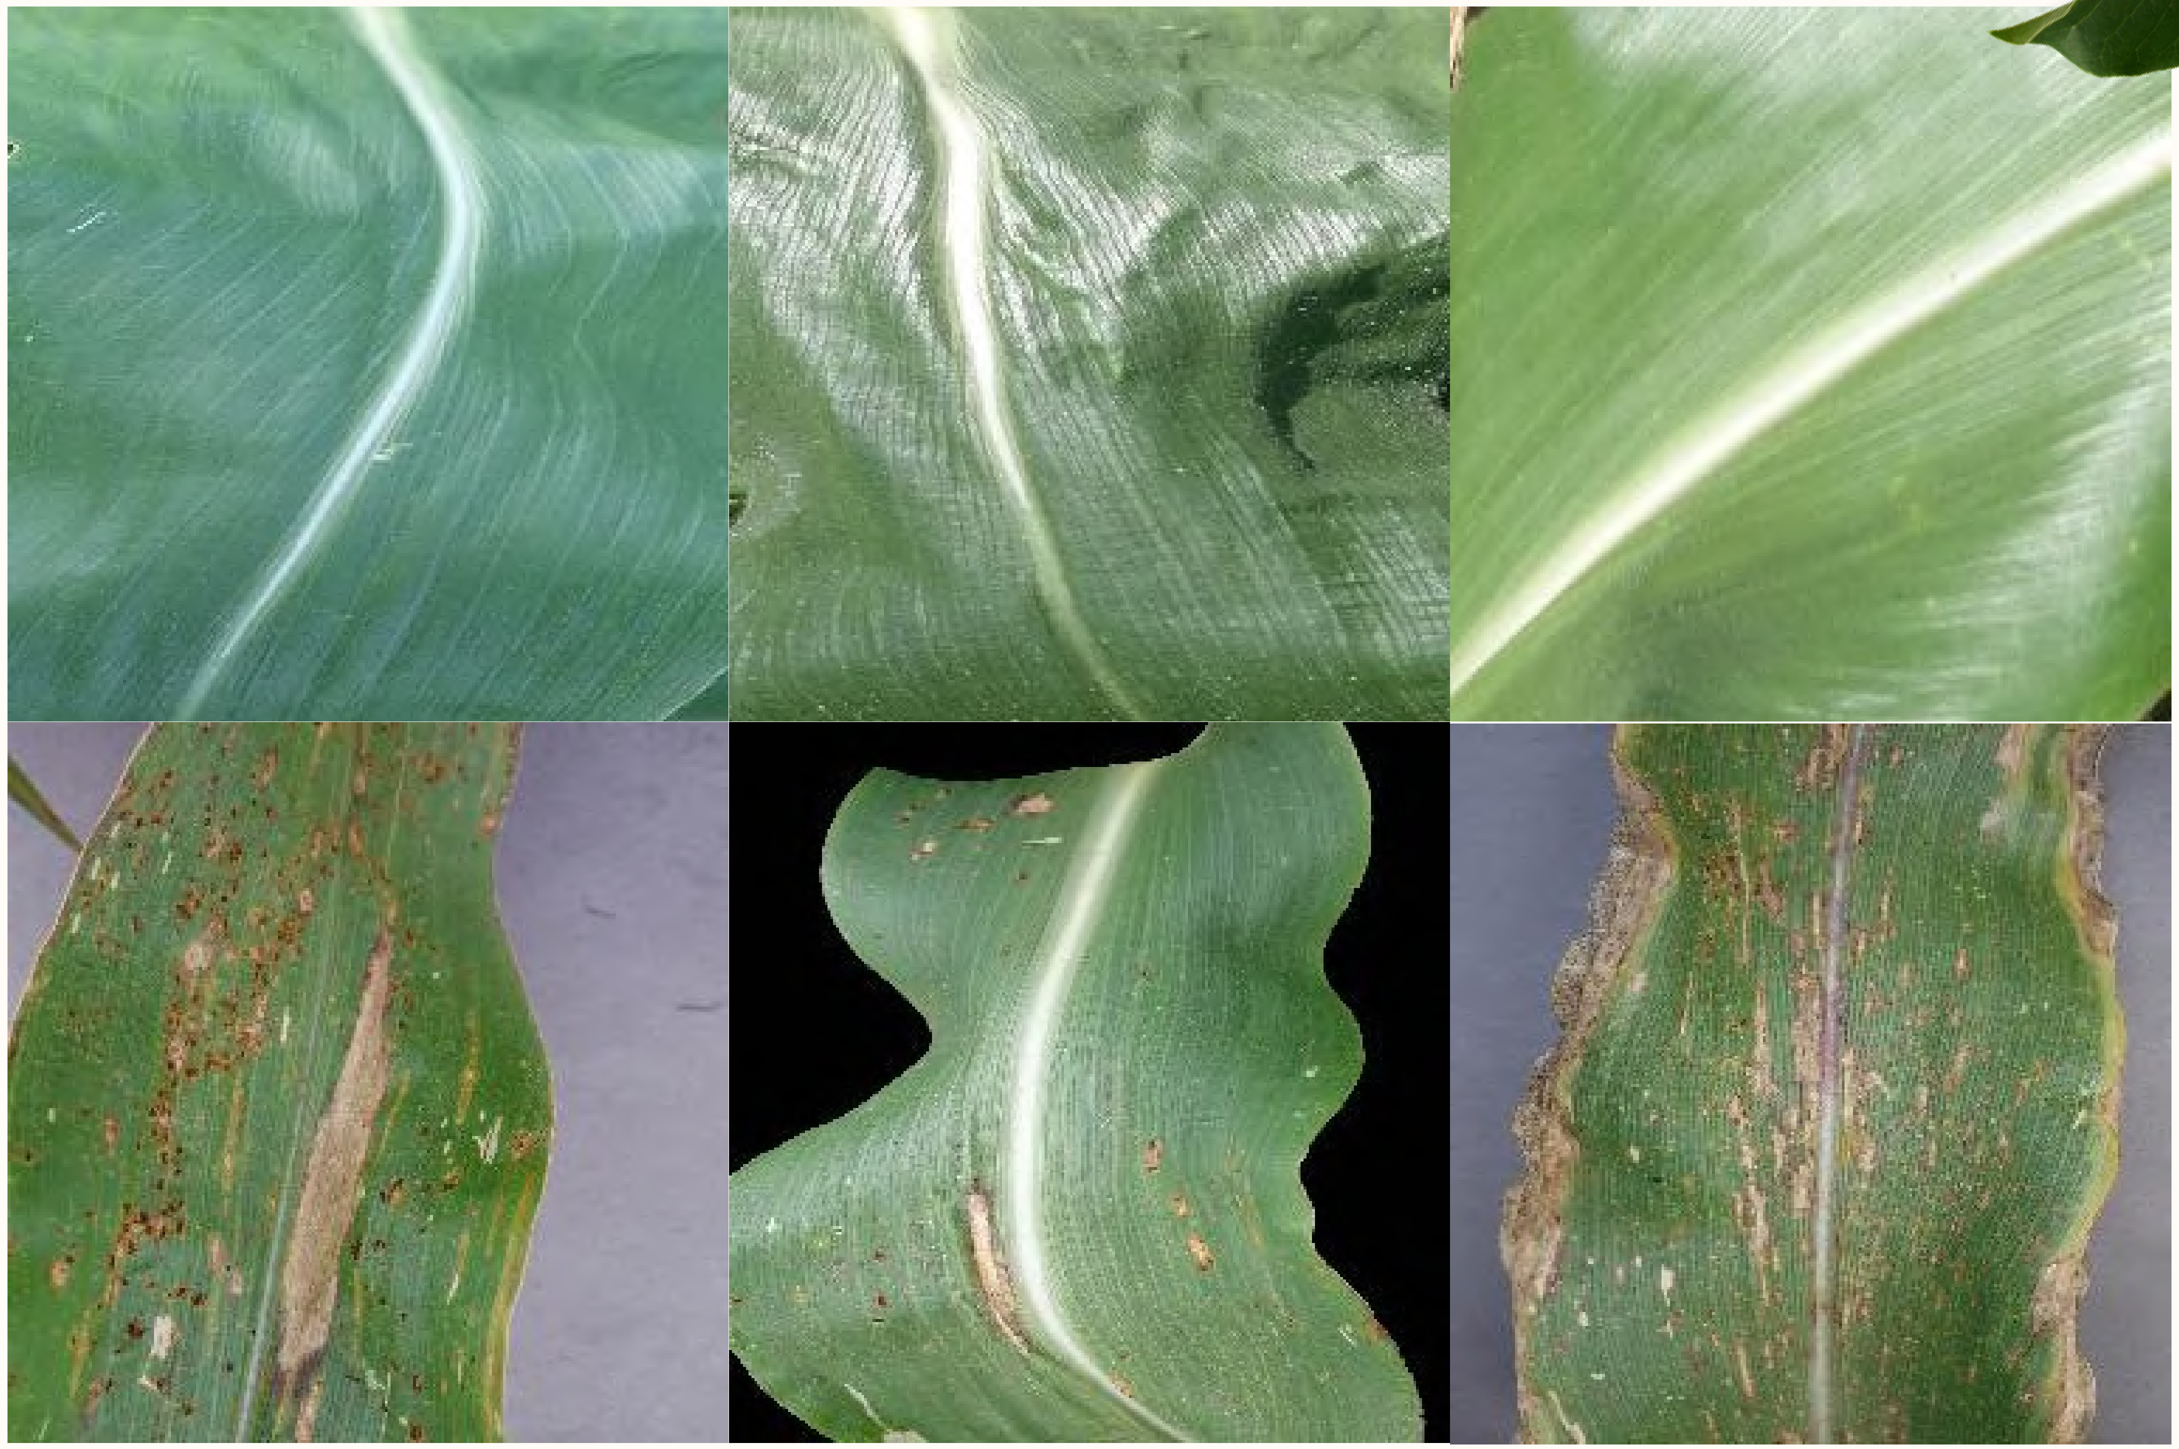

TIZÓN NORTEÑO OXIDO COMUN CERCOSPORA

AGROVISION

DNN

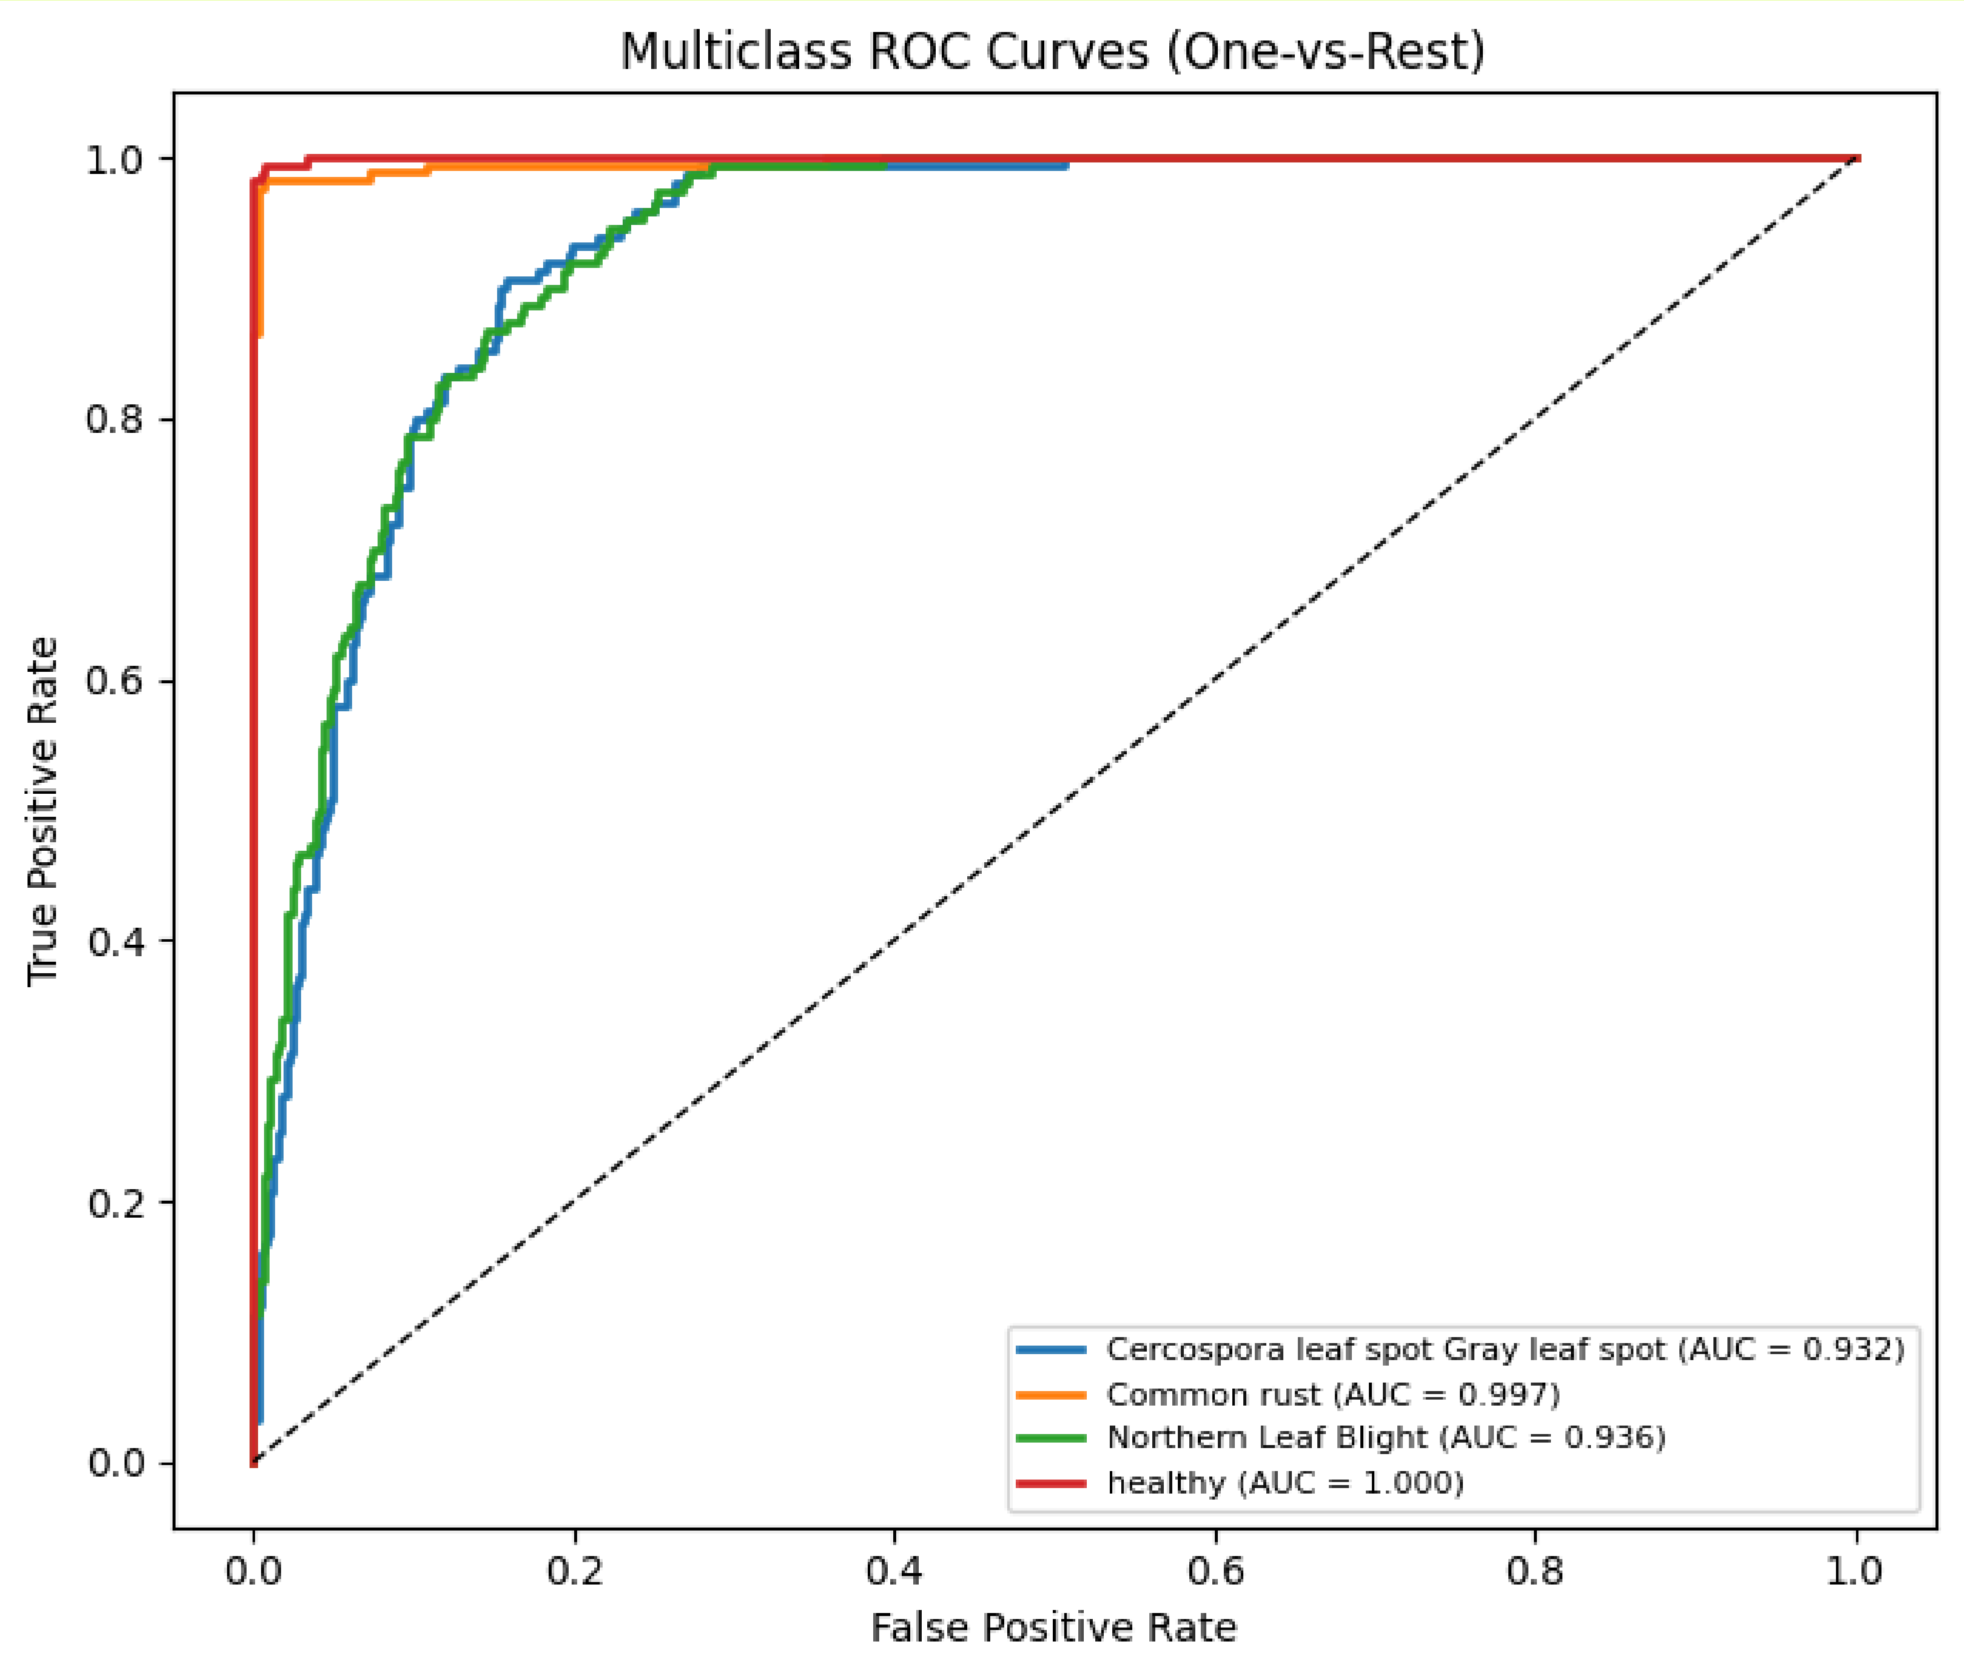

AGROVISION

CNN 1.0

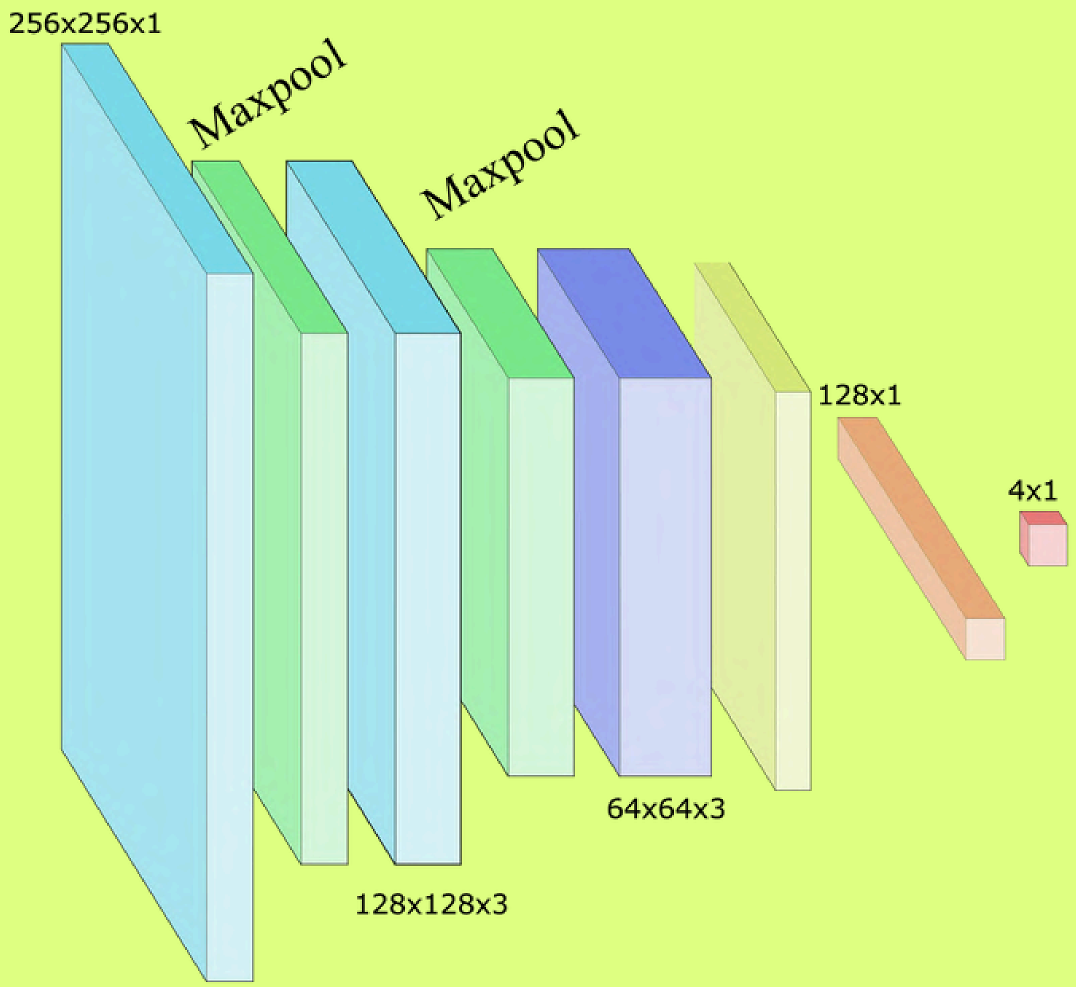

Conv + ReLU
+ BatchNorm + Dropout

Conv + ReLU
+ BatchNorm + Dropout

Conv + ReLU
+ BatchNorm

GAP

Dropout + Dense
+ Dropout

Dense
+ Softmax

- AdamW, weight decay = 1e-4, LR = 3e-4, EarlyStopping, ReduceLROnPlateau

AGROVISION

CNN 1.0

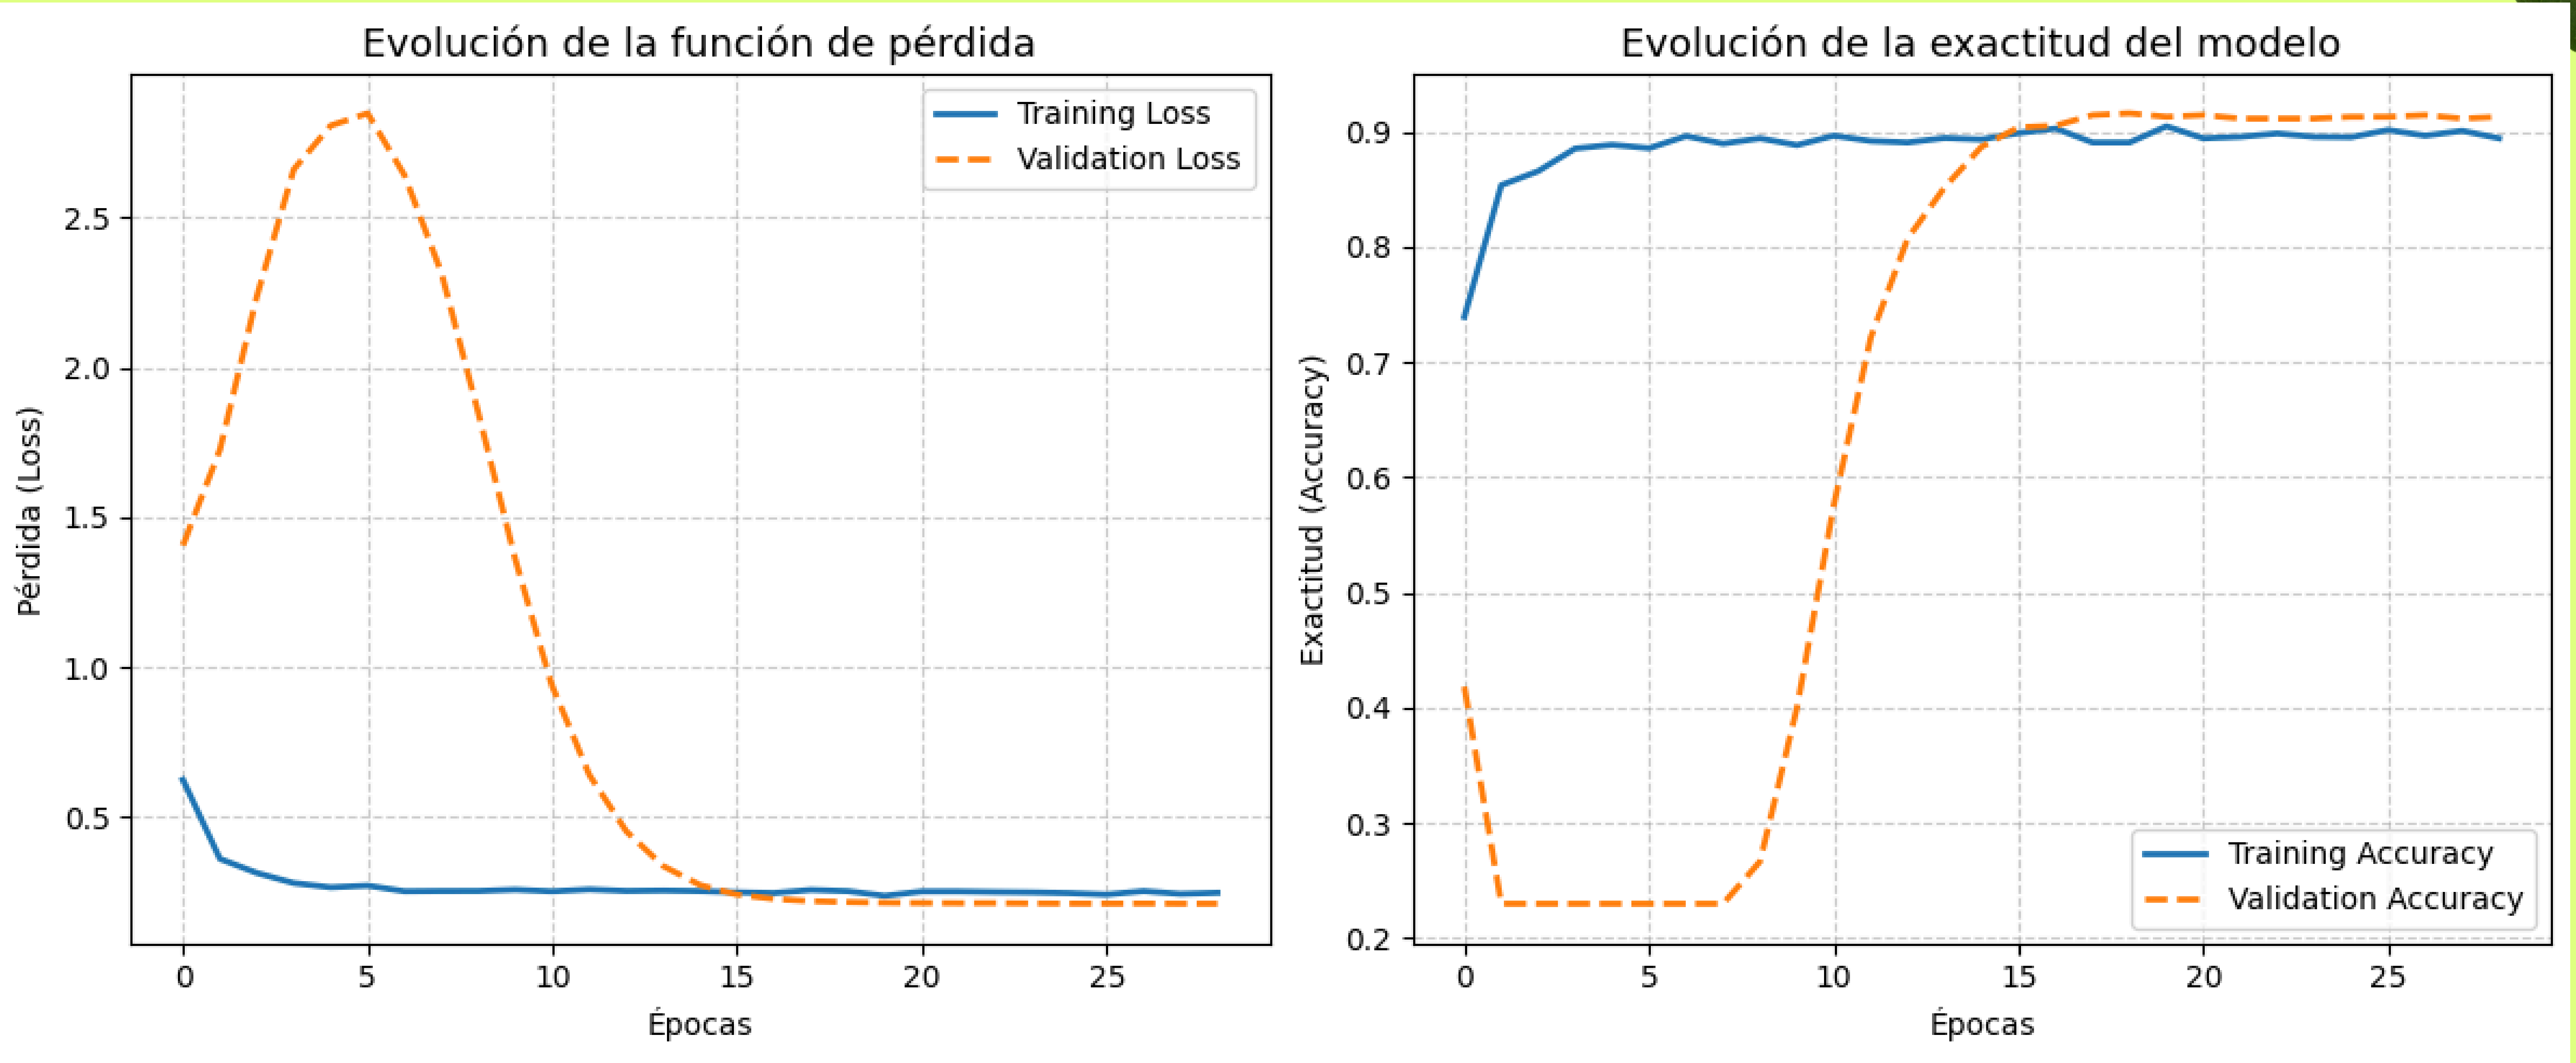

AGROVISION

CNN 1.0

Accuracy

0.91

Macro AUC (OvR)

0.98

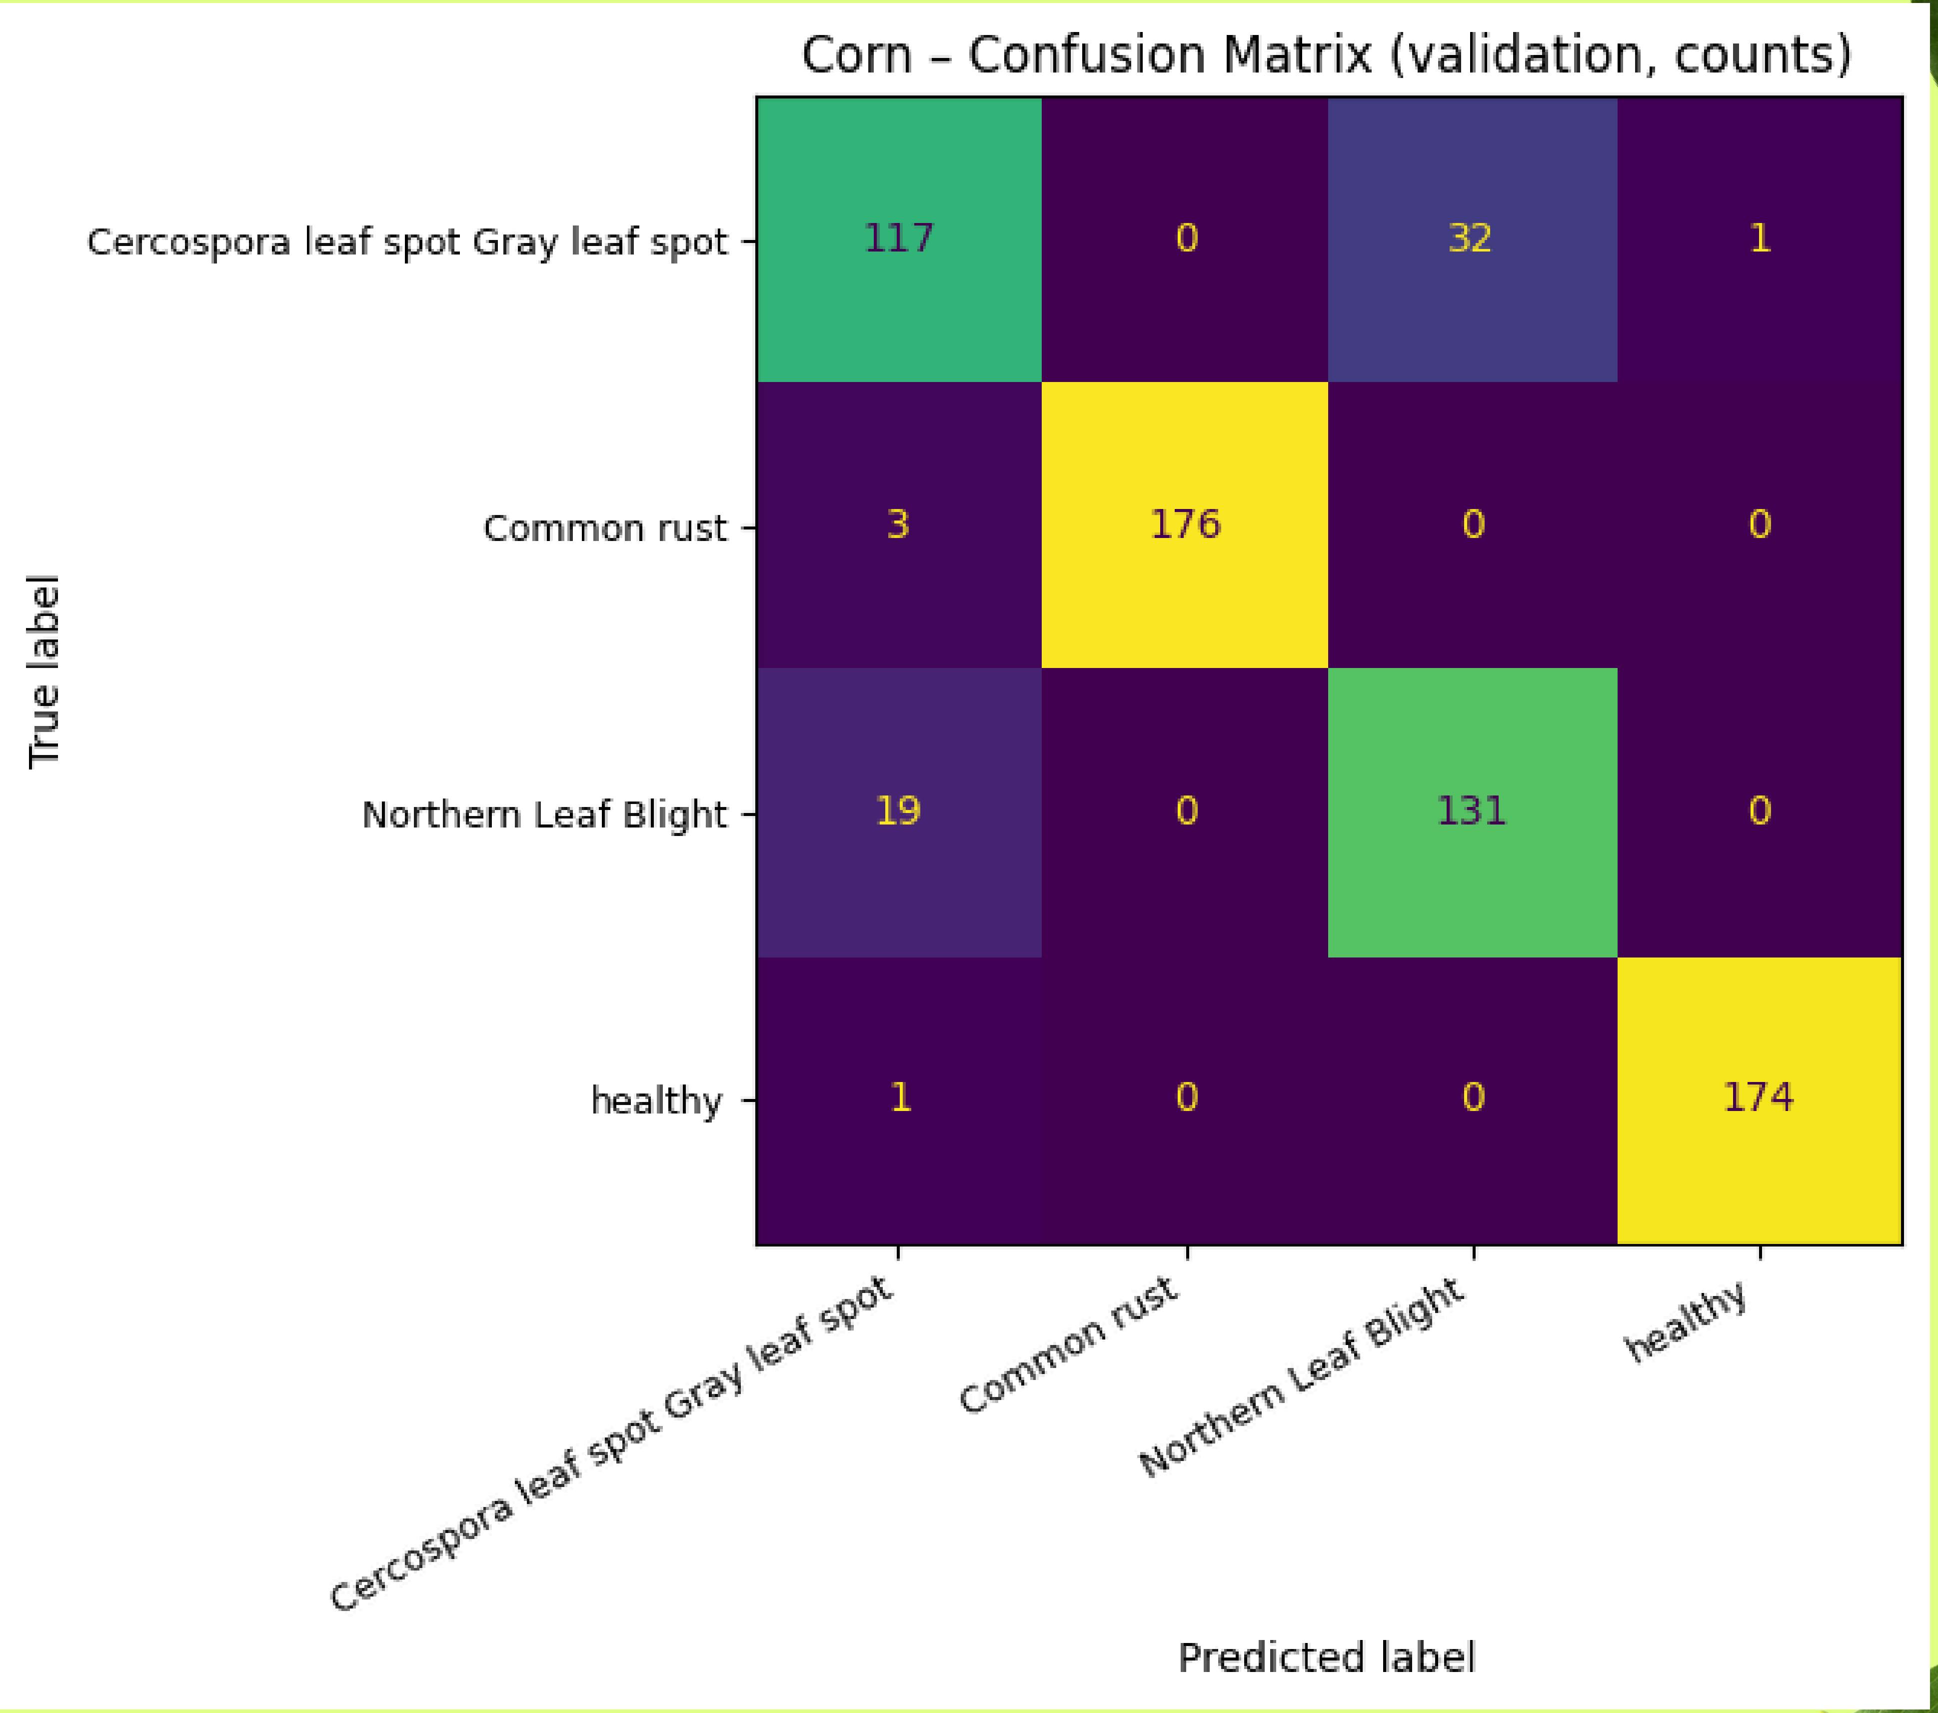

AGROVISION

CNN 1.0

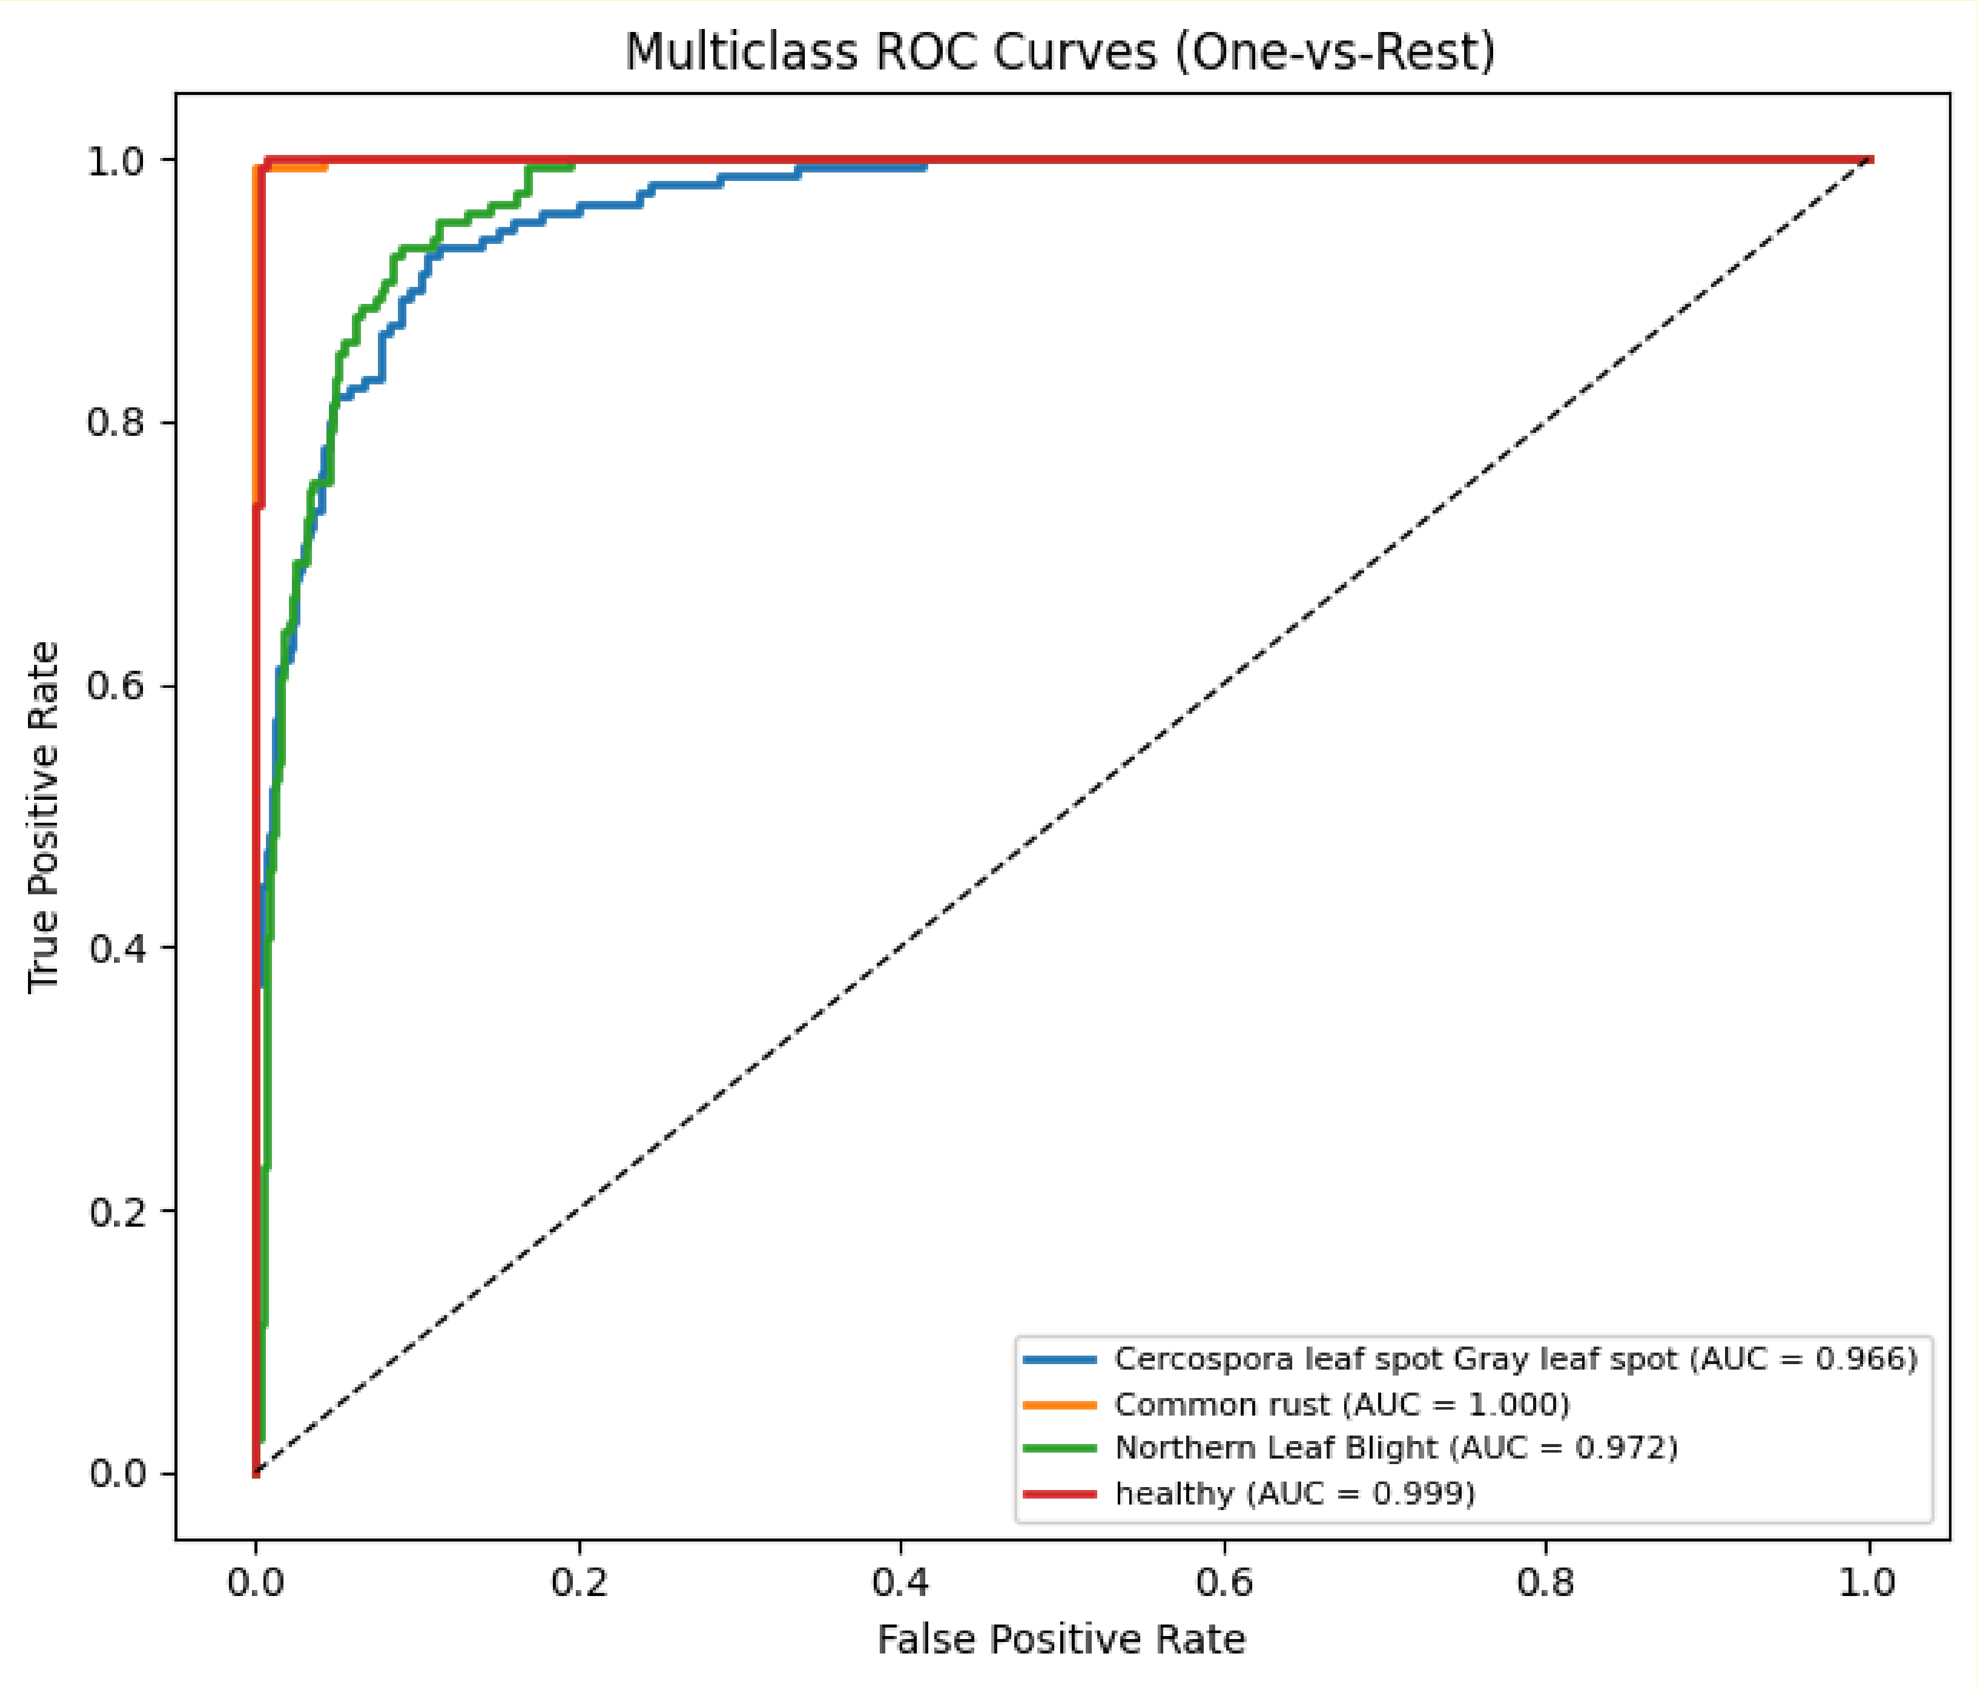

VISUALIZACIÓN DE SELECTIVIDAD DE KERNELS

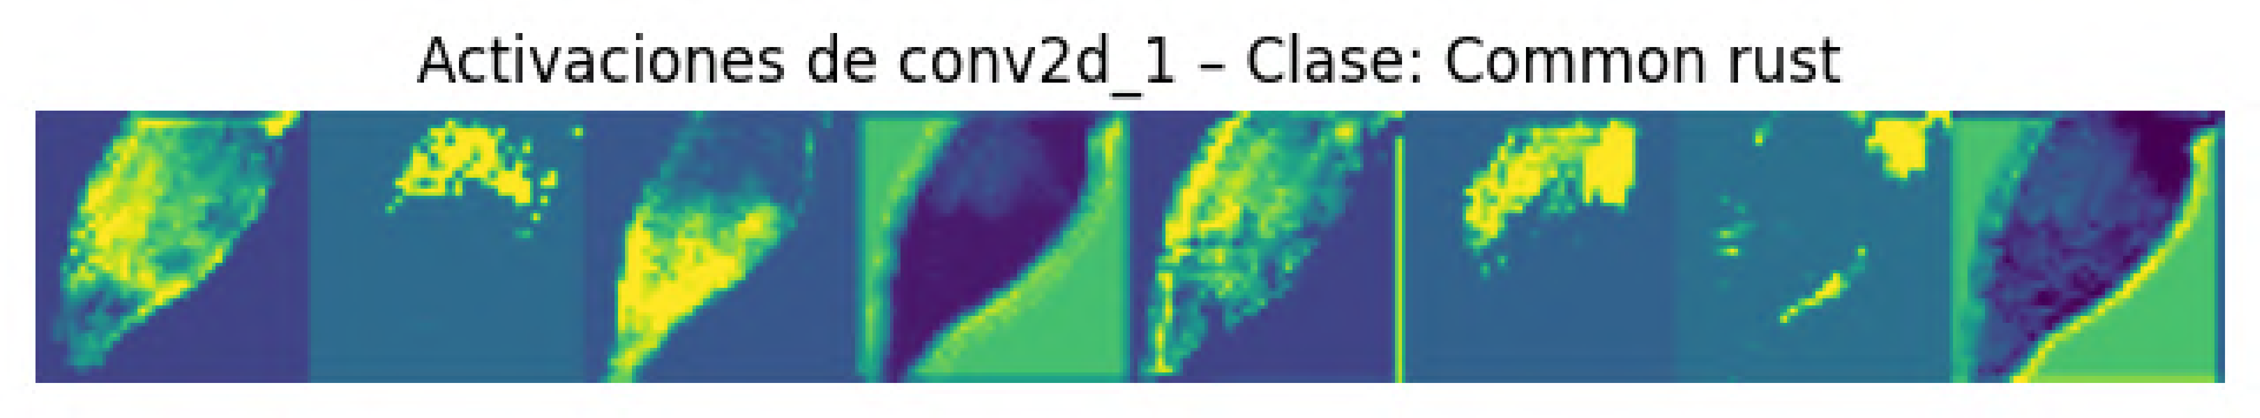

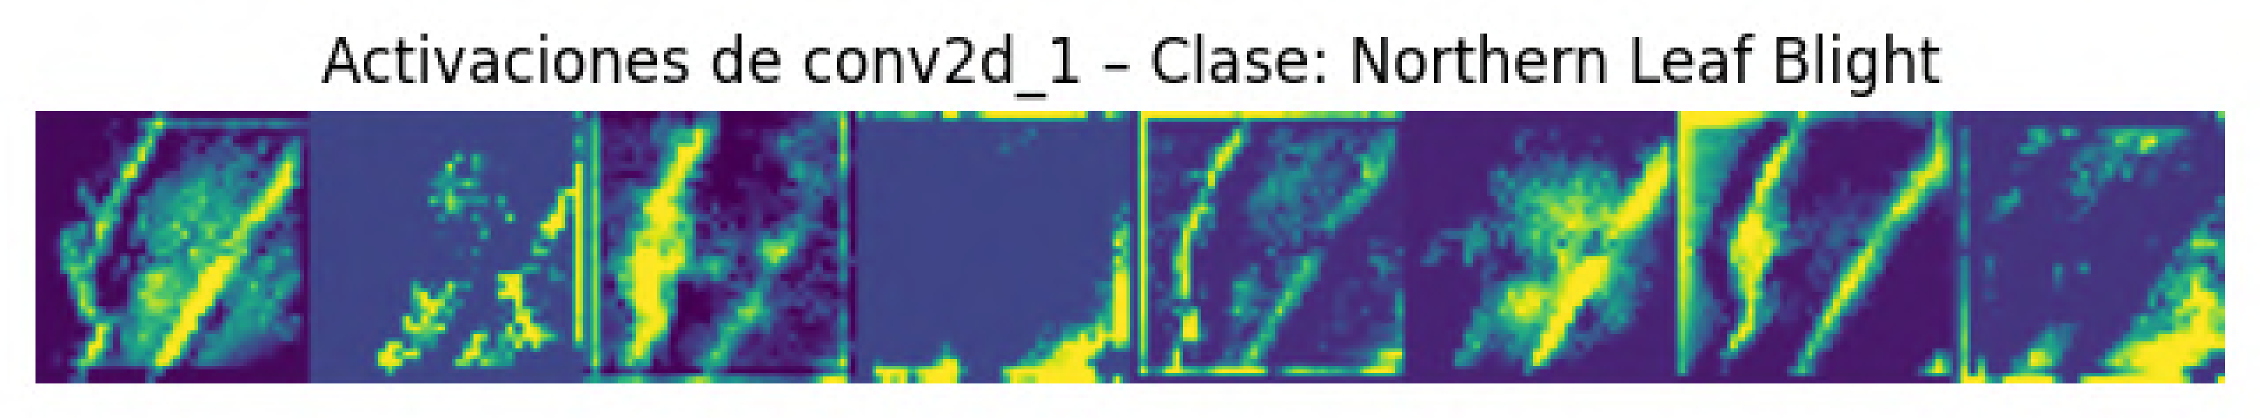

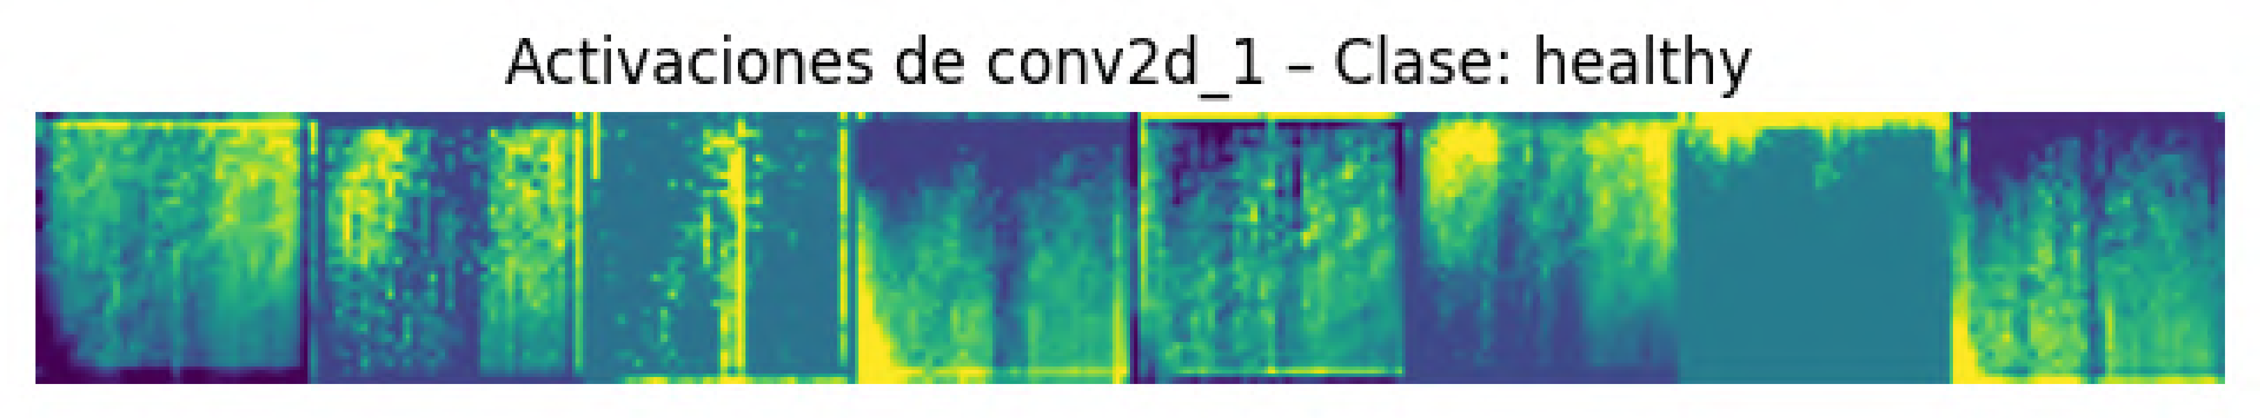

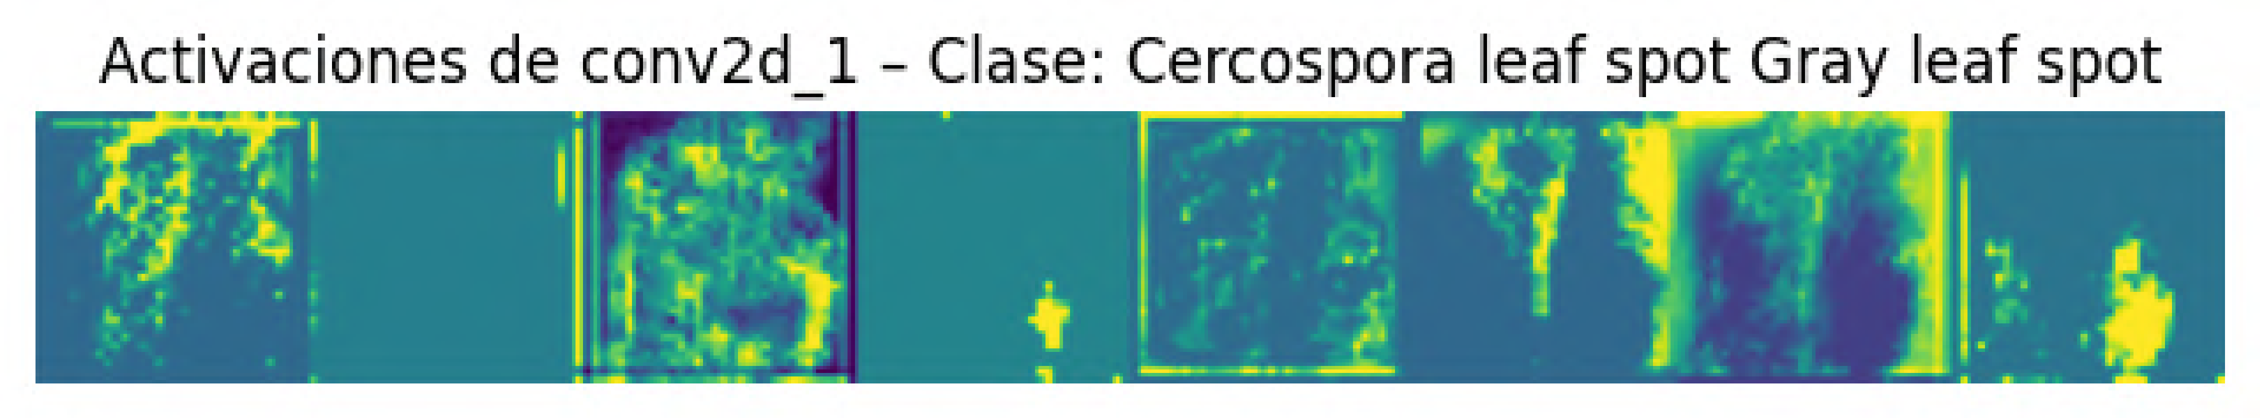

VISUALIZACIÓN DE SELECTIVIDAD DE KERNELS

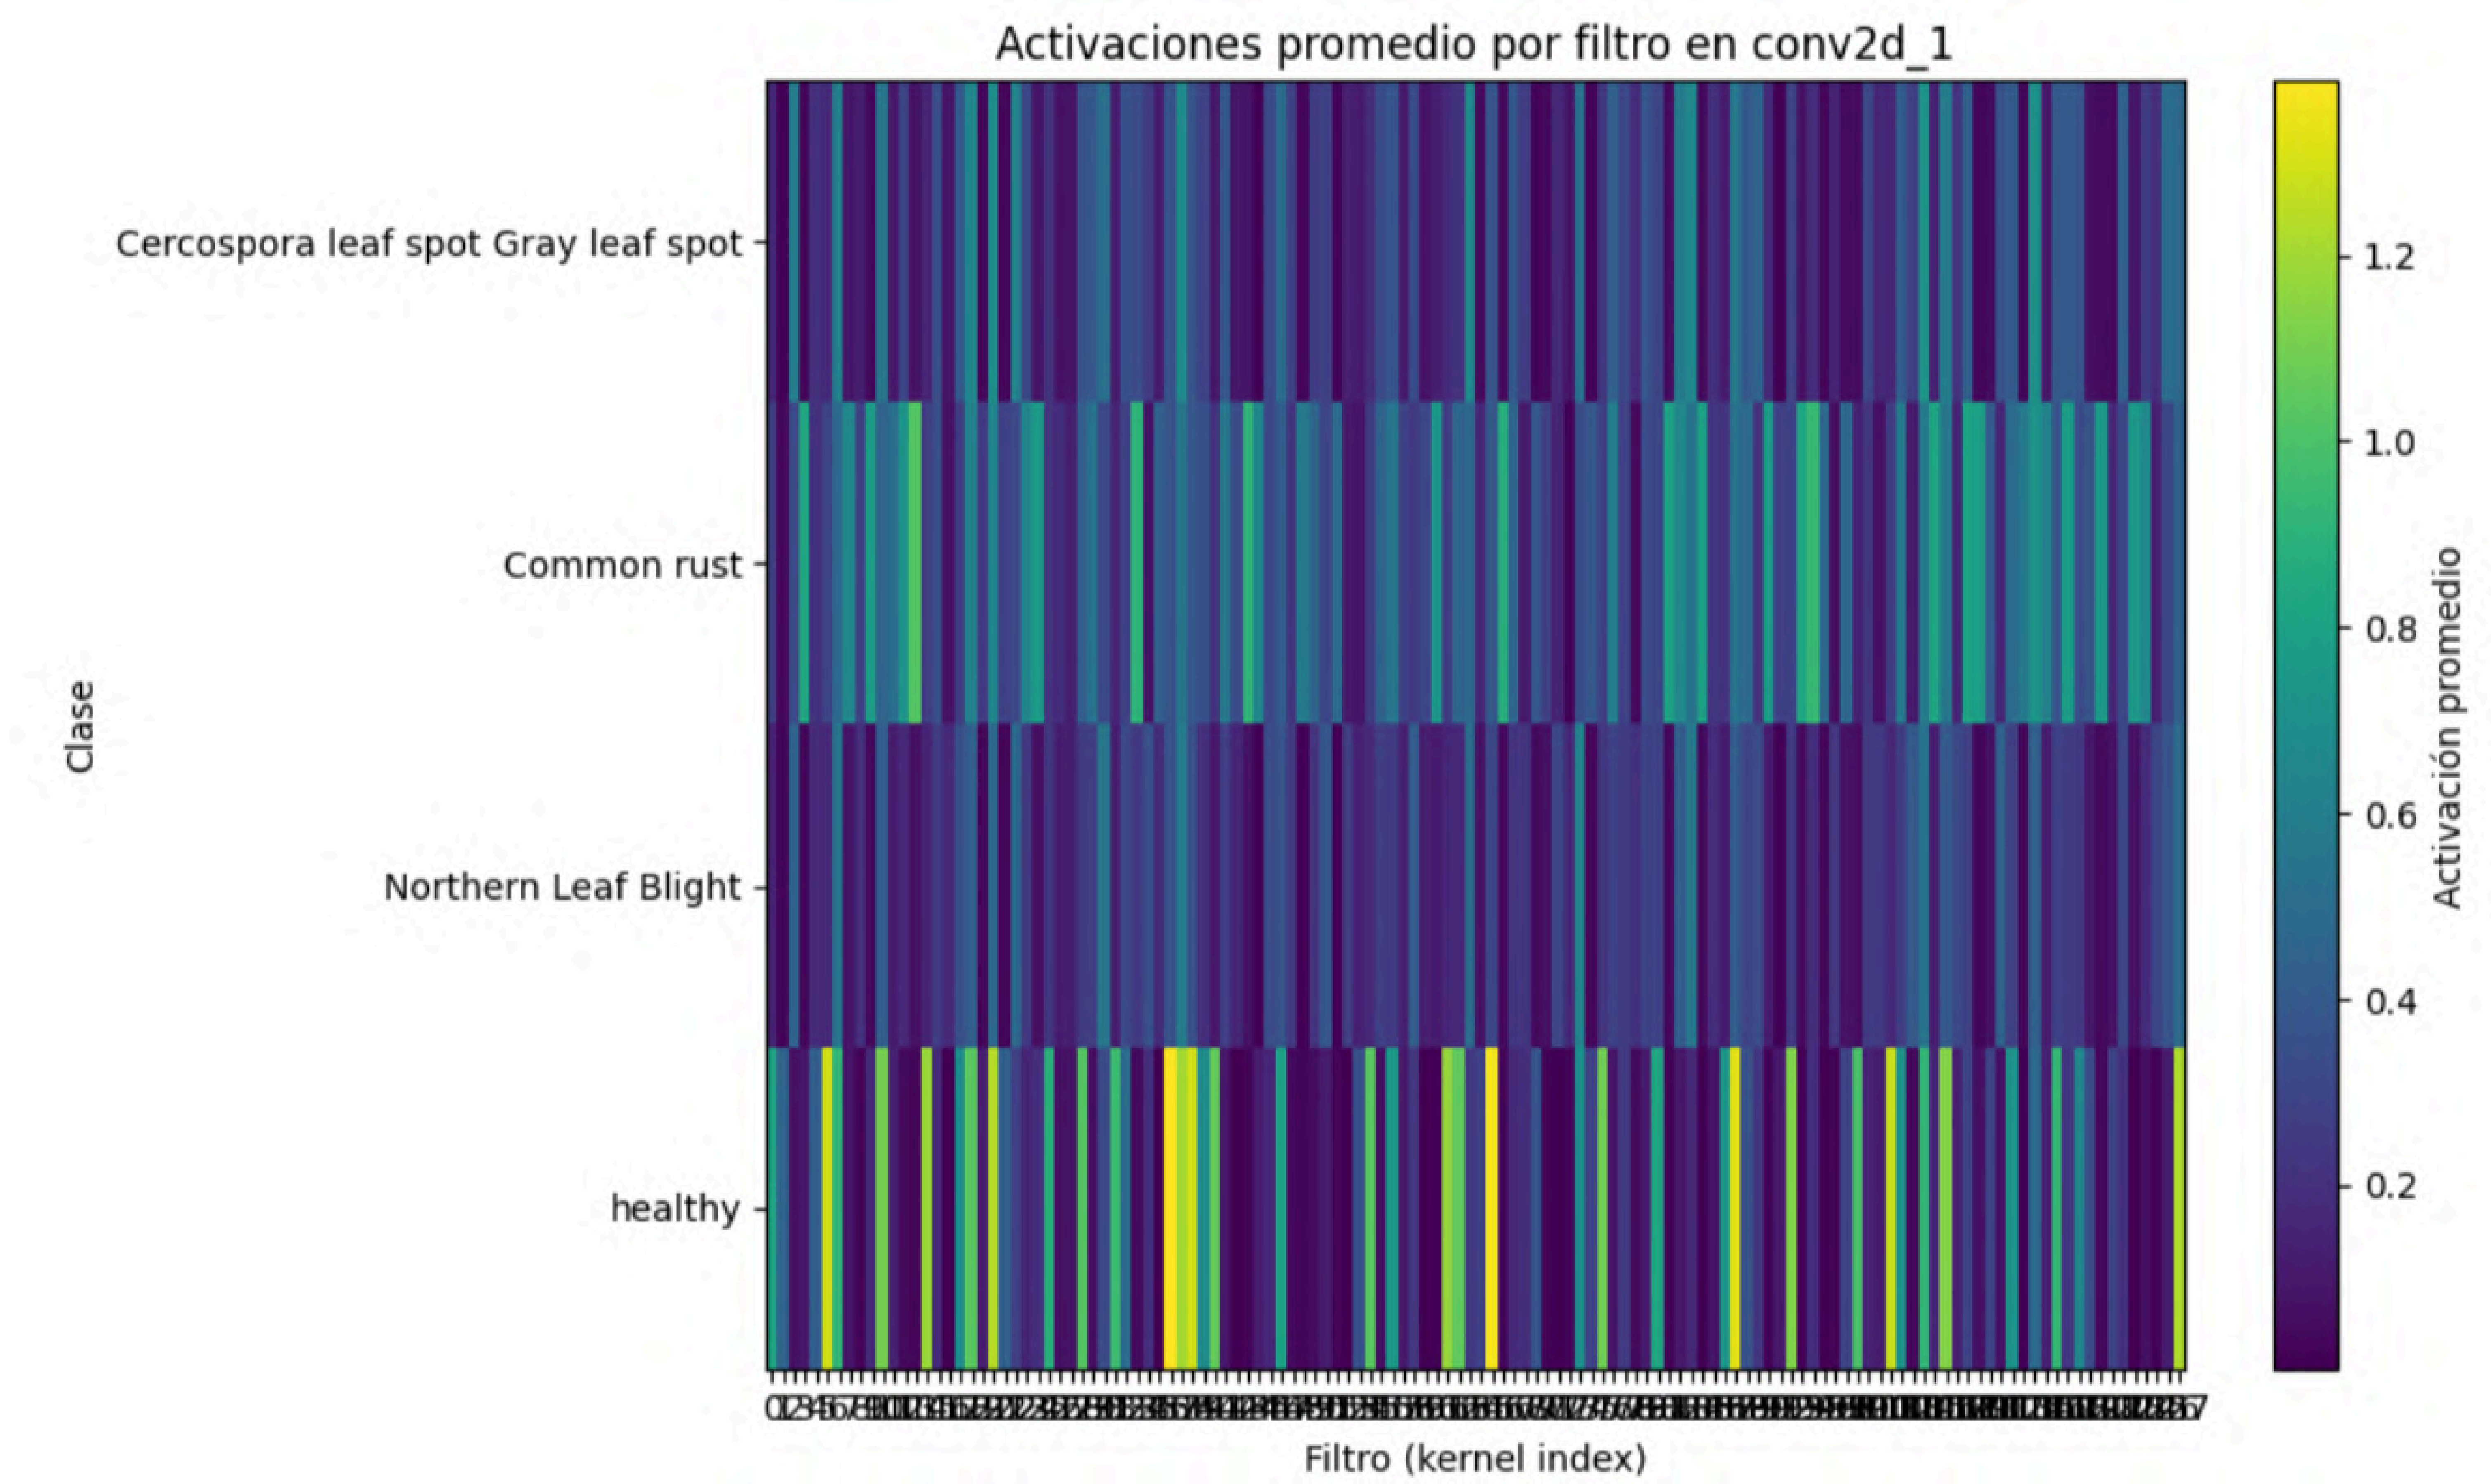

AGROVISION

CNN 2.0

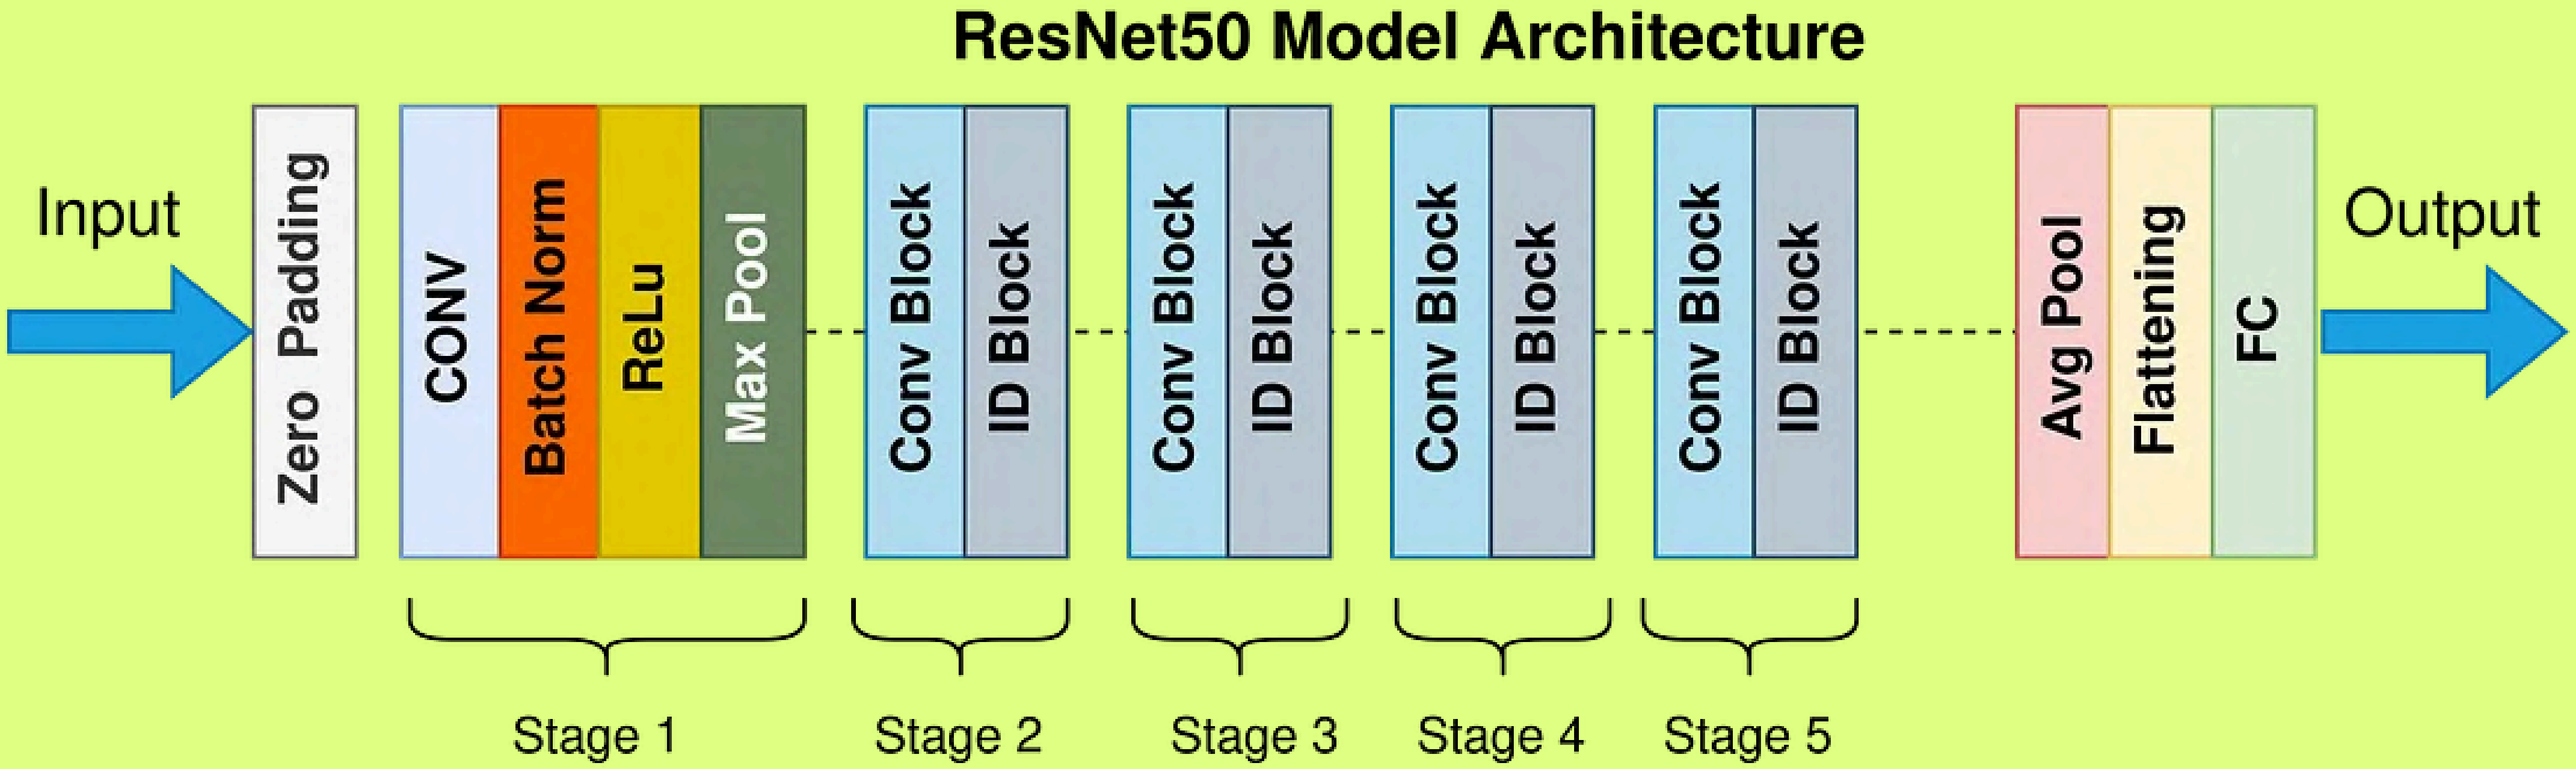

Pretrained on the ImageNet dataset

Se entrenan 140 capas de 175

- AdamW, LR = 2e-4, EarlyStopping, ReduceLROnPlateau

AGROVISION

CNN 2.0

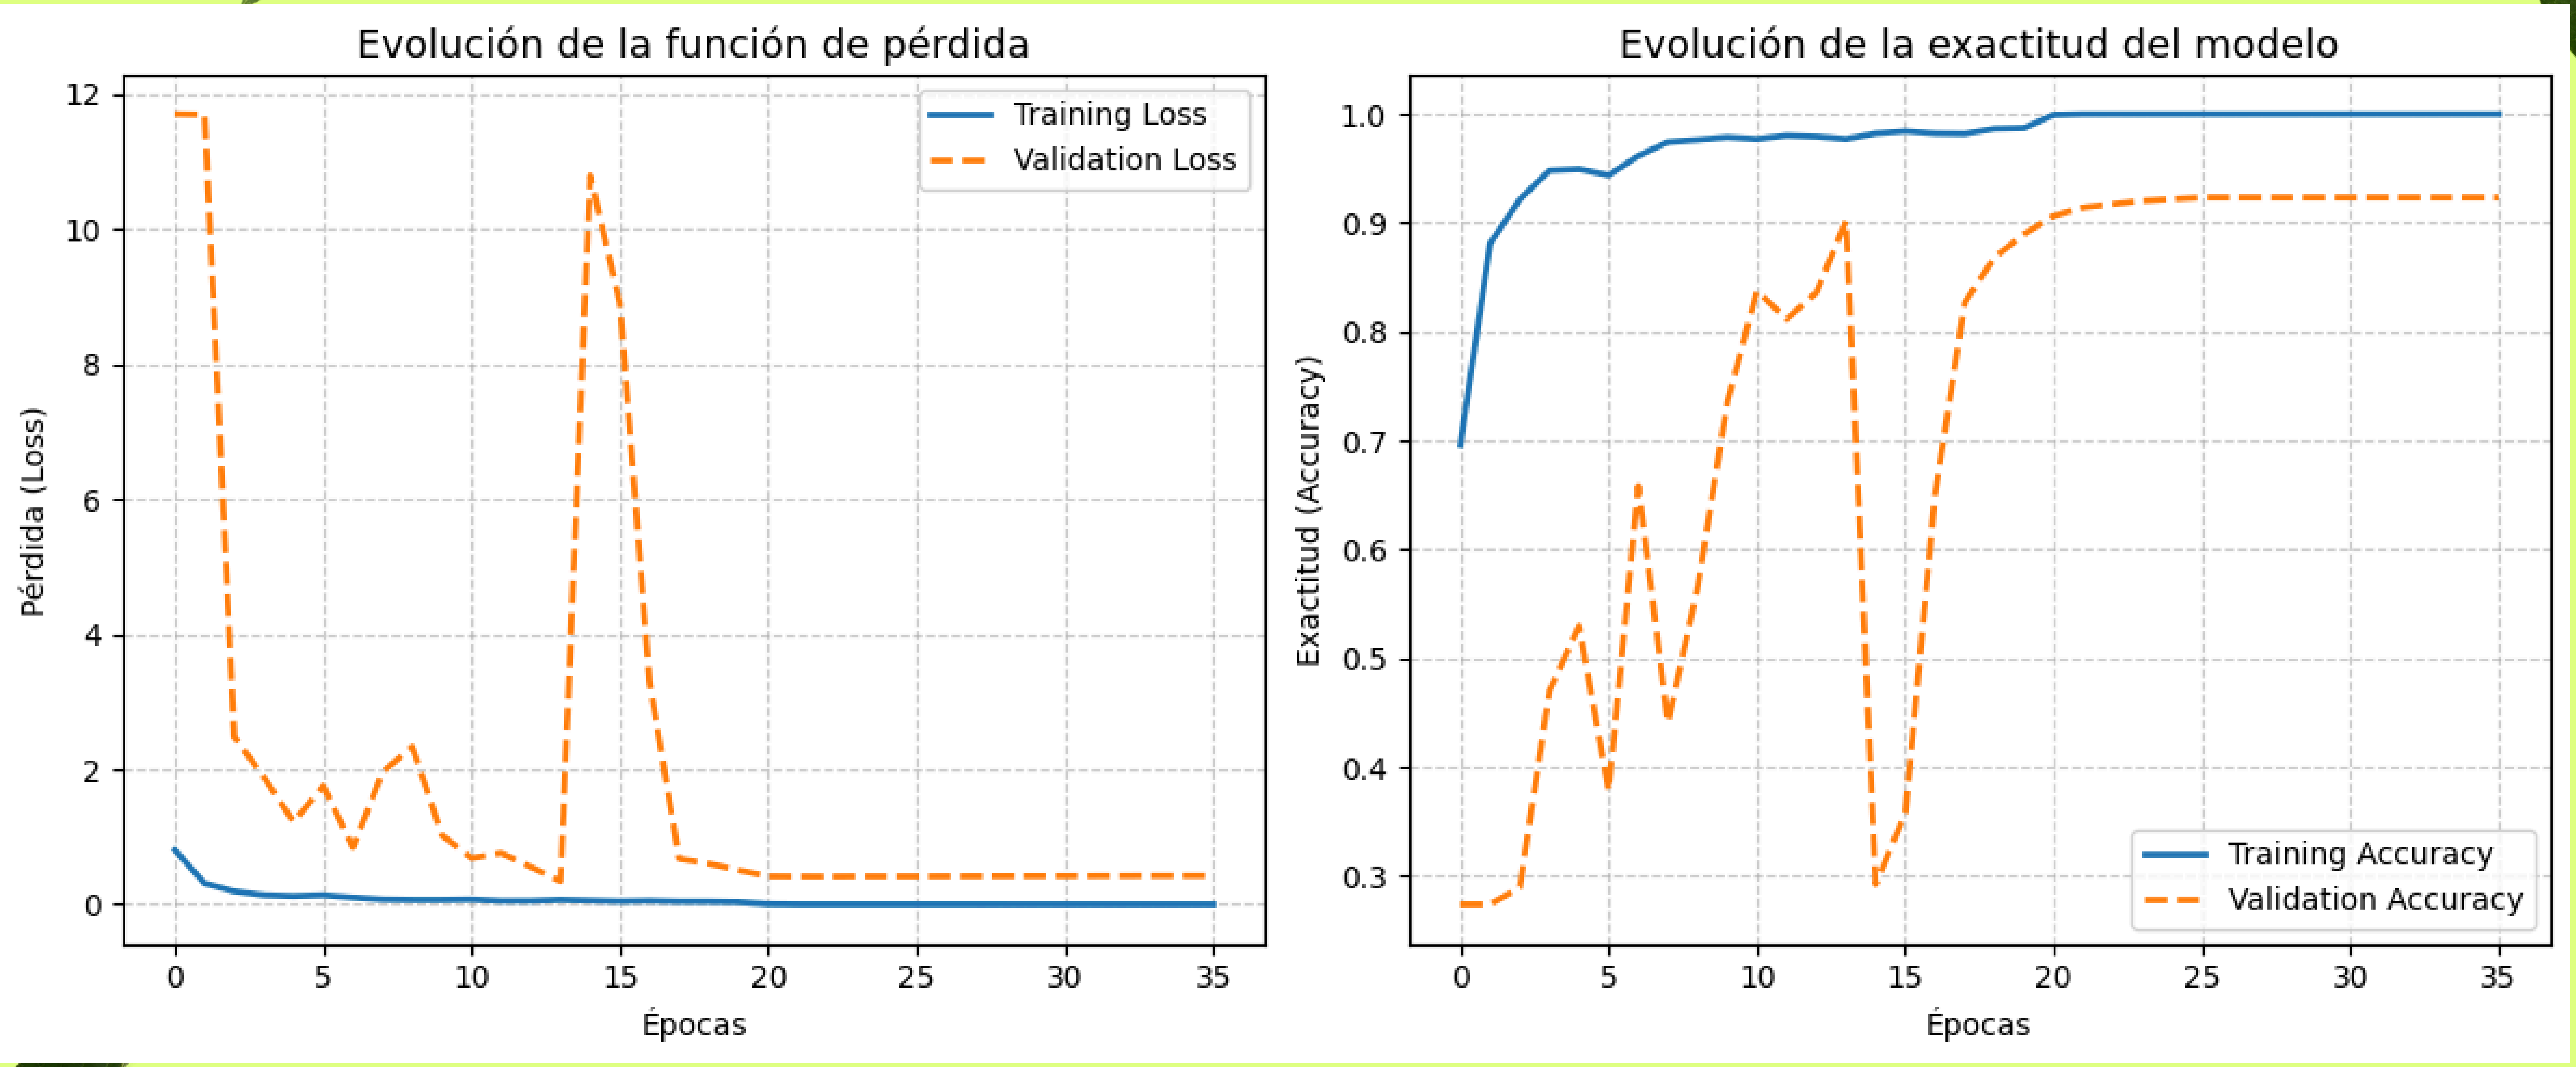

AGROVISION

CNN 2.0

Accuracy

0.94

Macro AUC (OvR)

0.99

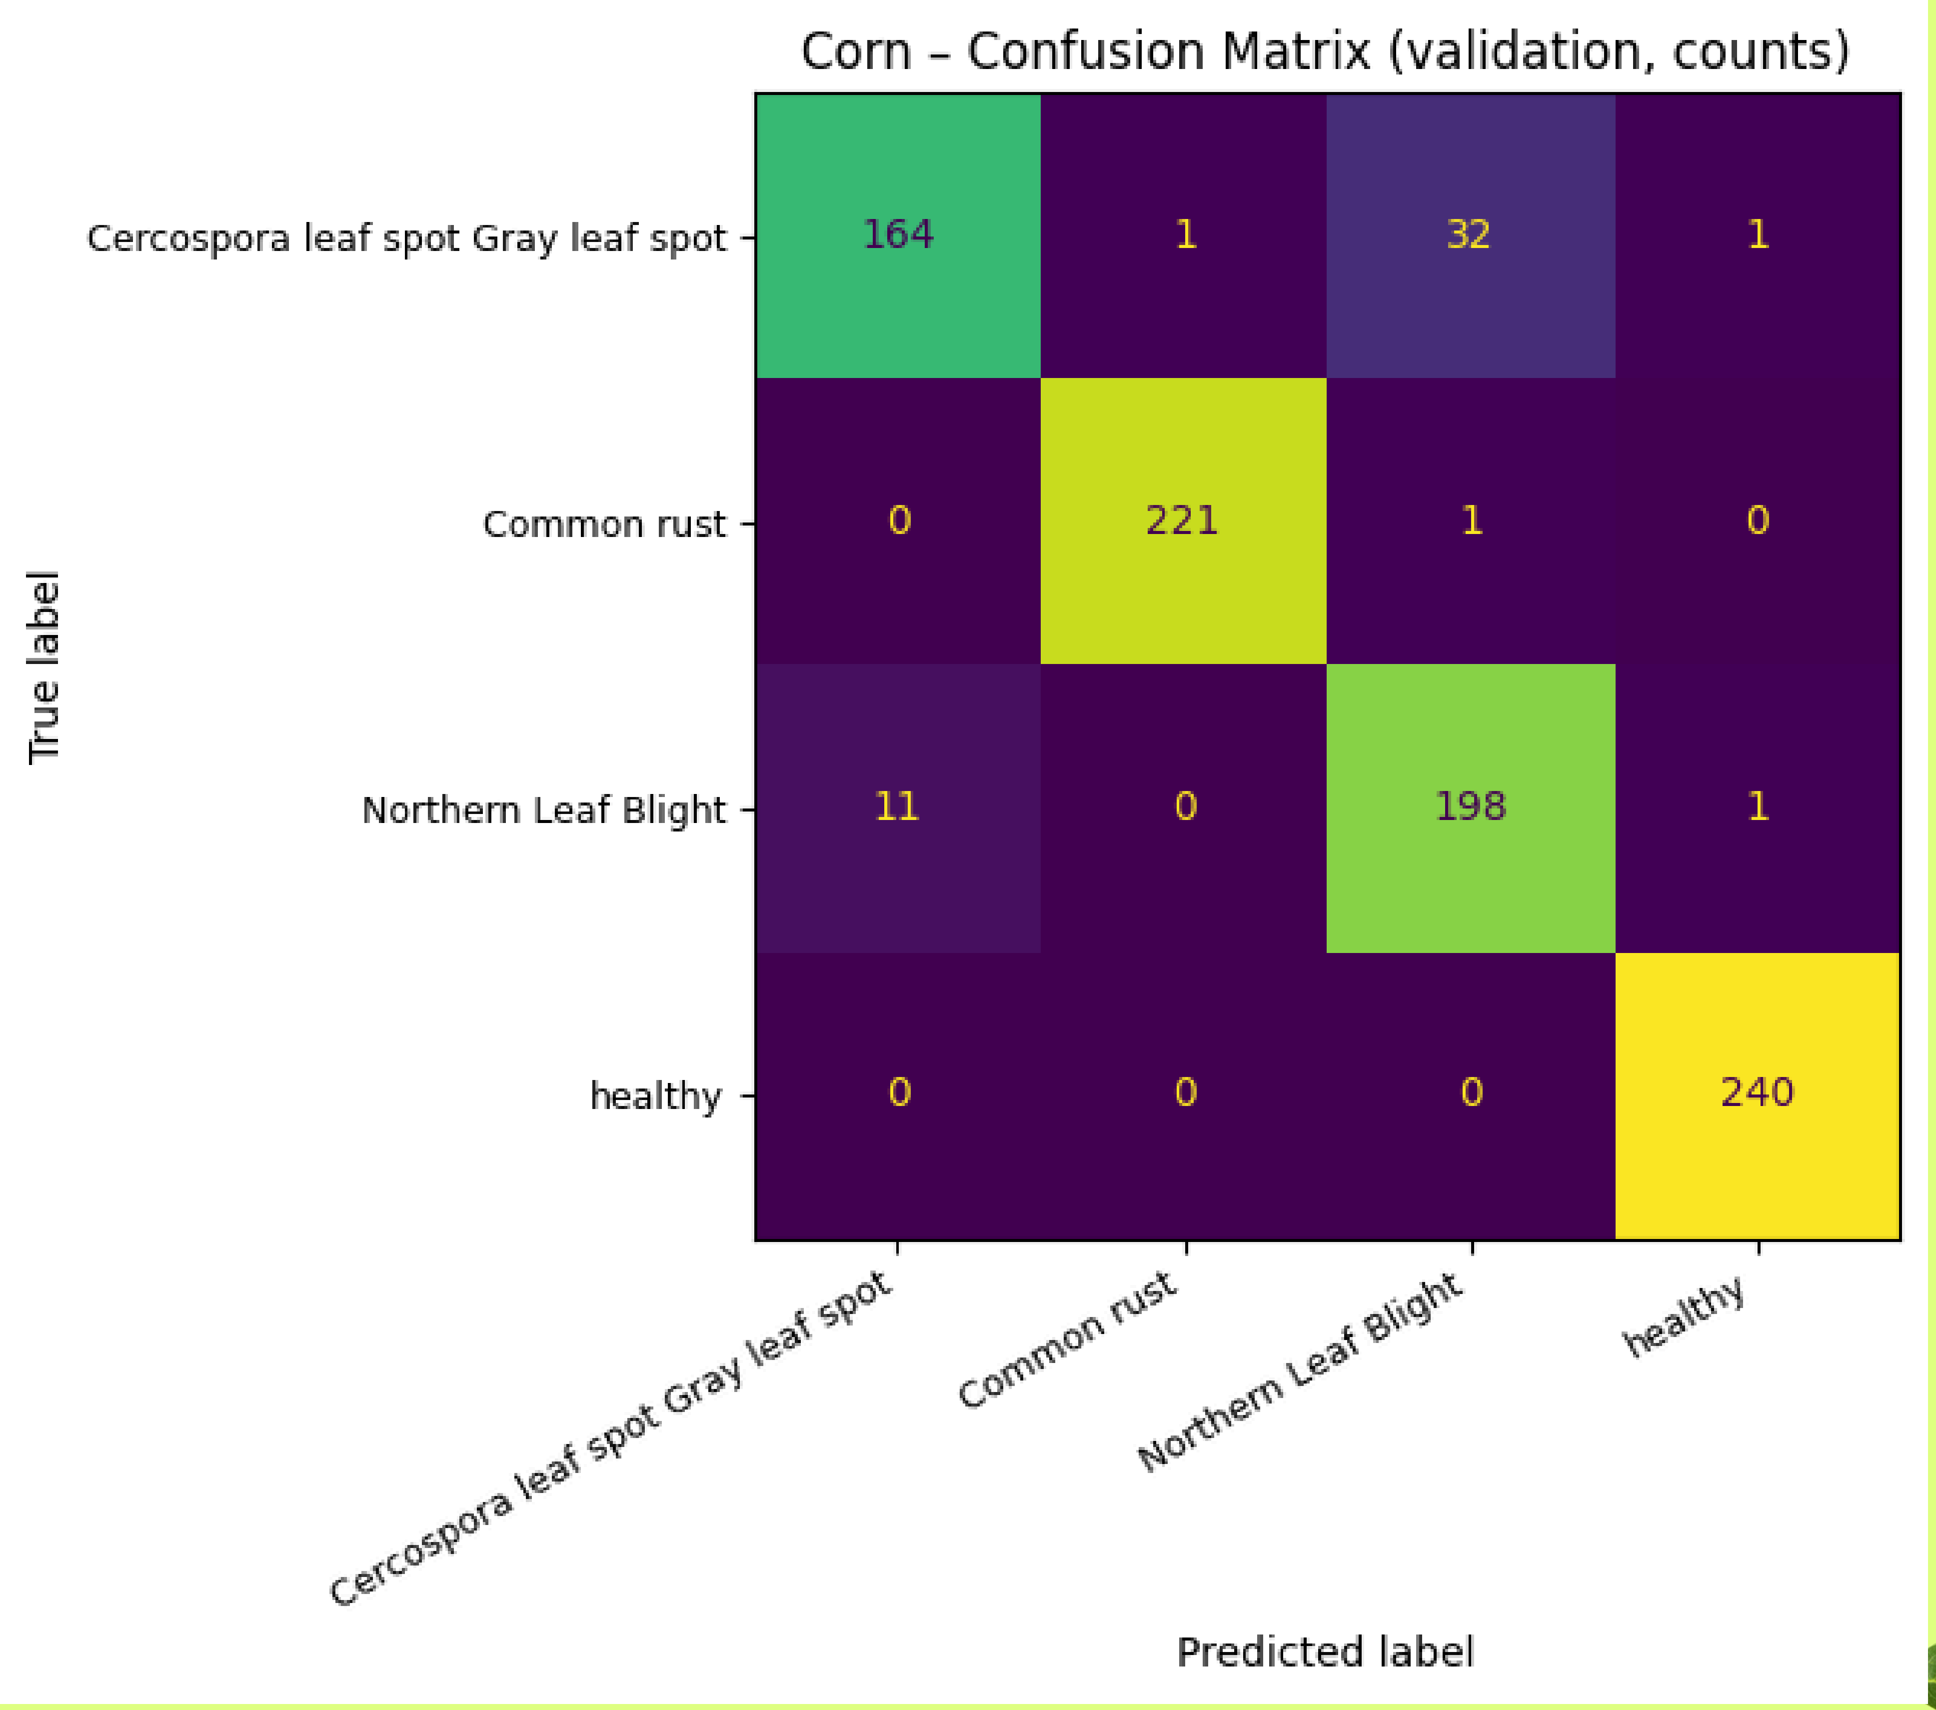

AGROVISION

CNN 2.0

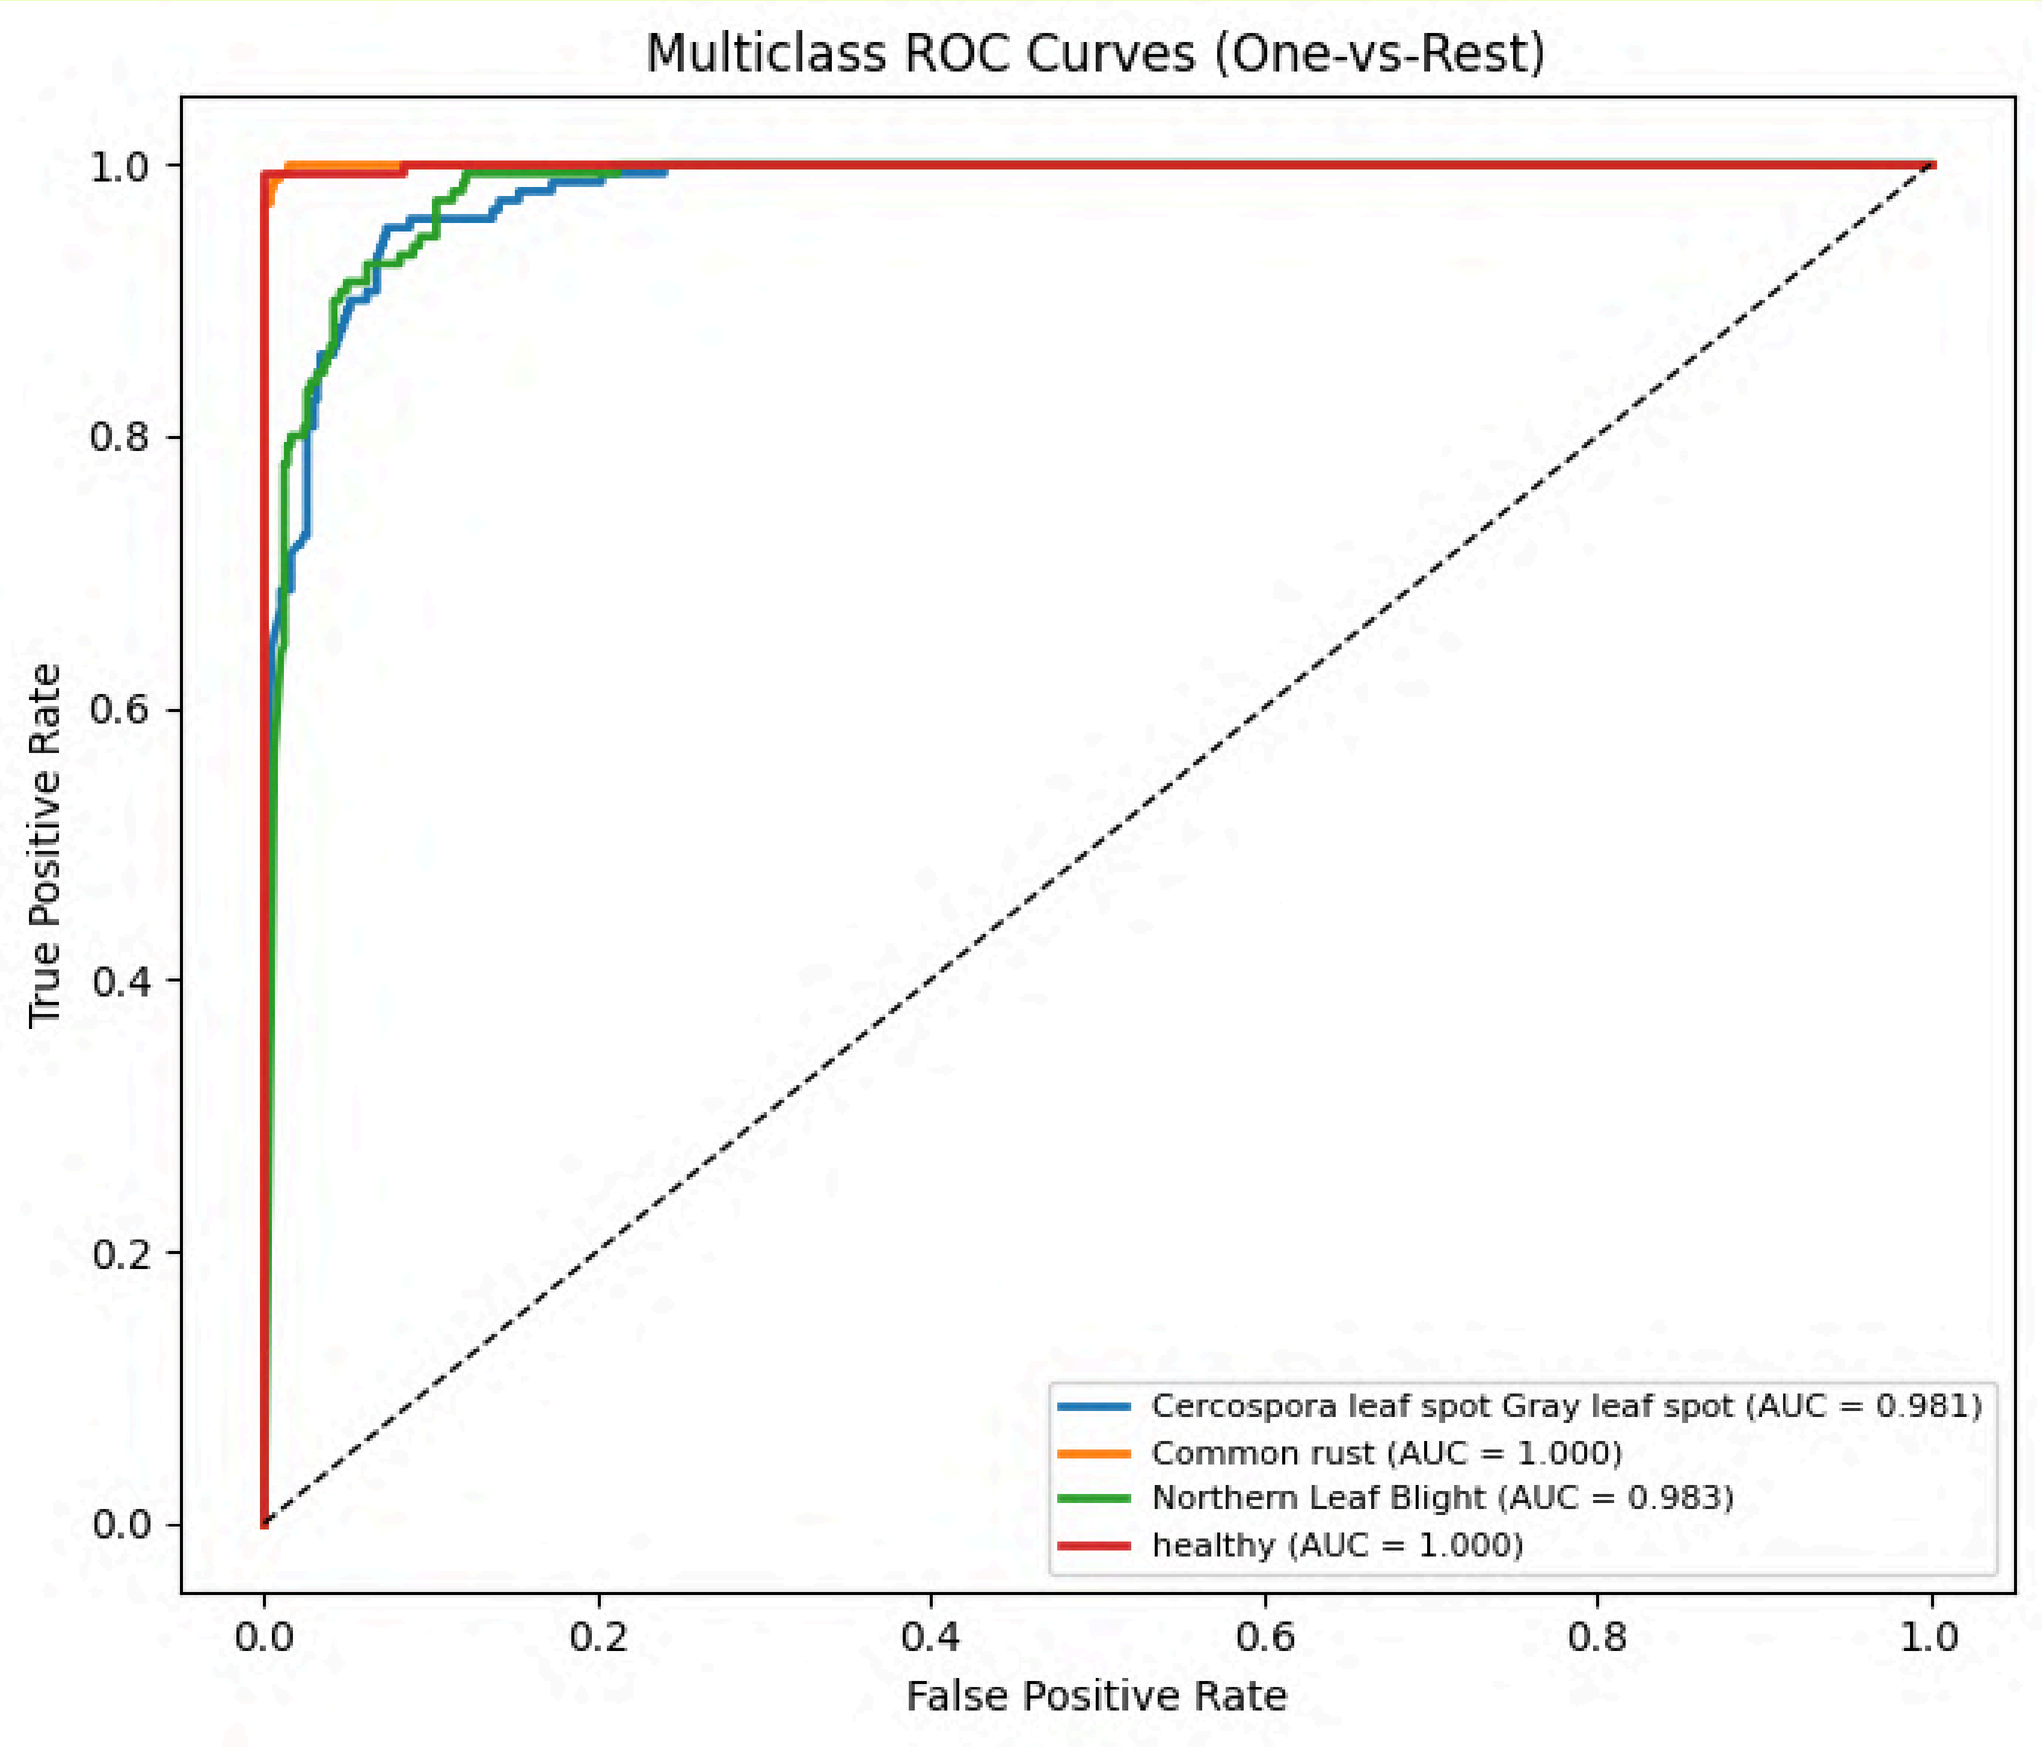

AGROVISION

MÉTRICAS USADAS

LOSS (Sparse Categ Cross)

$$J = -\frac{1}{N}\sum_{n=1}^{N}\log(\hat{y}_{n},\, y_{n})$$

PRECISION

$$\text{Precision} = \frac{TP}{TP + FP}$$

ACCURACY

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

AUC

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR})\, d(\text{FPR})$$

AGROVISION

NUESTRAS PROPUESTAS

METRICS MACRO	1. DNN	2. CNN 1.0	2. CNN 2.0
LOSS (Sparse Categ Cross)	0.3791	0.2323	0.2356
PRECISION	84.94%	91.26%	94.54%
ACCURACY	84.57%	91.90%	94.60%
AUC	96.18%	98.30%	99.21%

AGROVISION

AUTOENCODER

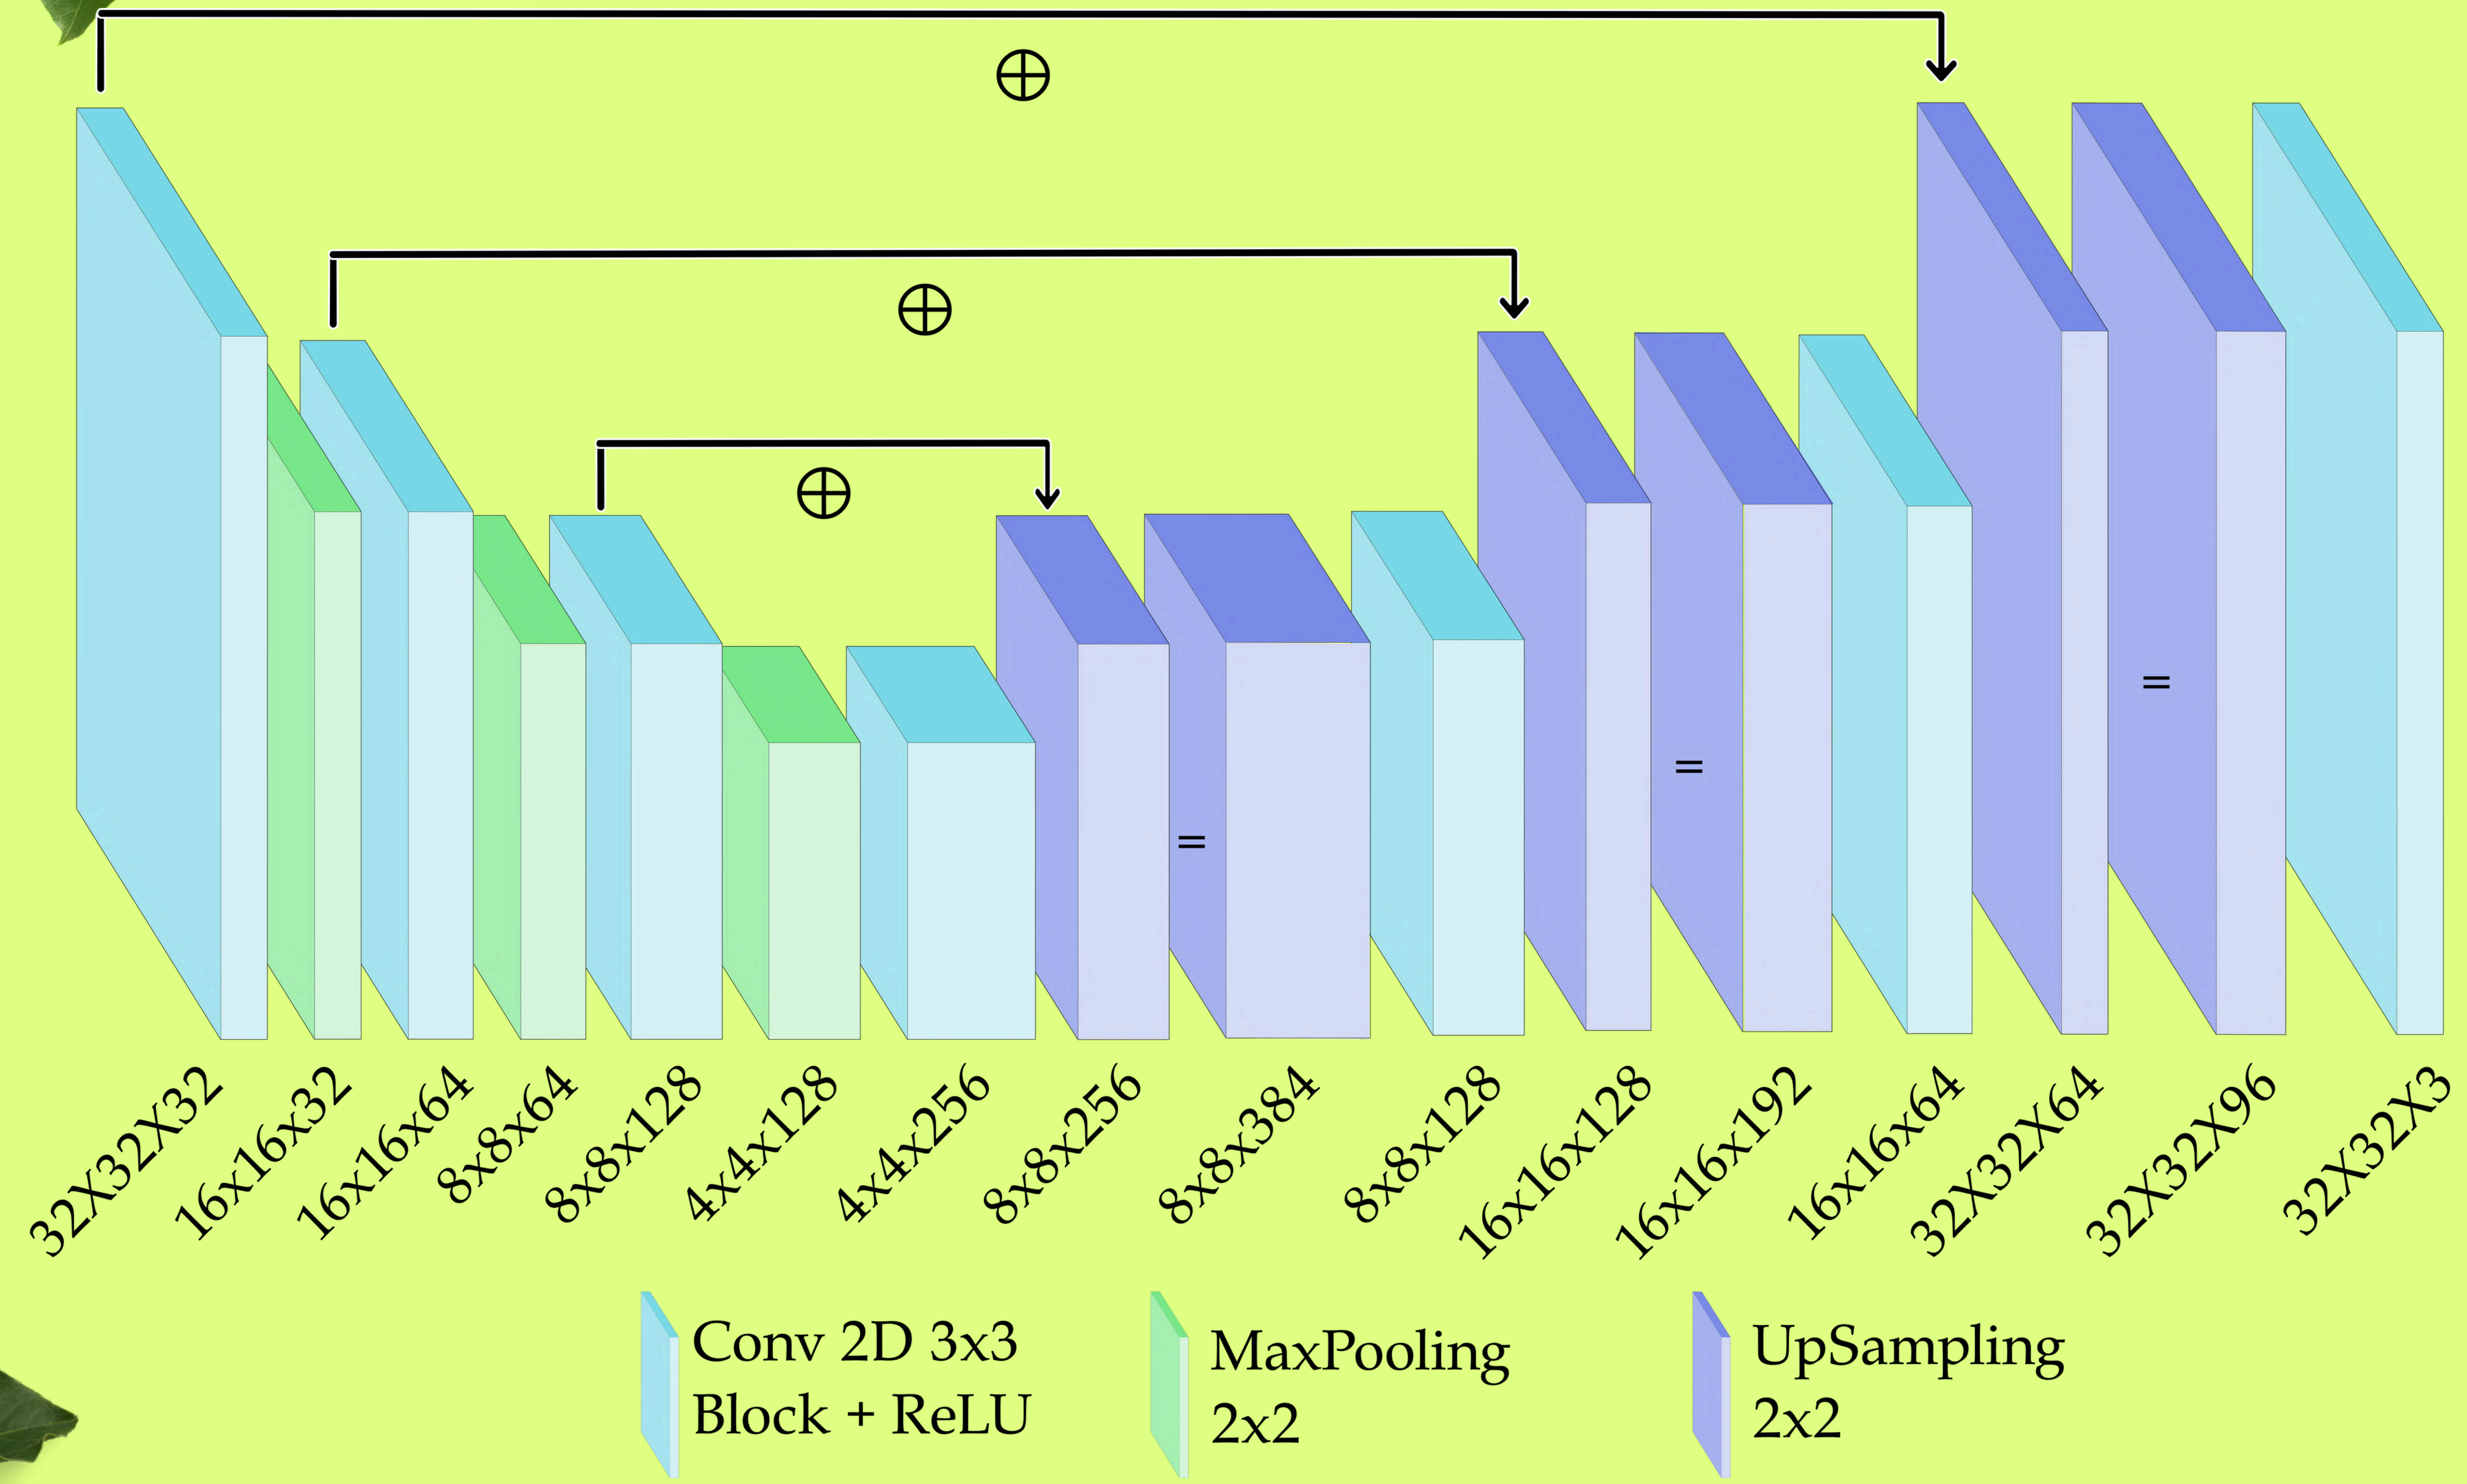

AGROVISION

AUTOENCODER

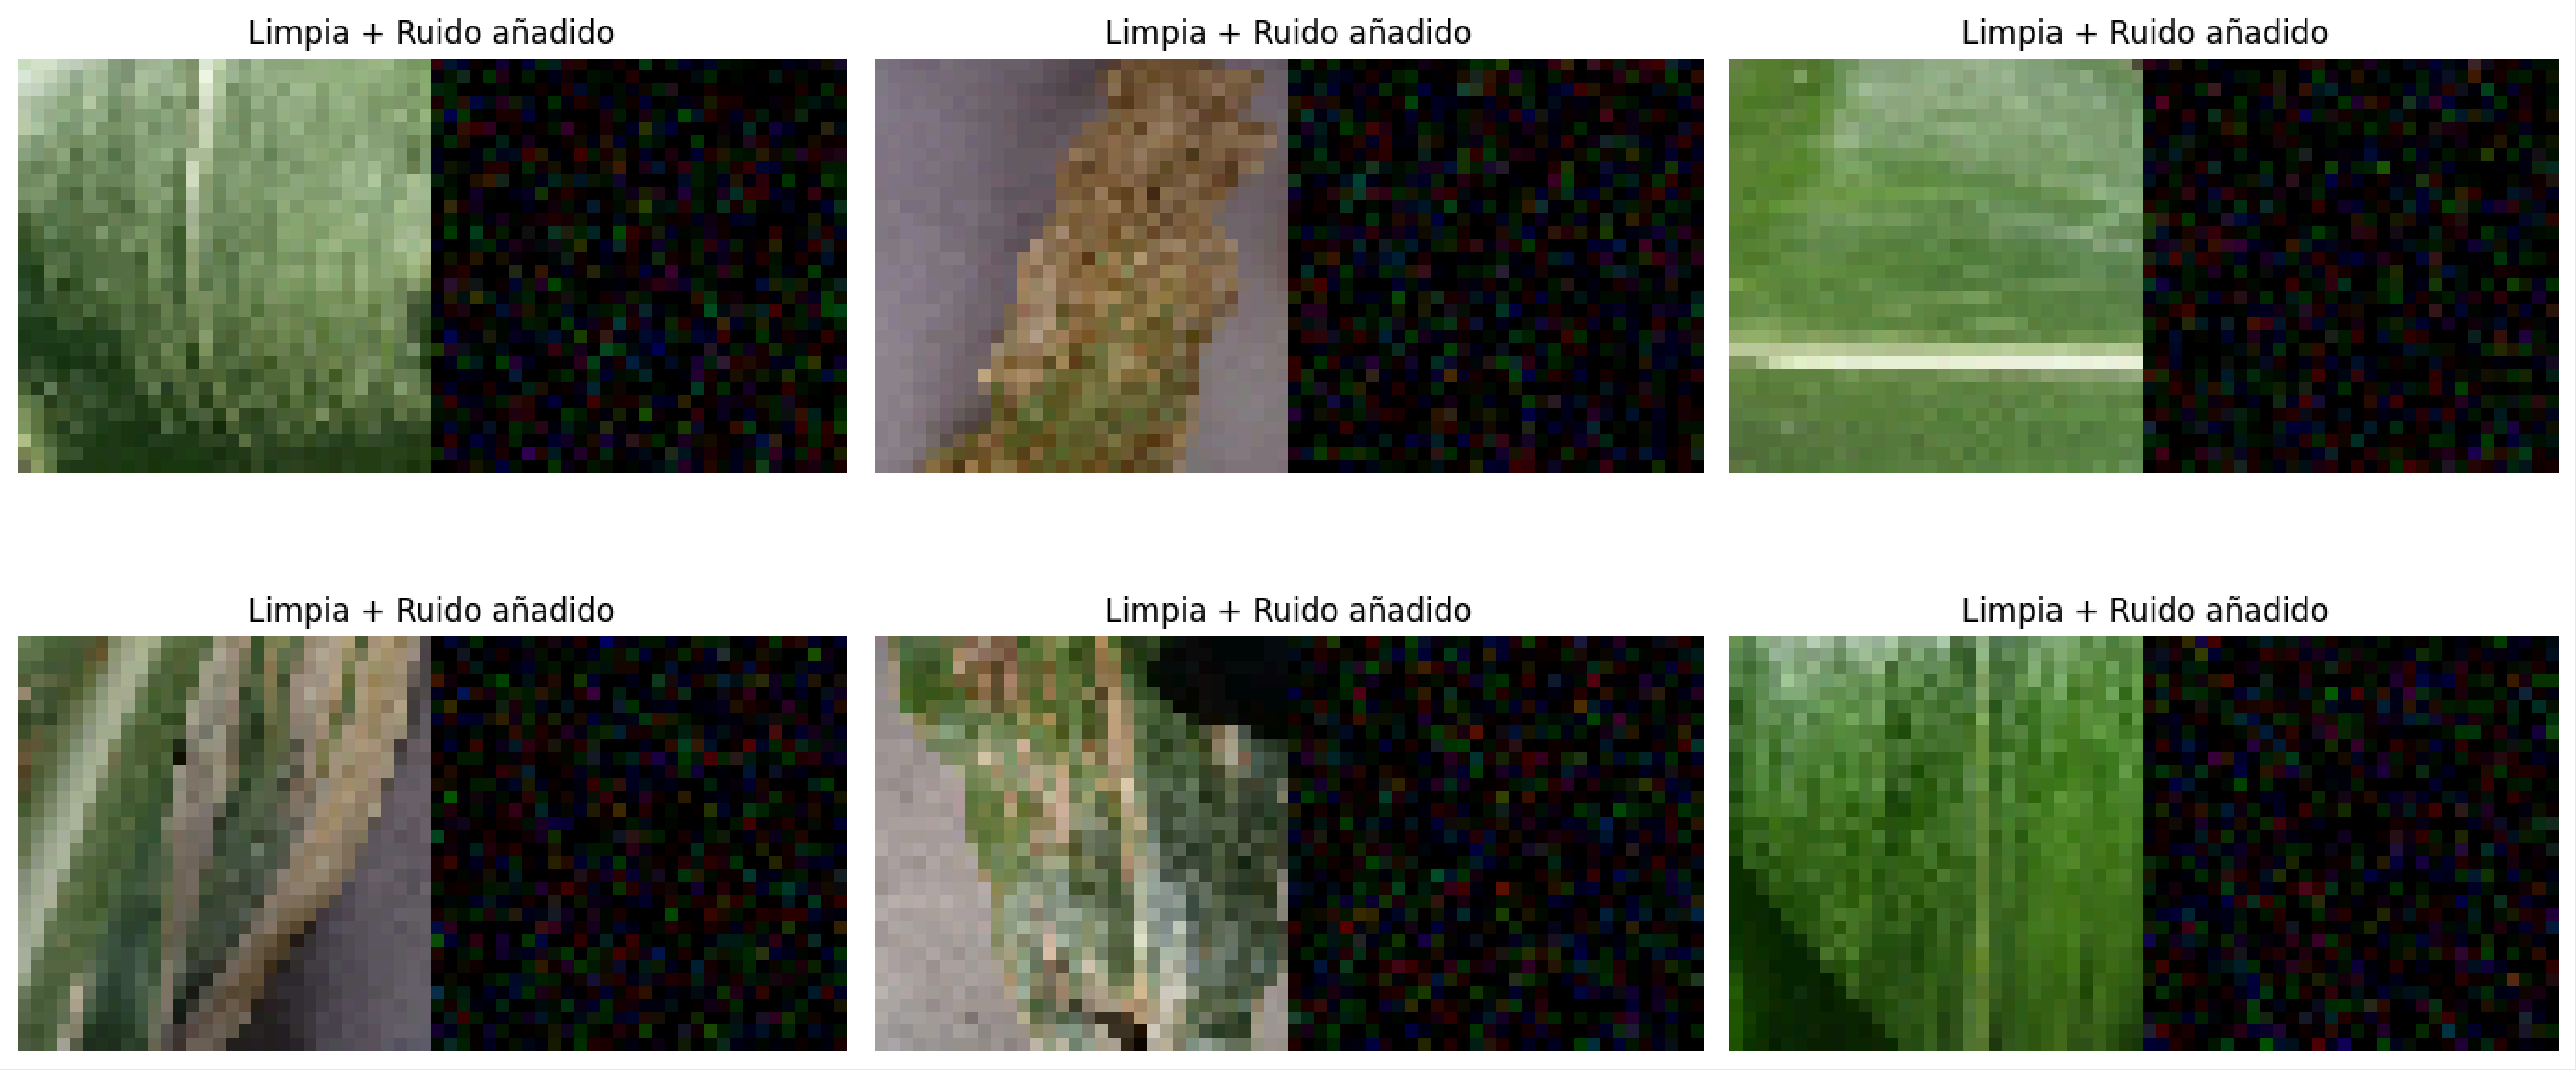

- Se entrenó un denoising autoencoder con un sigma de ruido de 0.1
- Adam, LR = 1e-4, EarlyStopping, Image size = 32x32, train/val split = 0.2

AGROVISION

AUTOENCODER

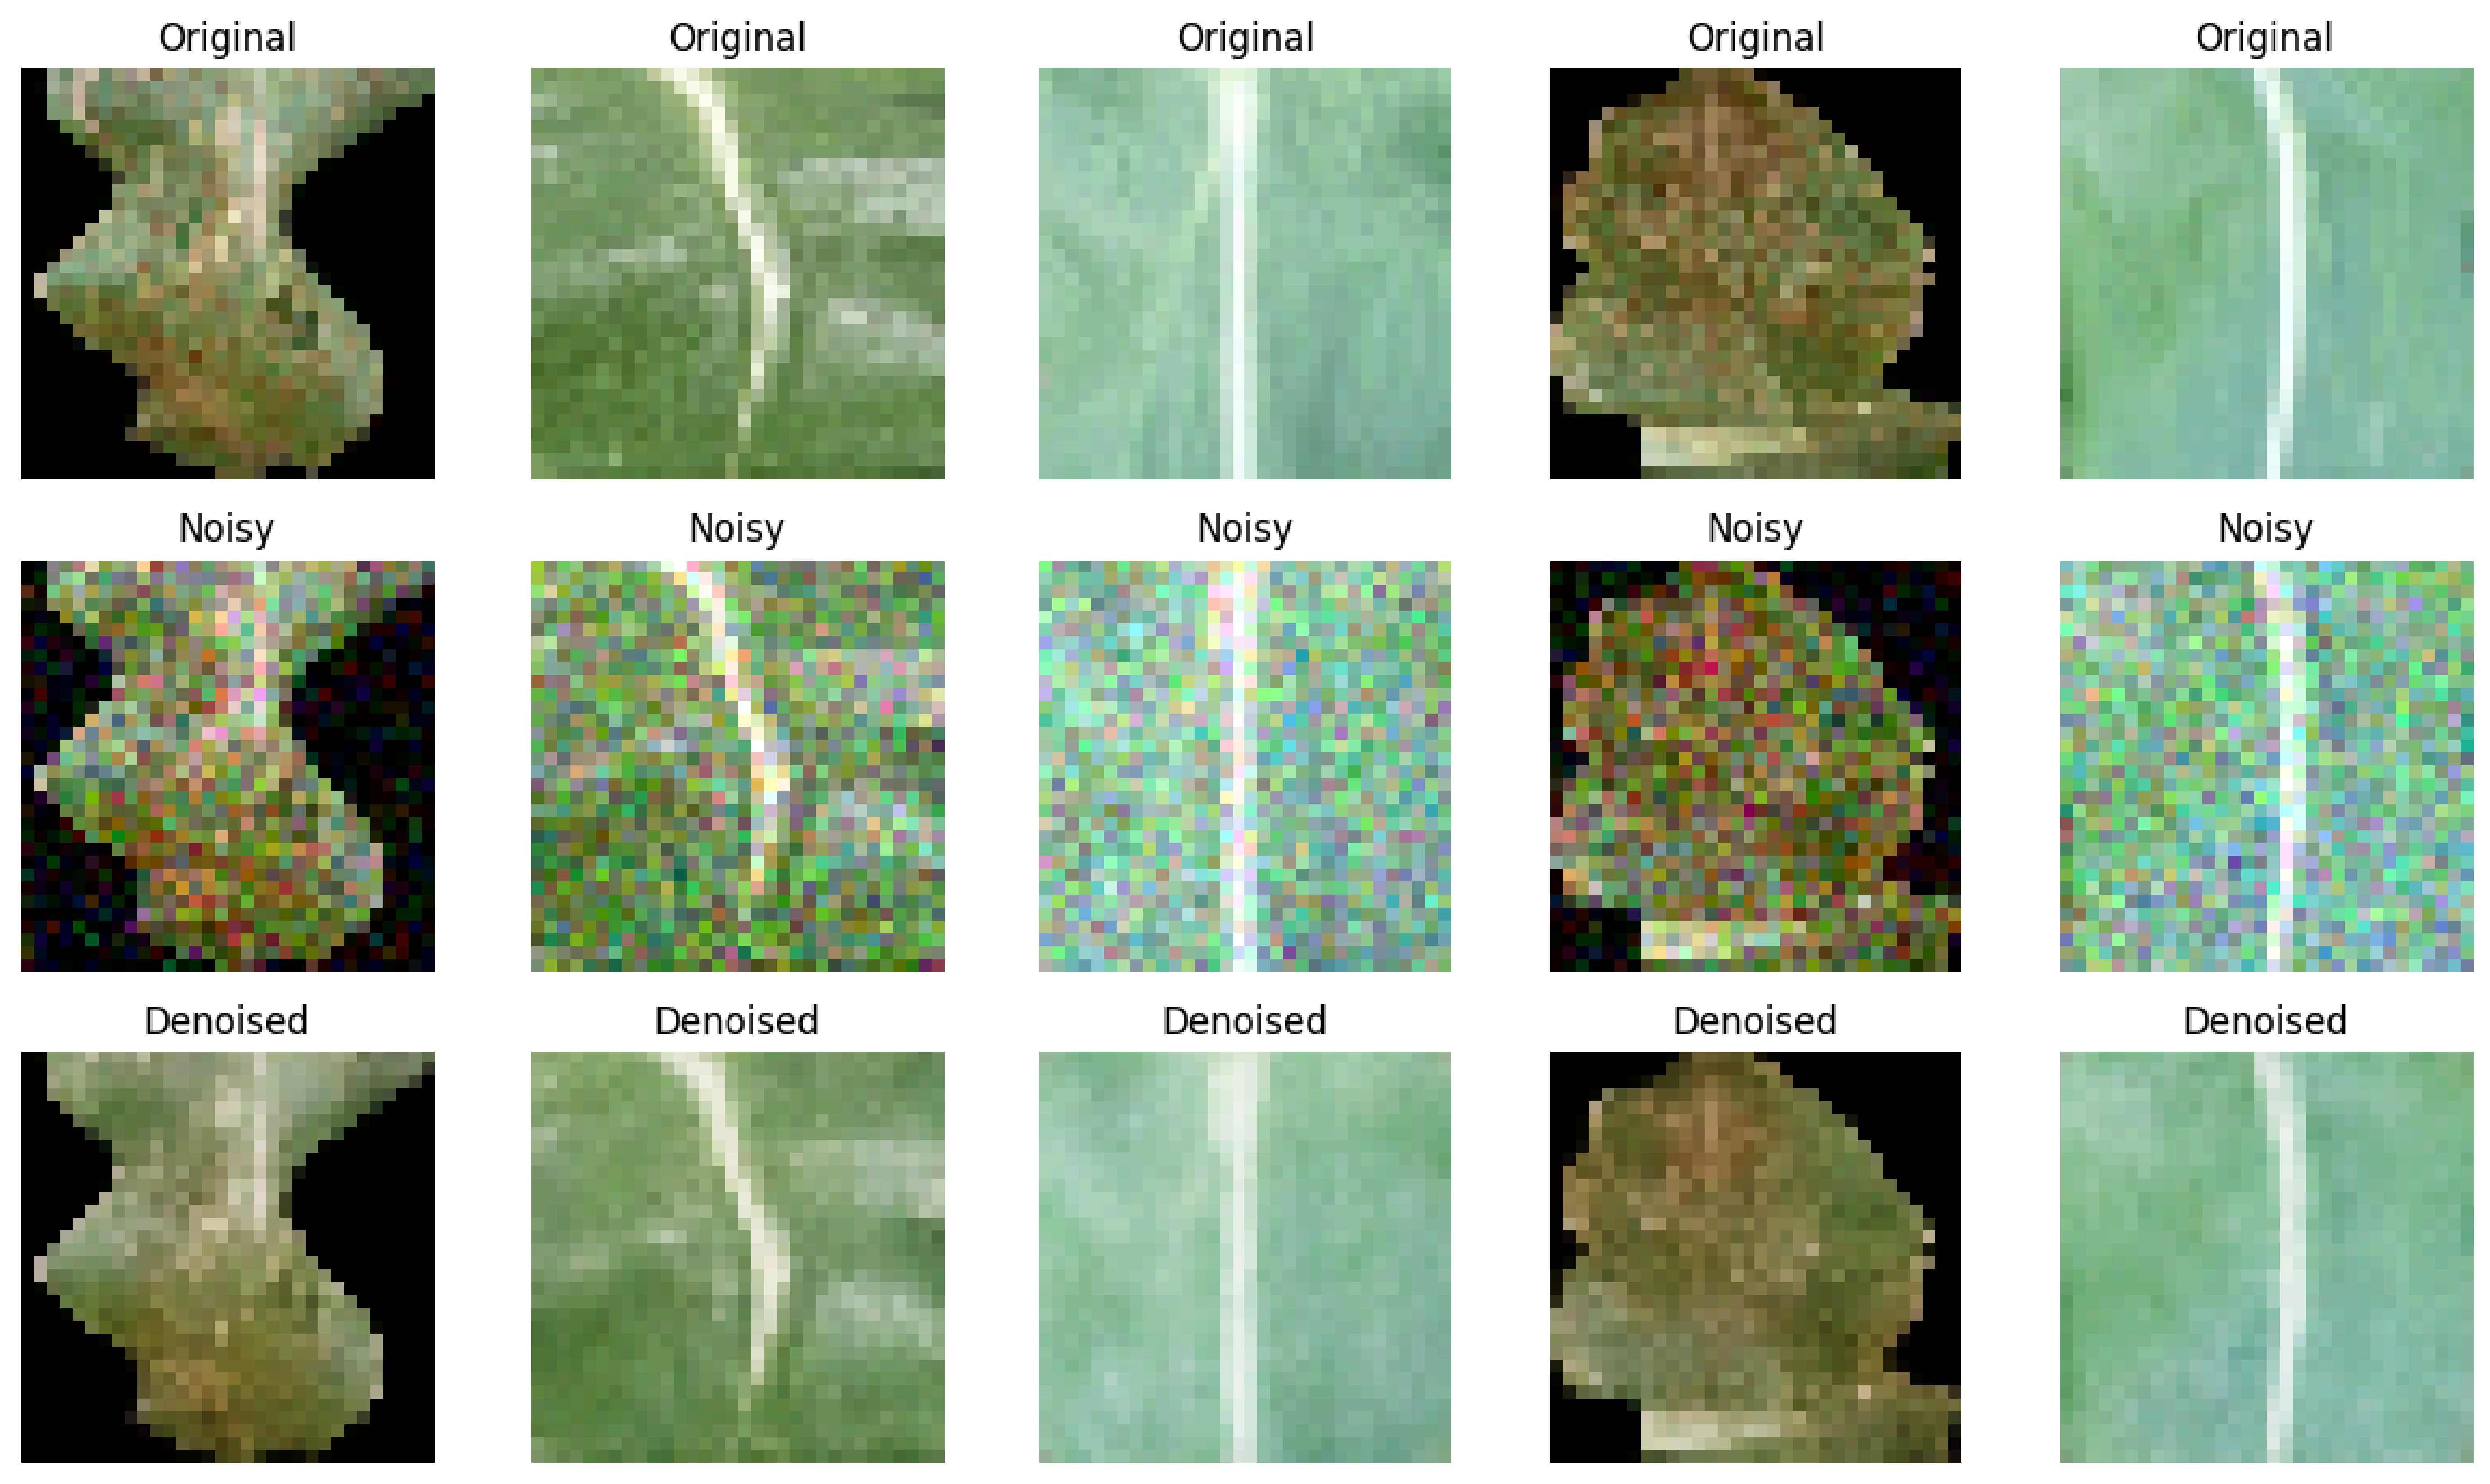

AGROVISION

AUTOENCODER

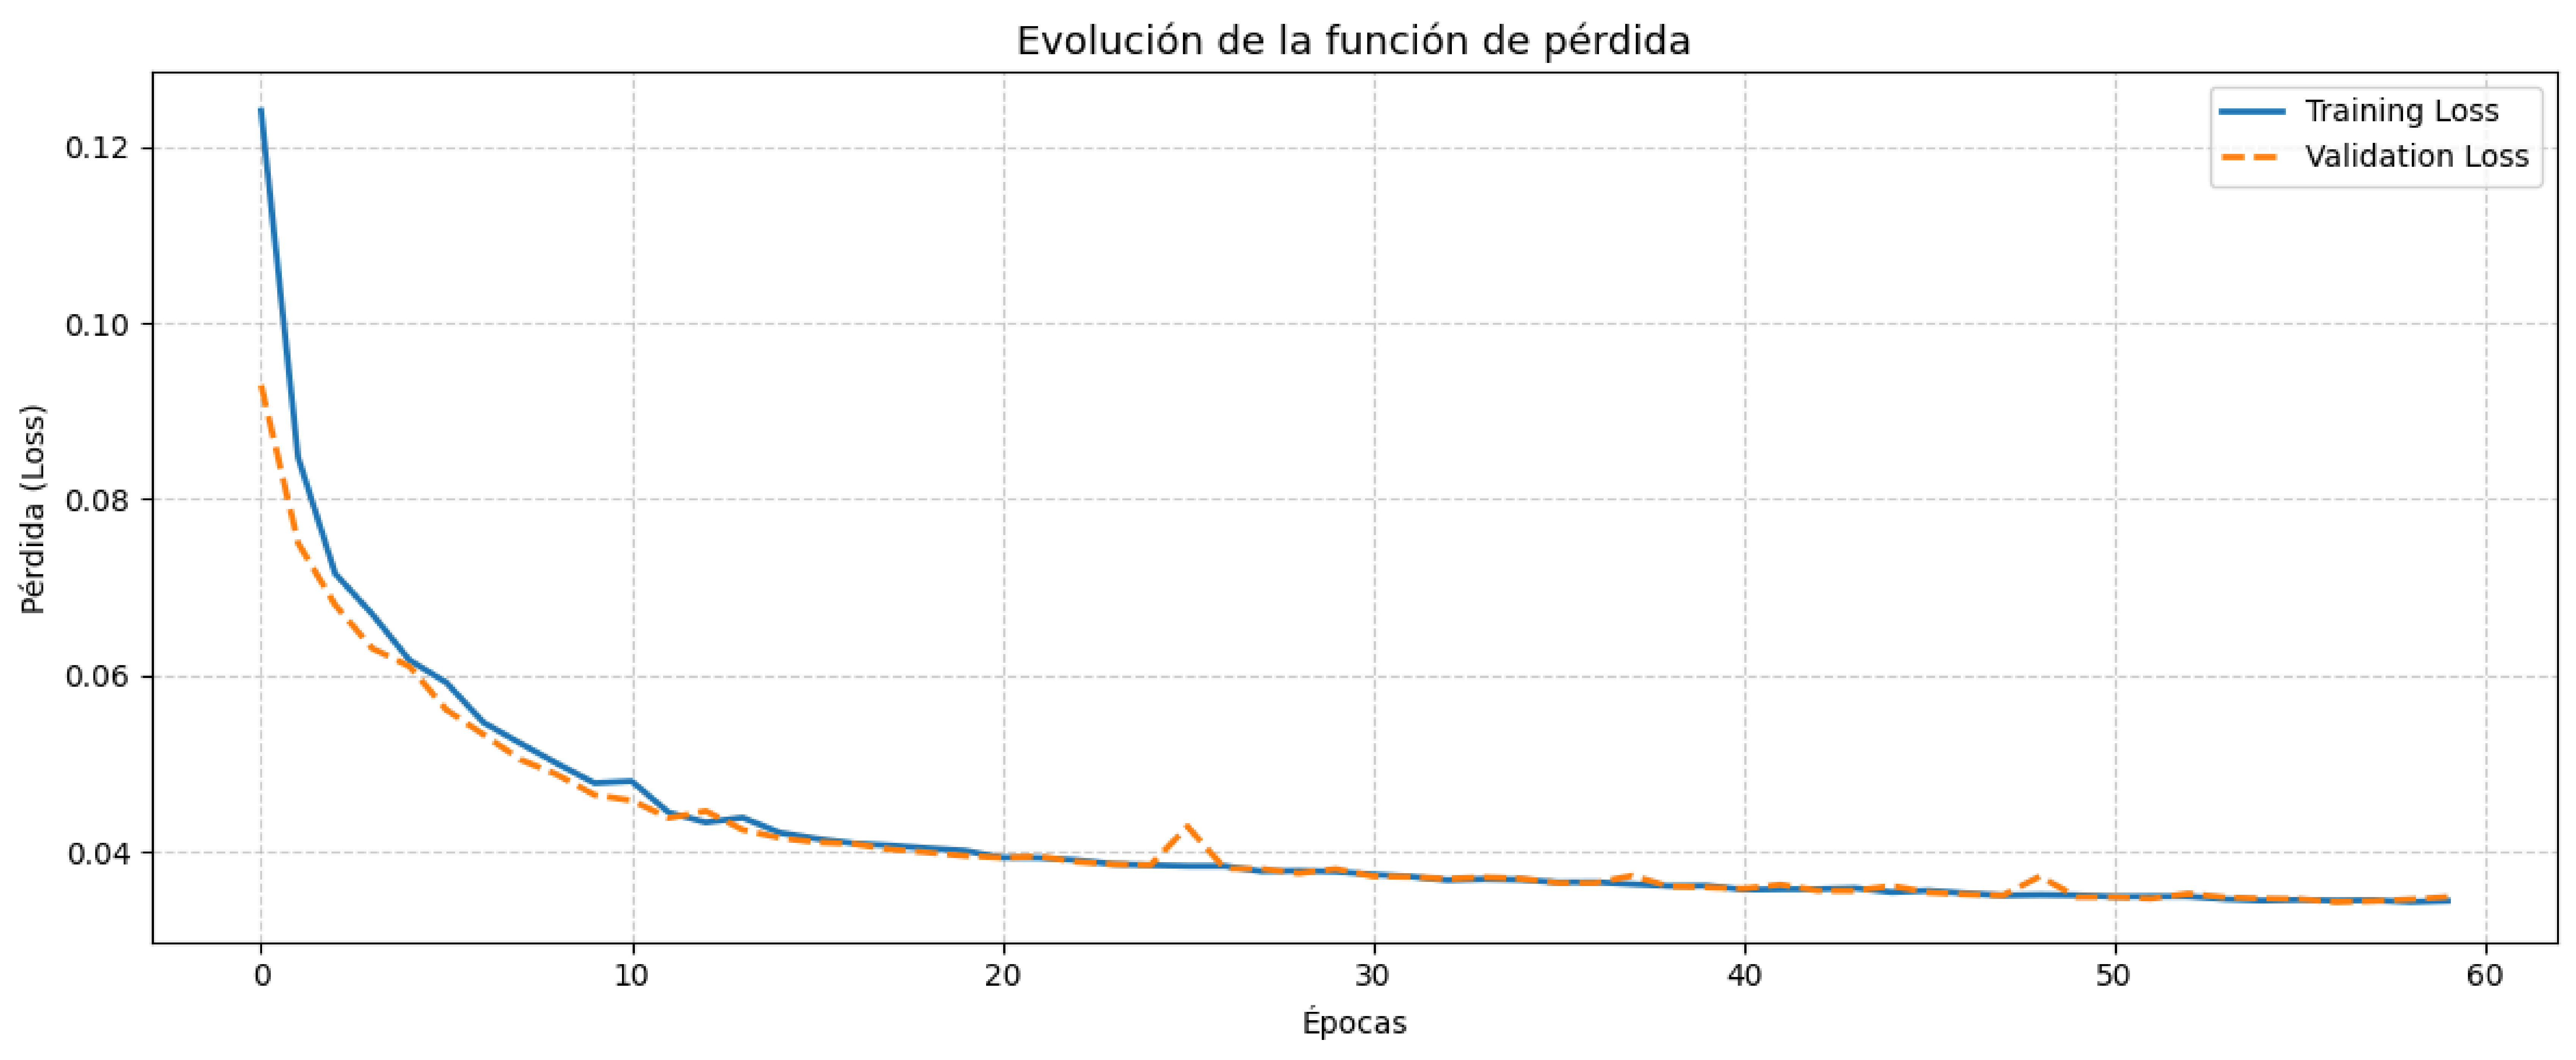

AGROVISION

REEVALUANDO RESNET50

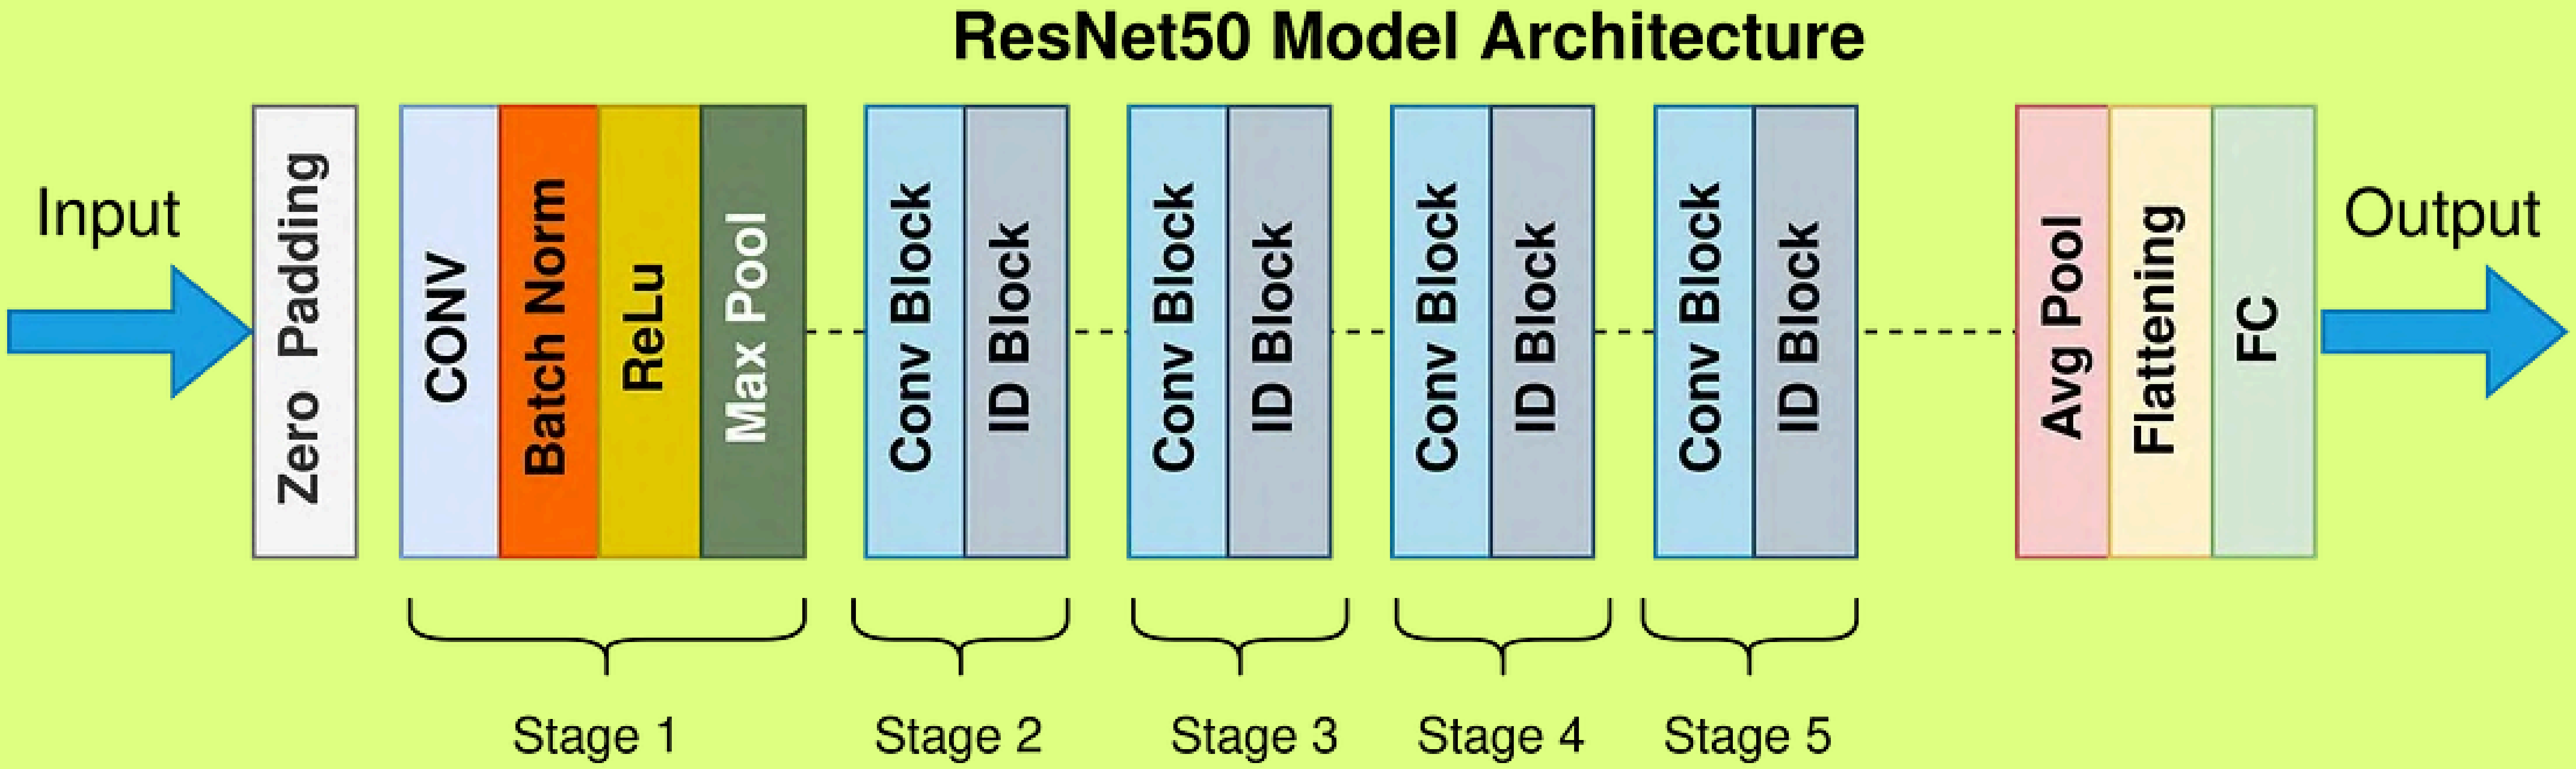

Pretrained on the ImageNet dataset

Se entrenan 140 capas de 175

- AdamW, LR = 2e-4, EarlyStopping, ReduceLROnPlateau

AGROVISION

REEVALUANDO RESNET50

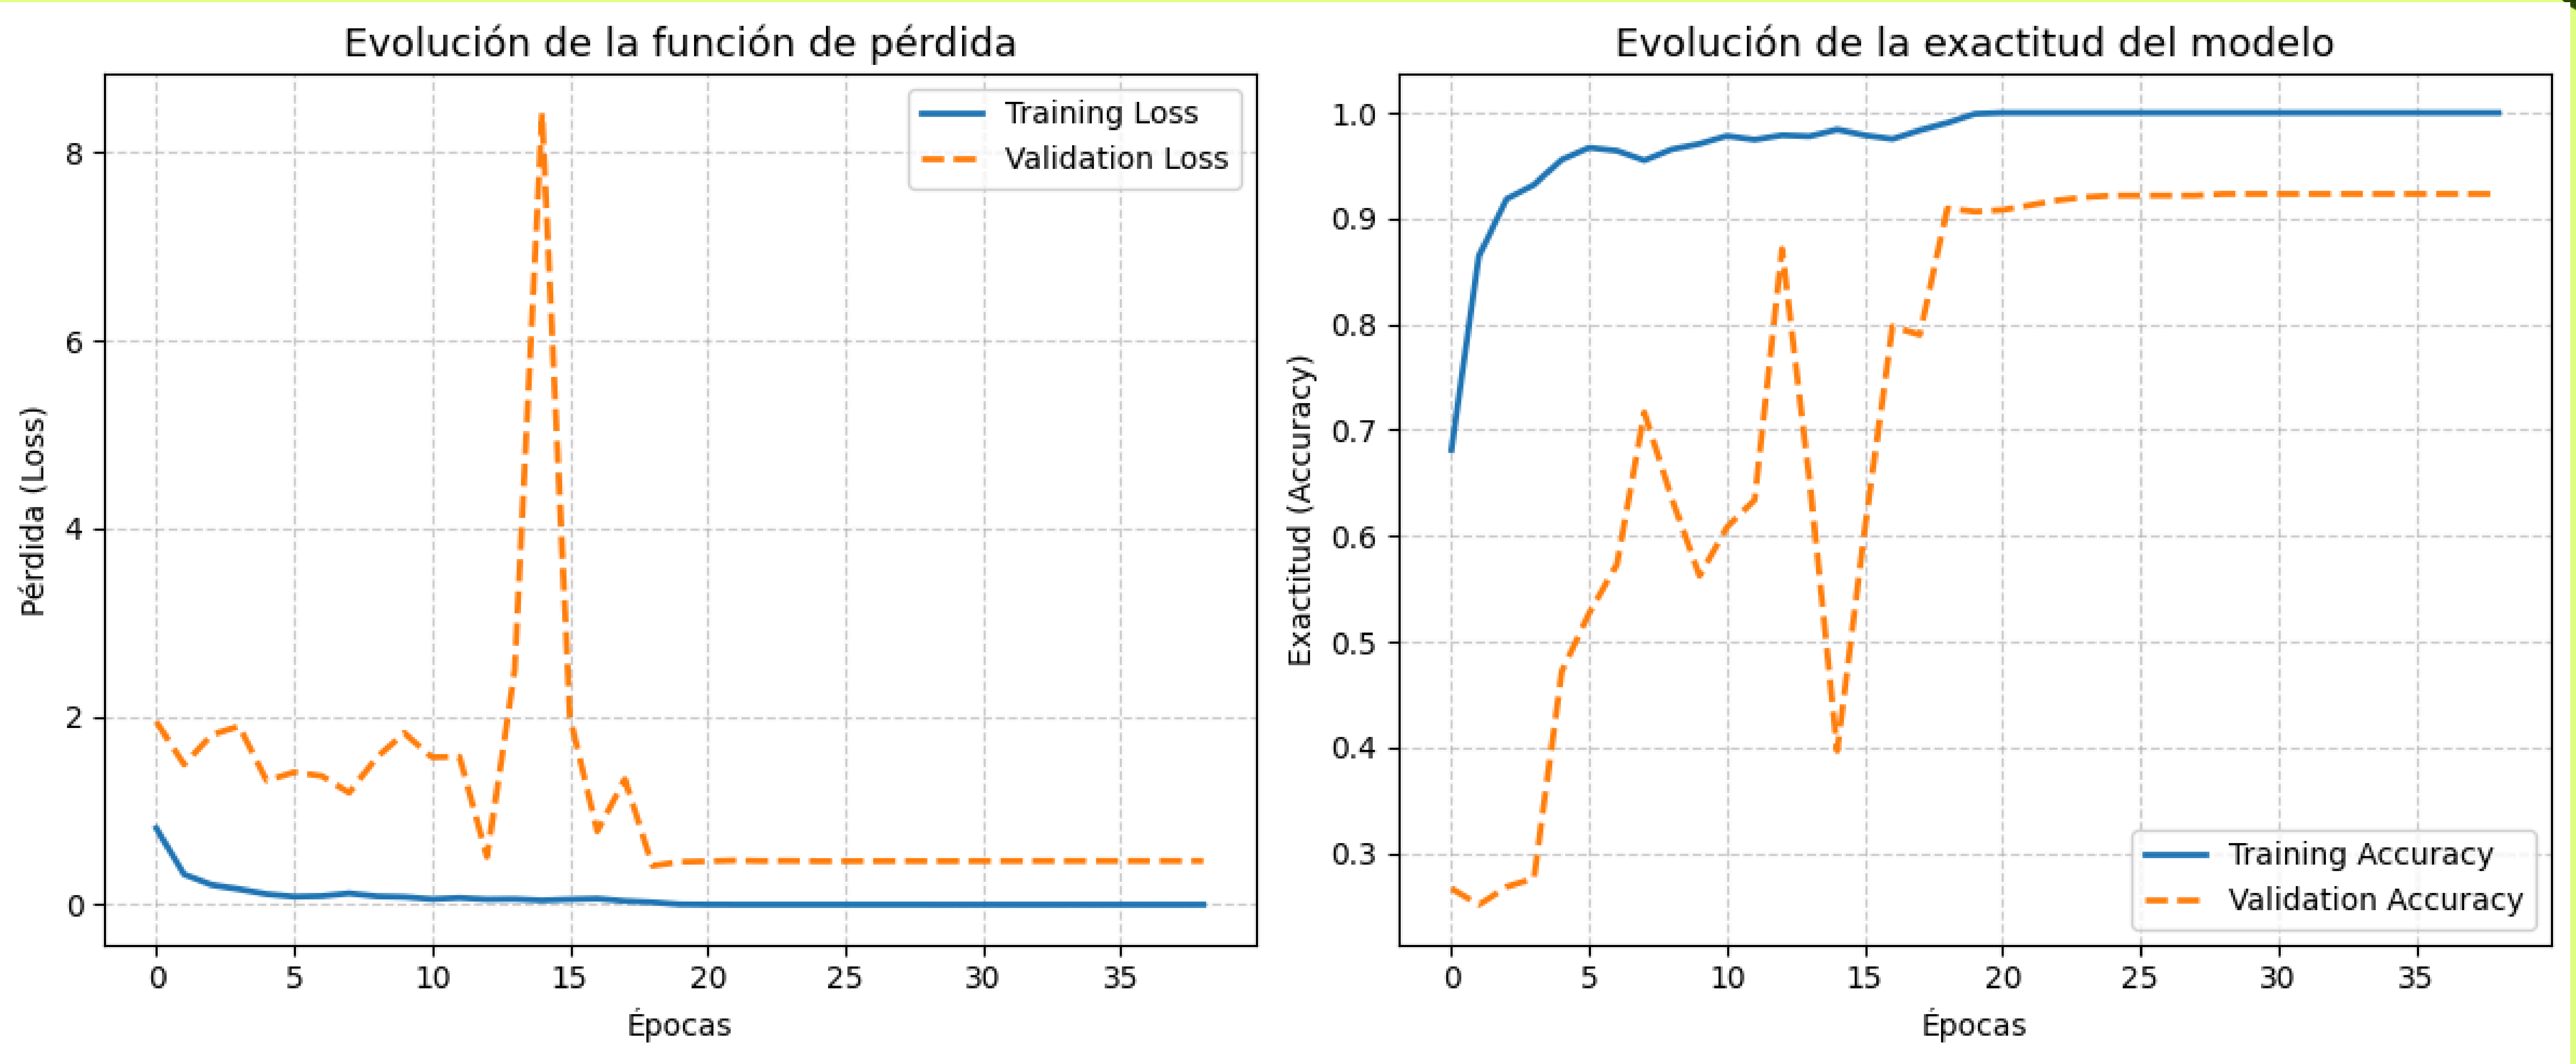

AGROVISION

REEVALUANDO RESNET50

Accuracy

0.94

Macro AUC (OvR)

0.99

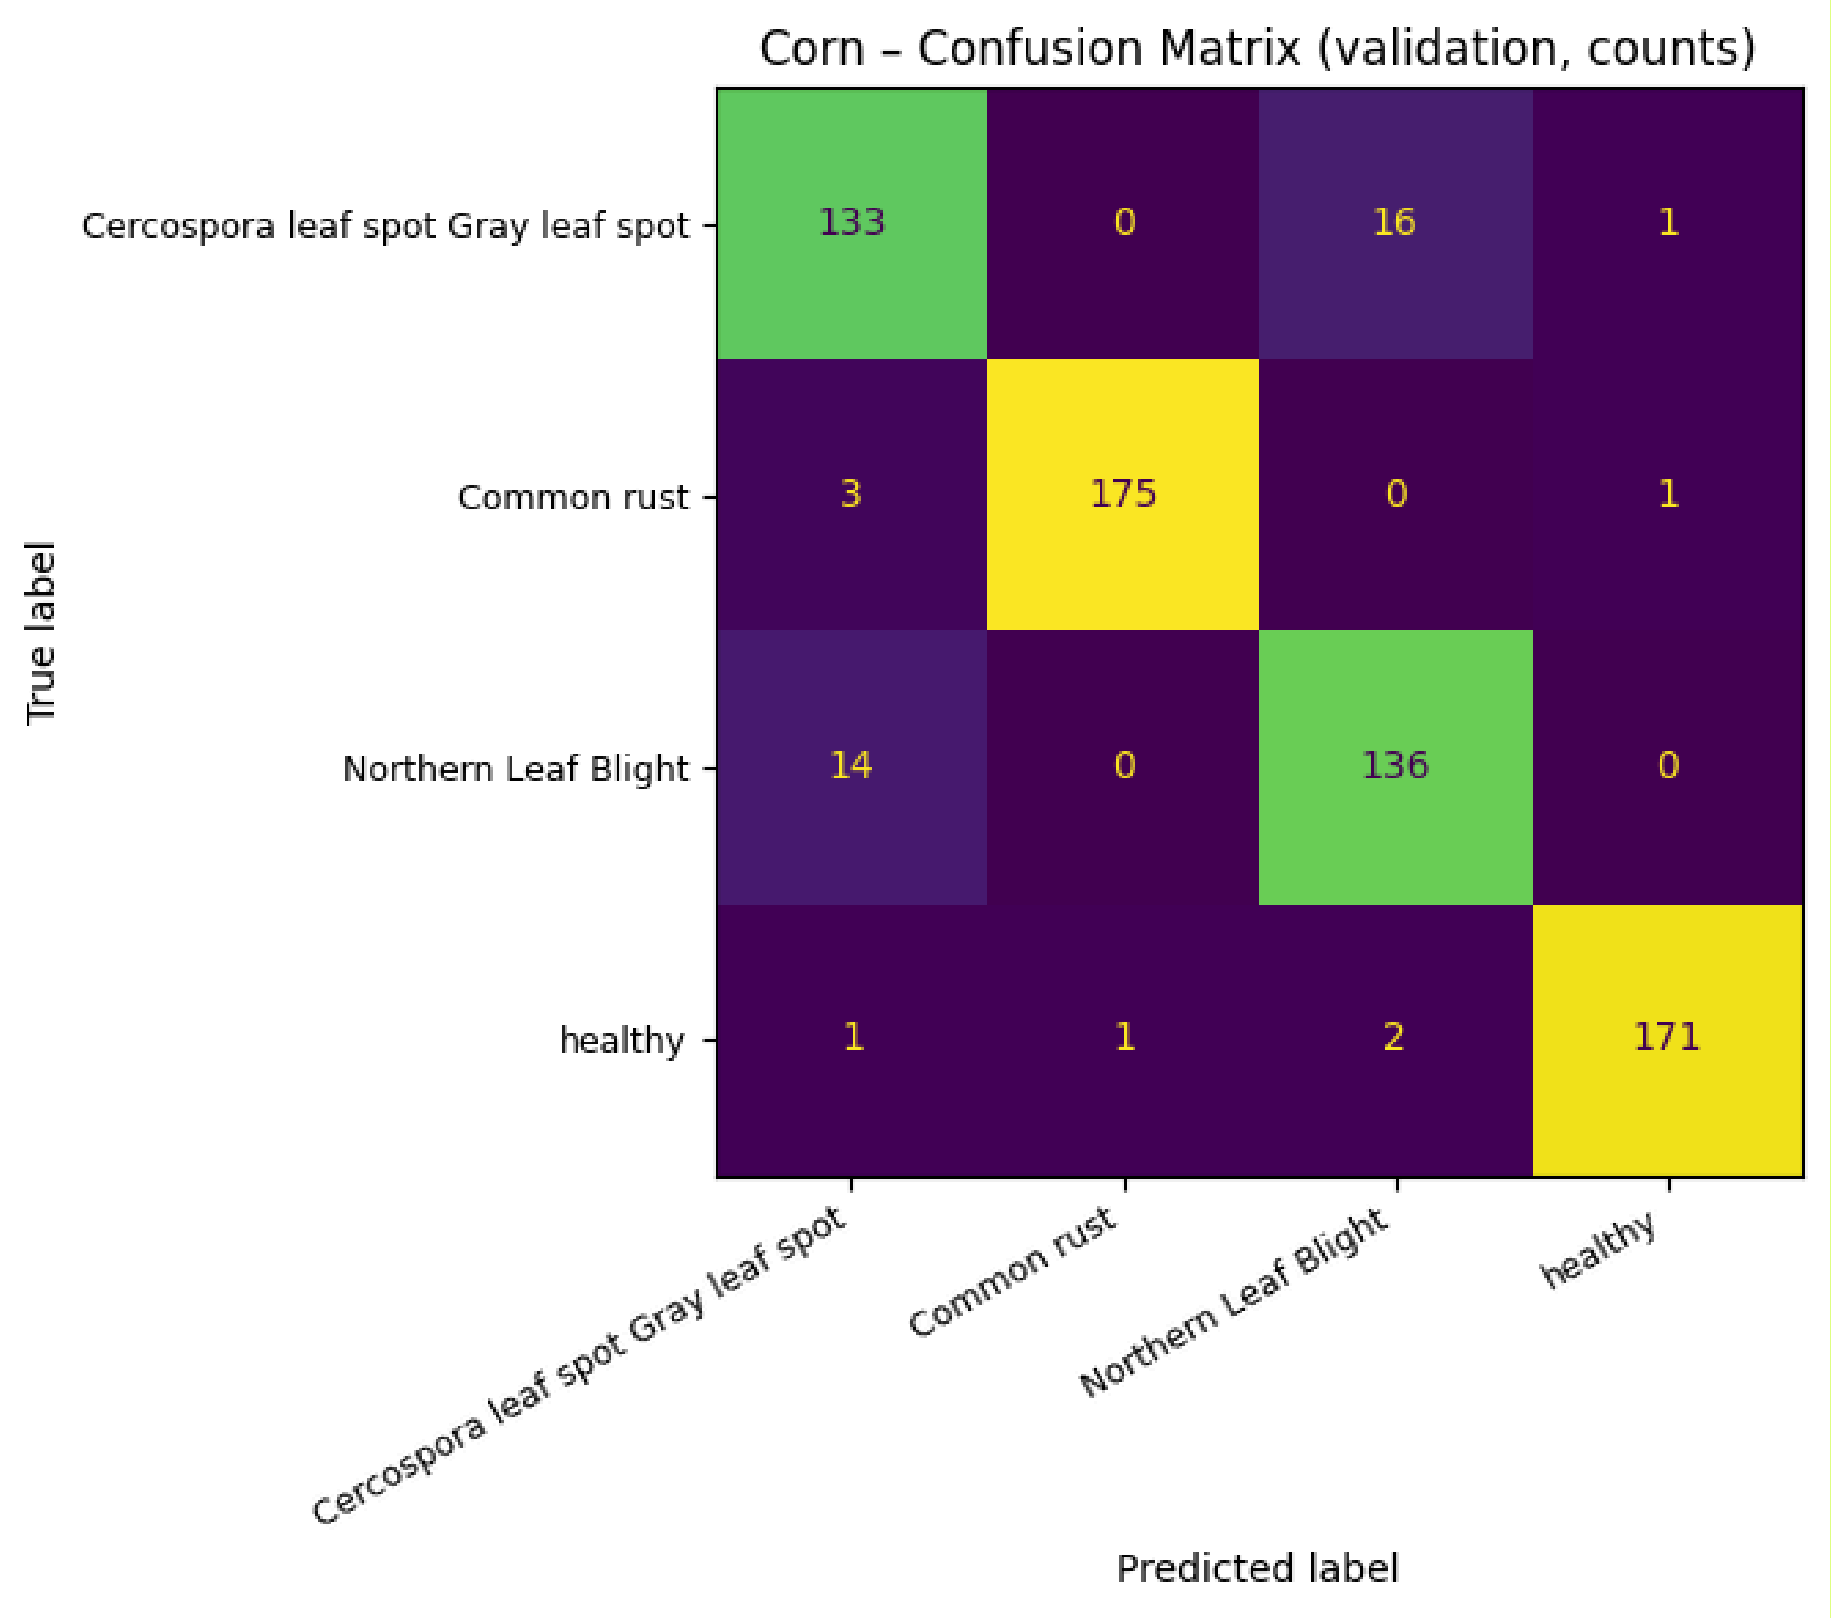

AGROVISION

REEVALUANDO RESNET50

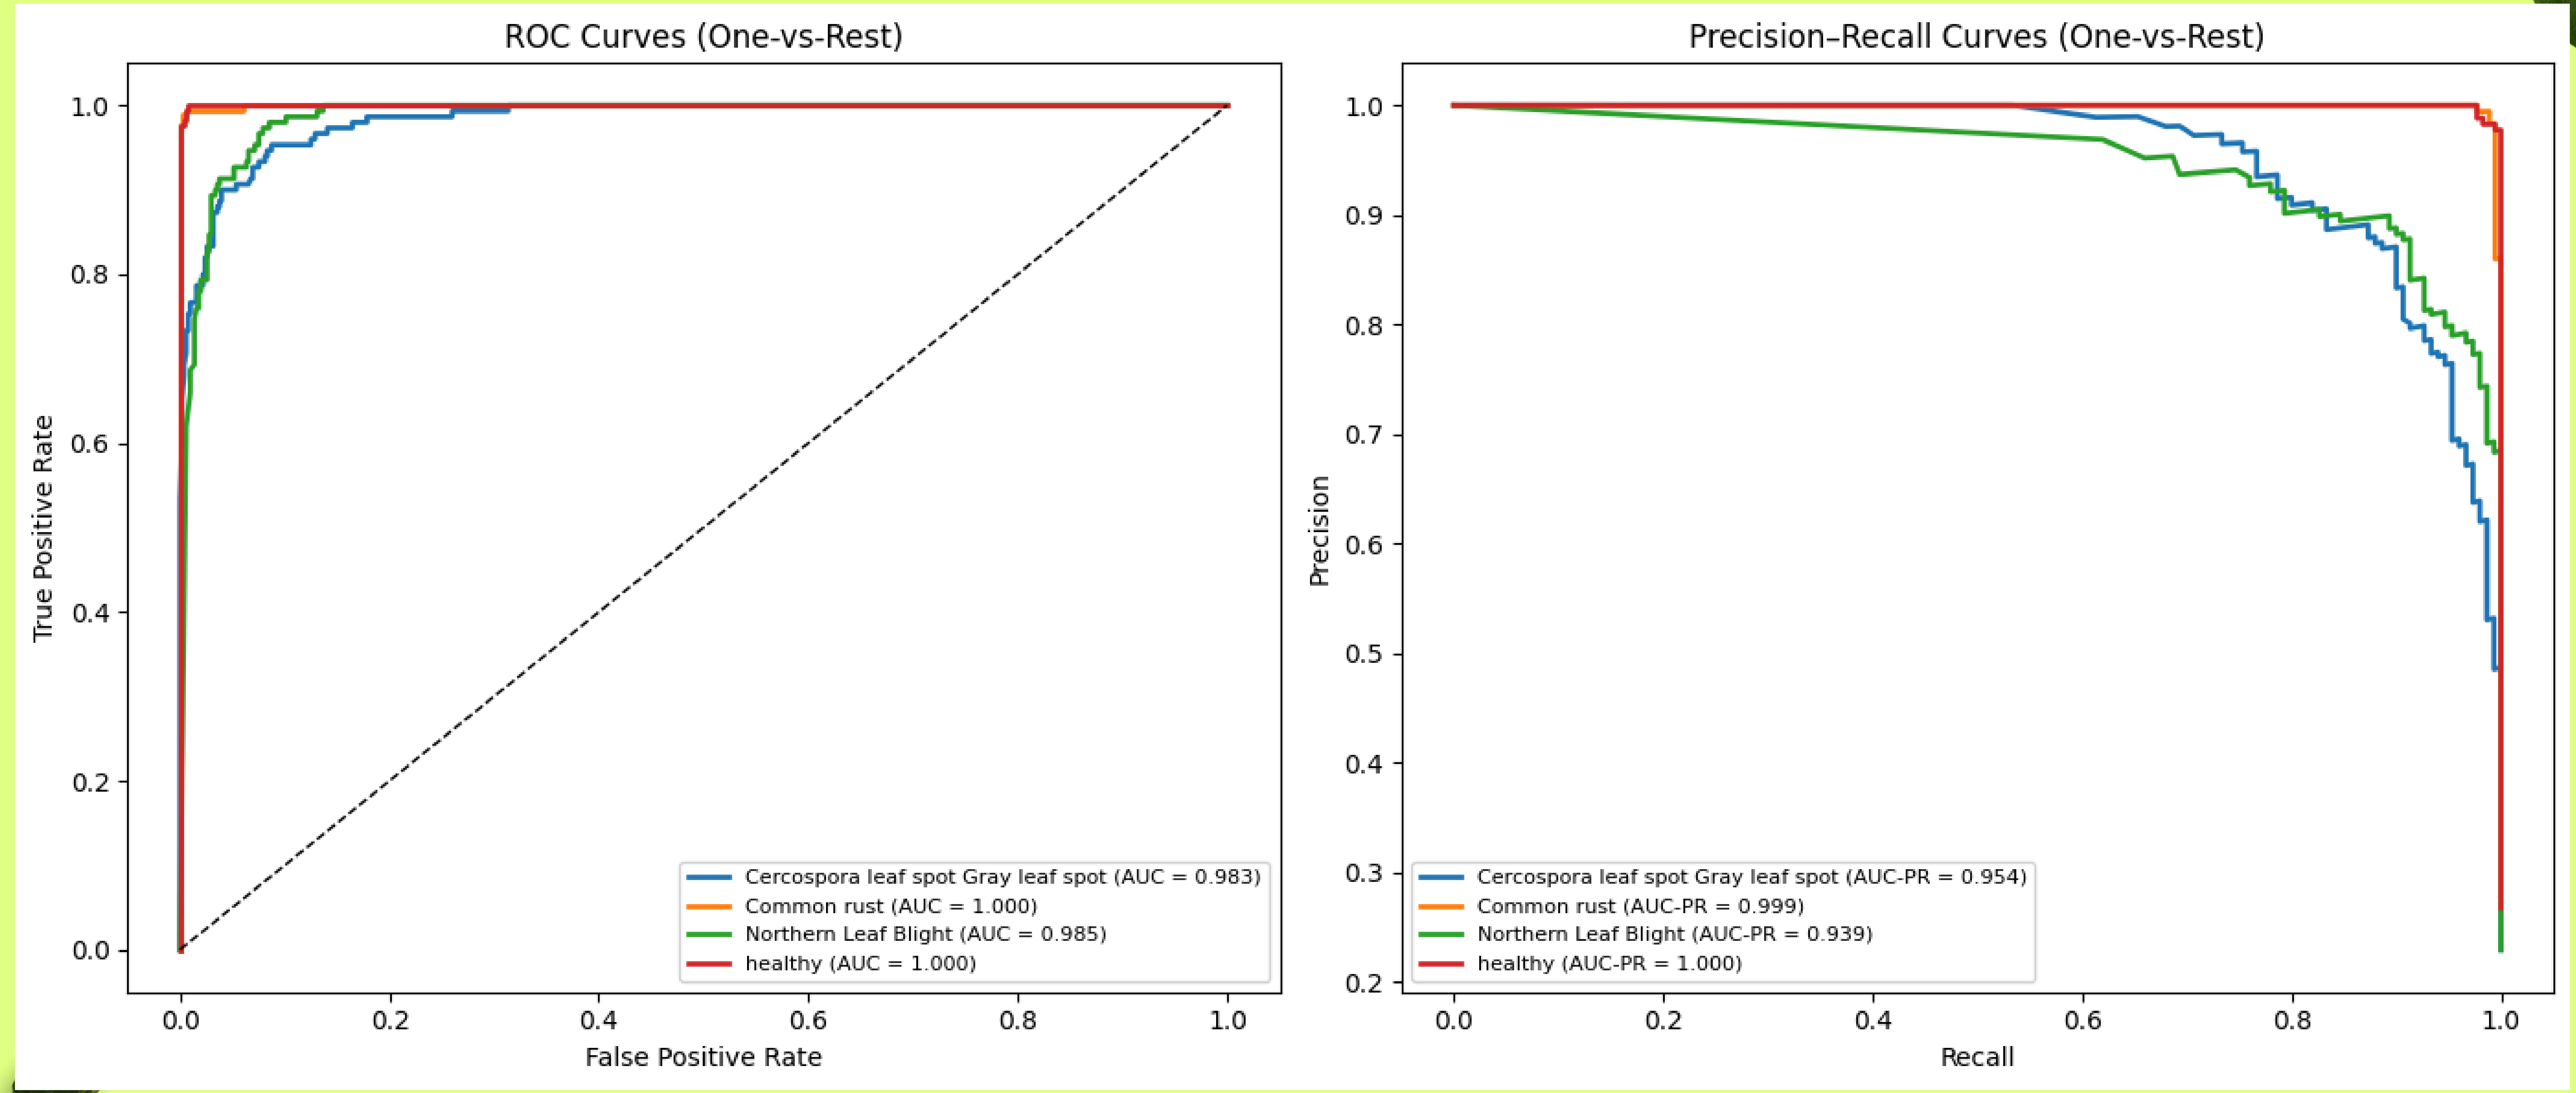

¿PUEDES DETECTAR MÁS POSITIVOS SIN LLENARTE DE FALSOS POSITIVOS?

REEVALUANDO CNN 2.0

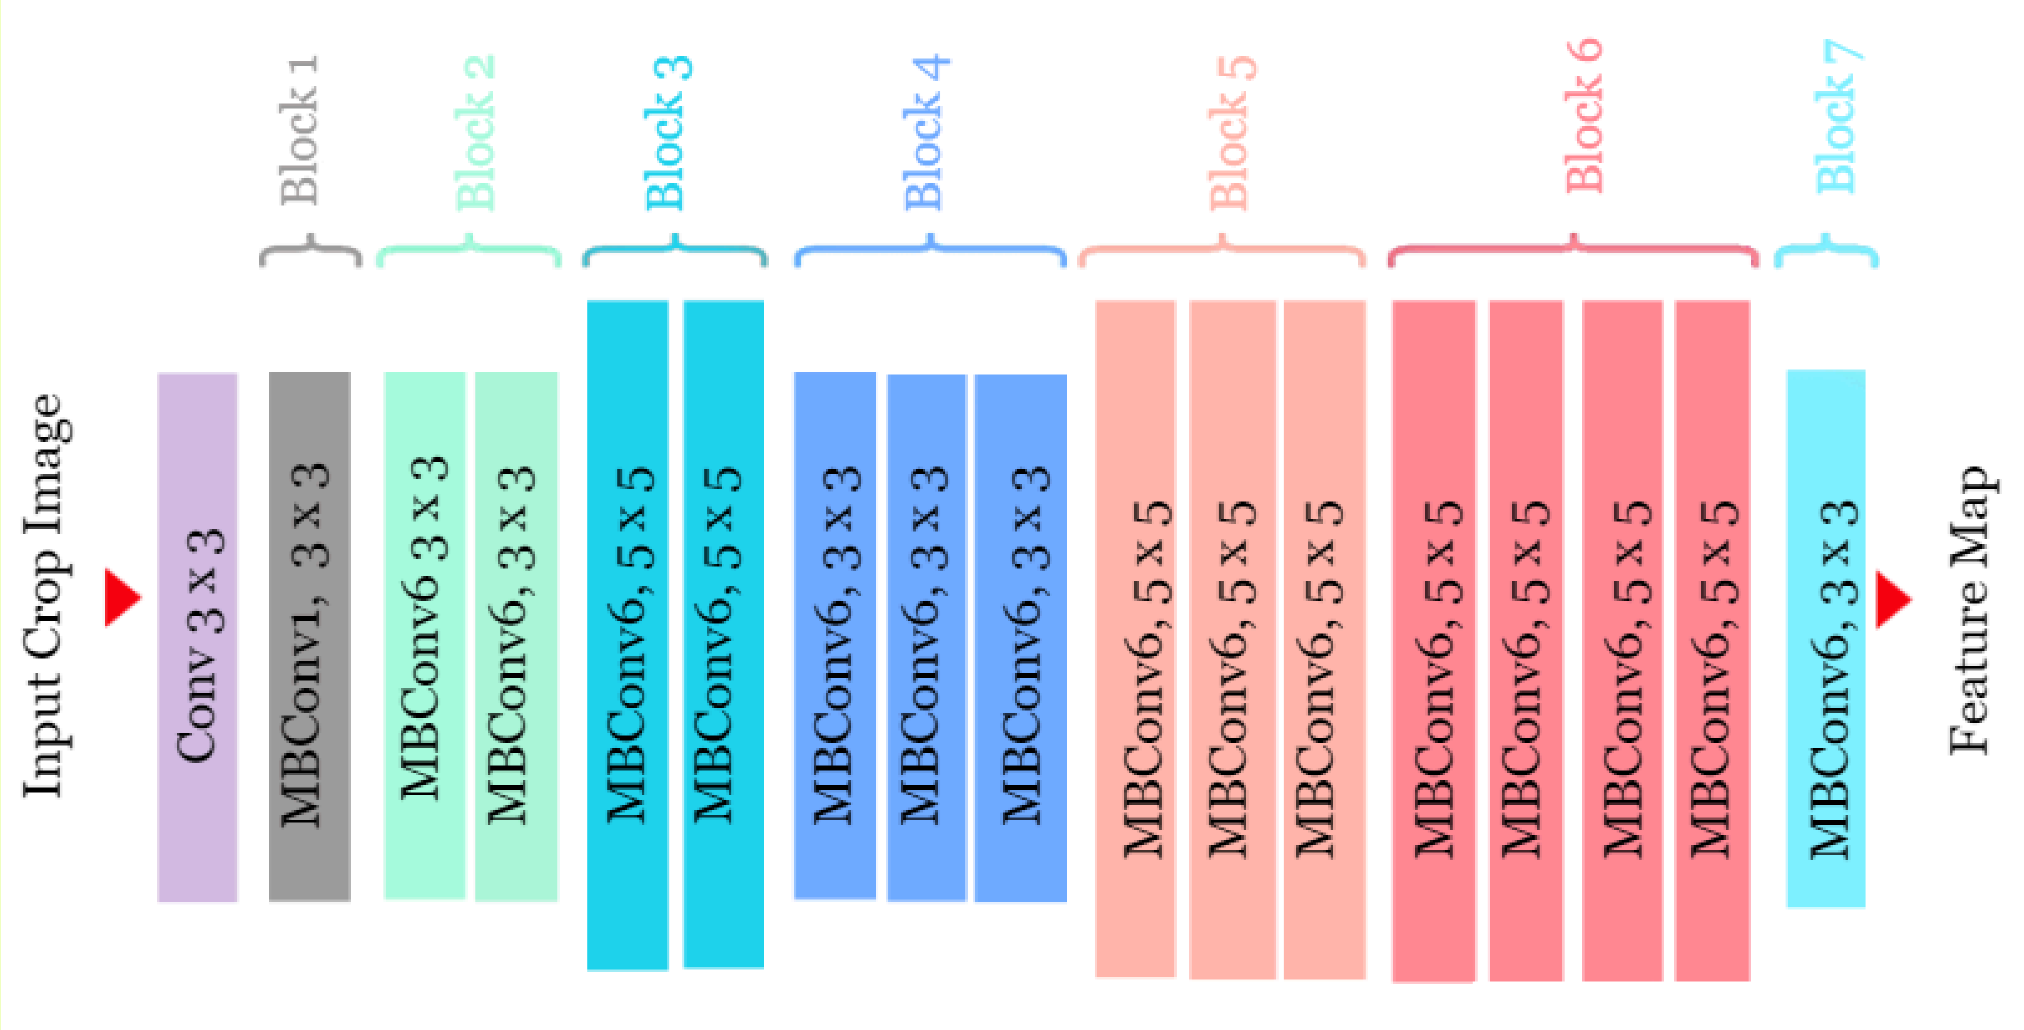

Pretrained on the ImageNet dataset

Se entrenan 140 capas de 175

- AdamW, LR = 2e-4, EarlyStopping, ReduceLROnPlateau

AGROVISION

EFFICIENTNETB0

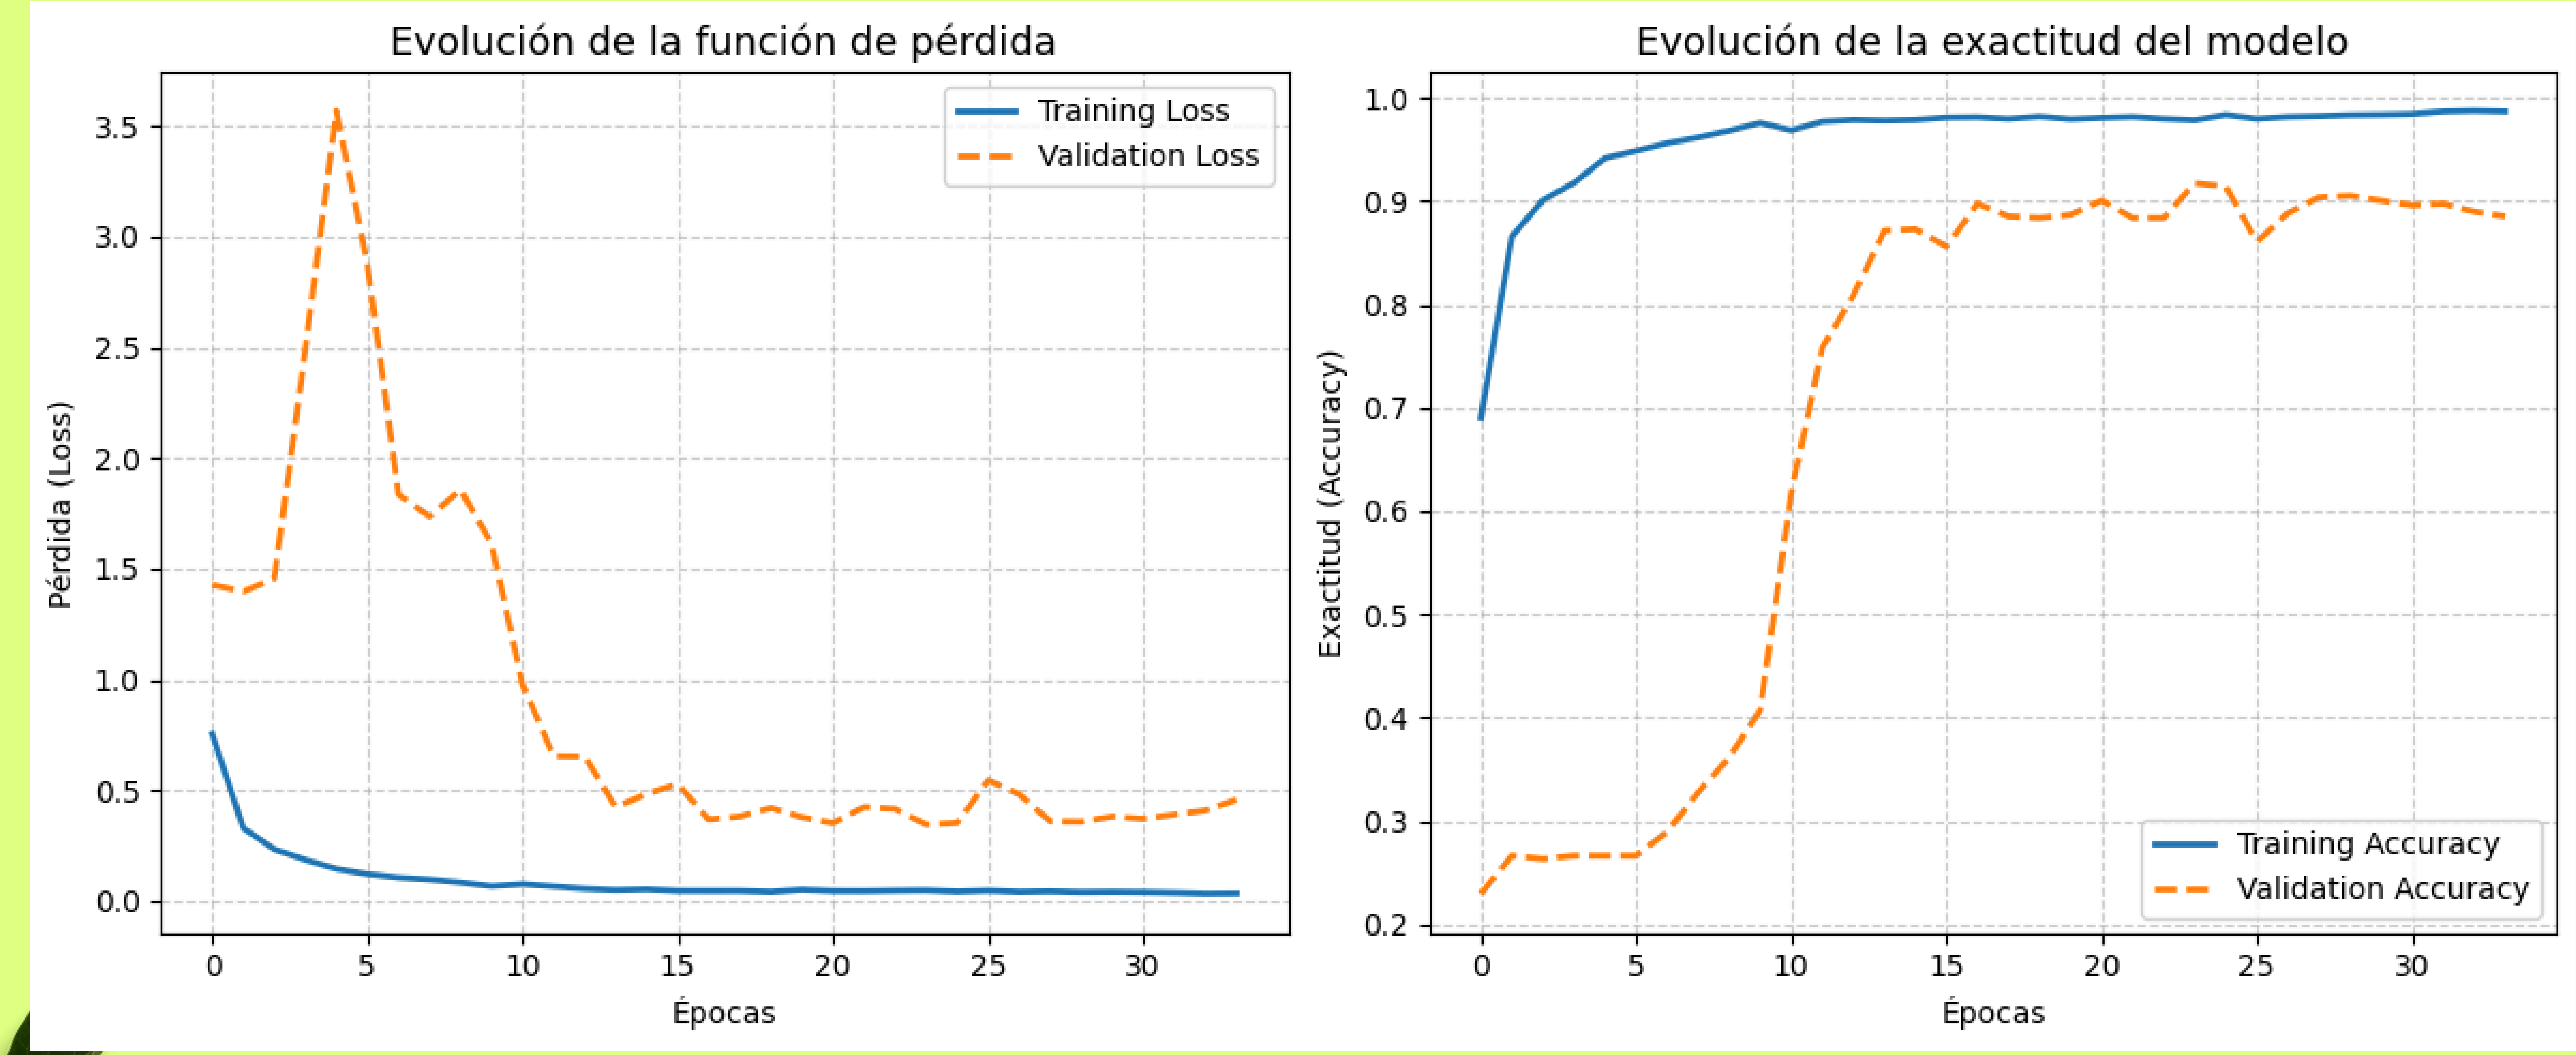

AGROVISION

EFFICIENTNETB0

Accuracy

0.92

Macro AUC (OvR)

0.98

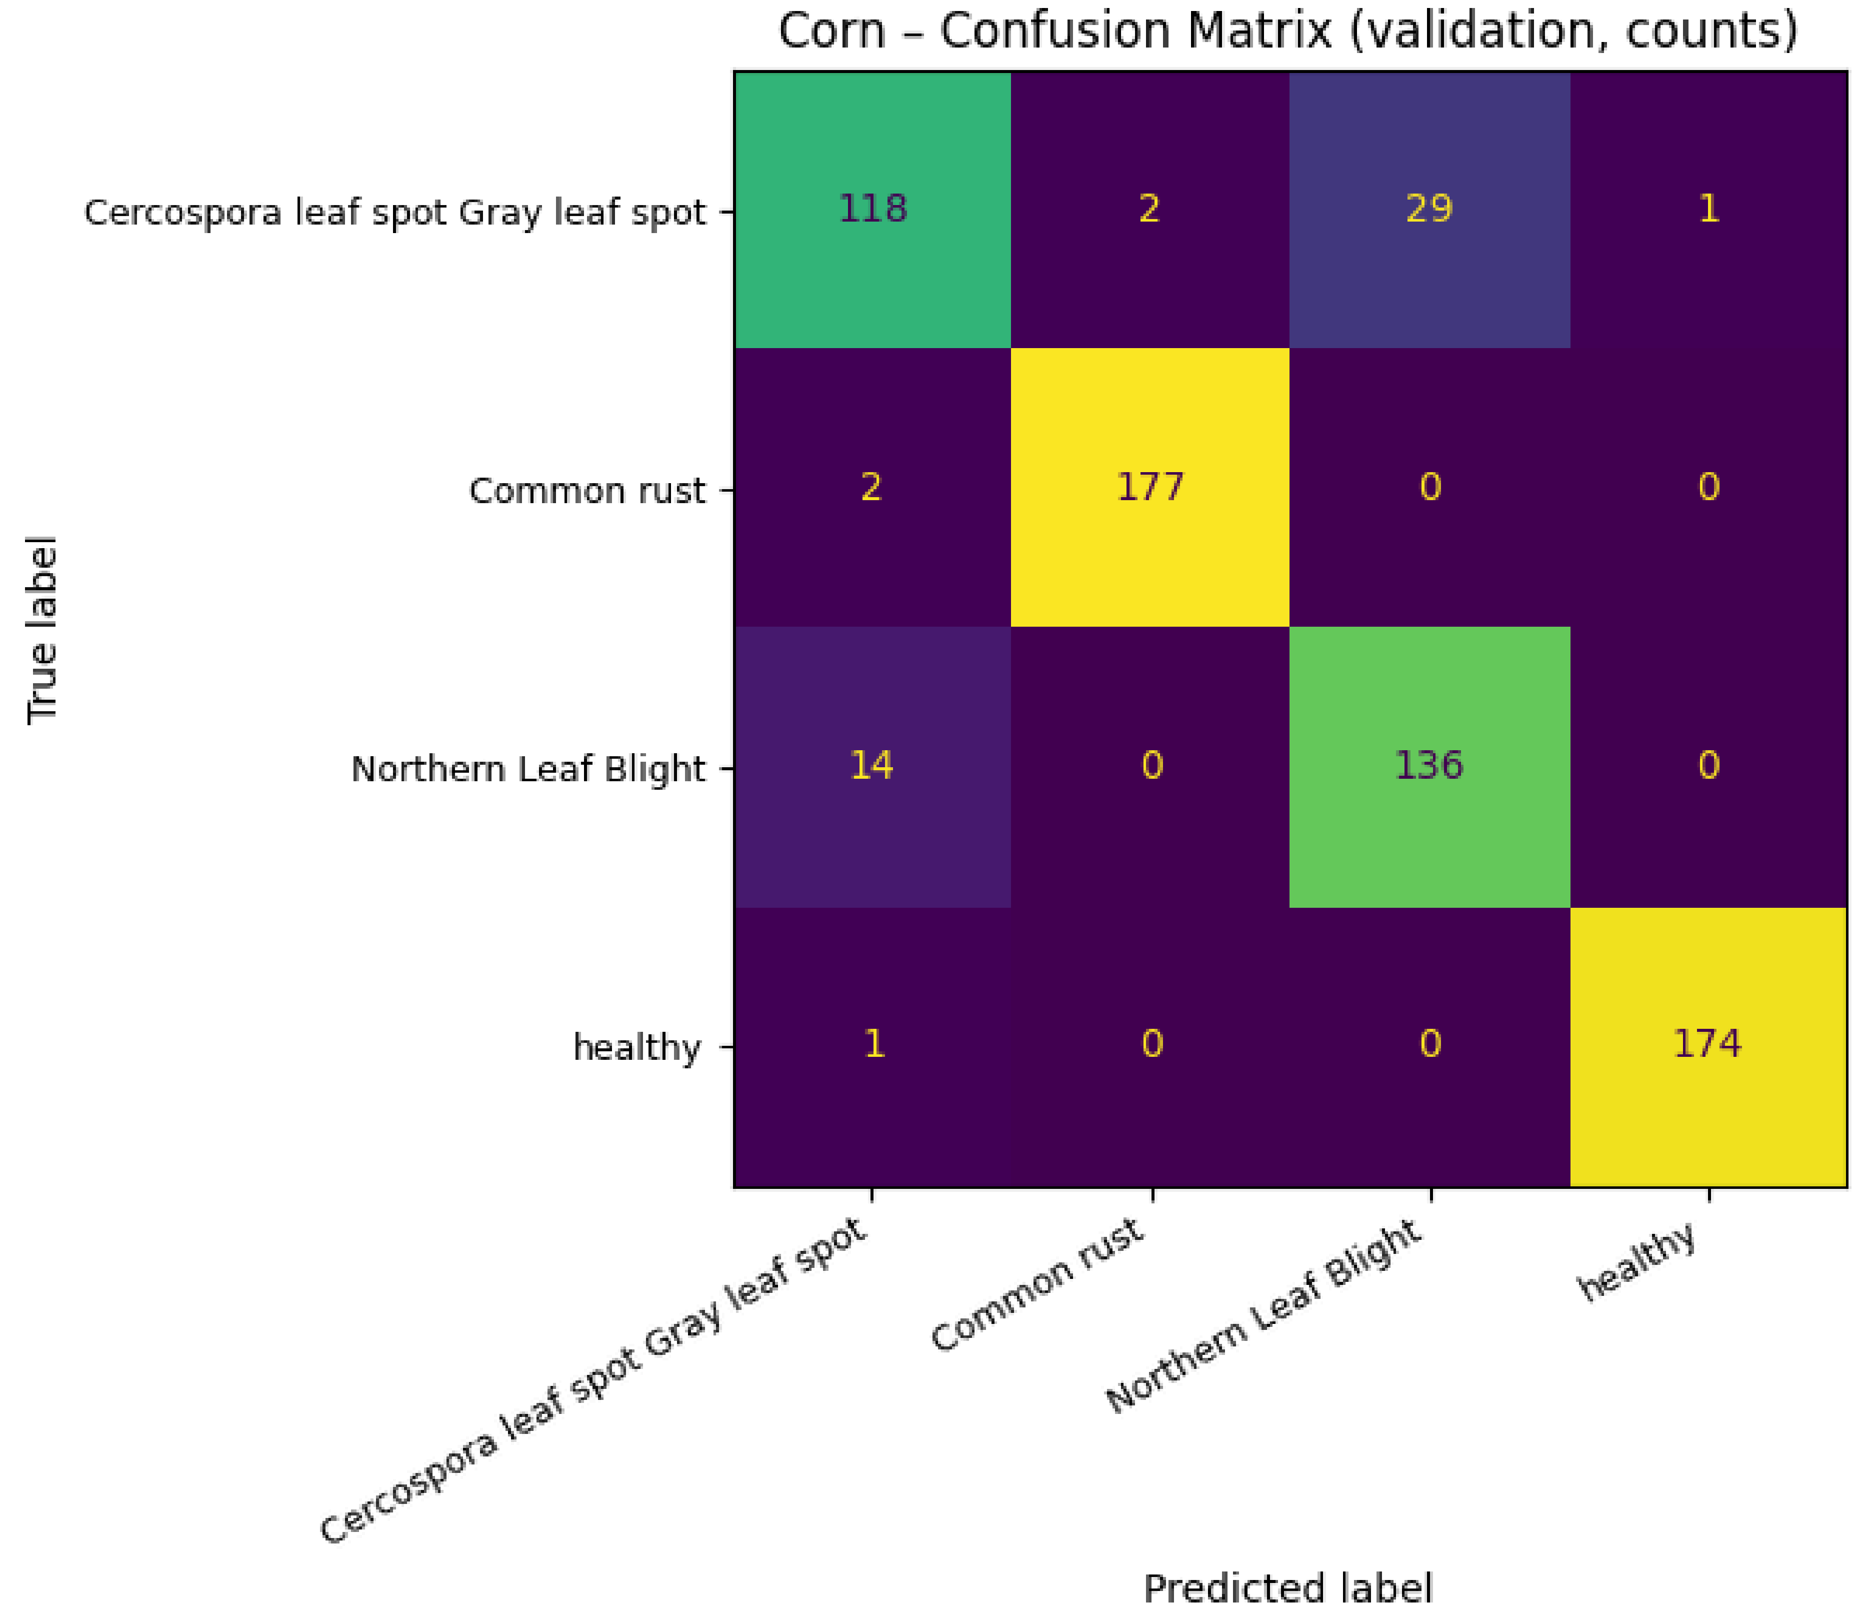

AGROVISION

EFFICIENTNETB0

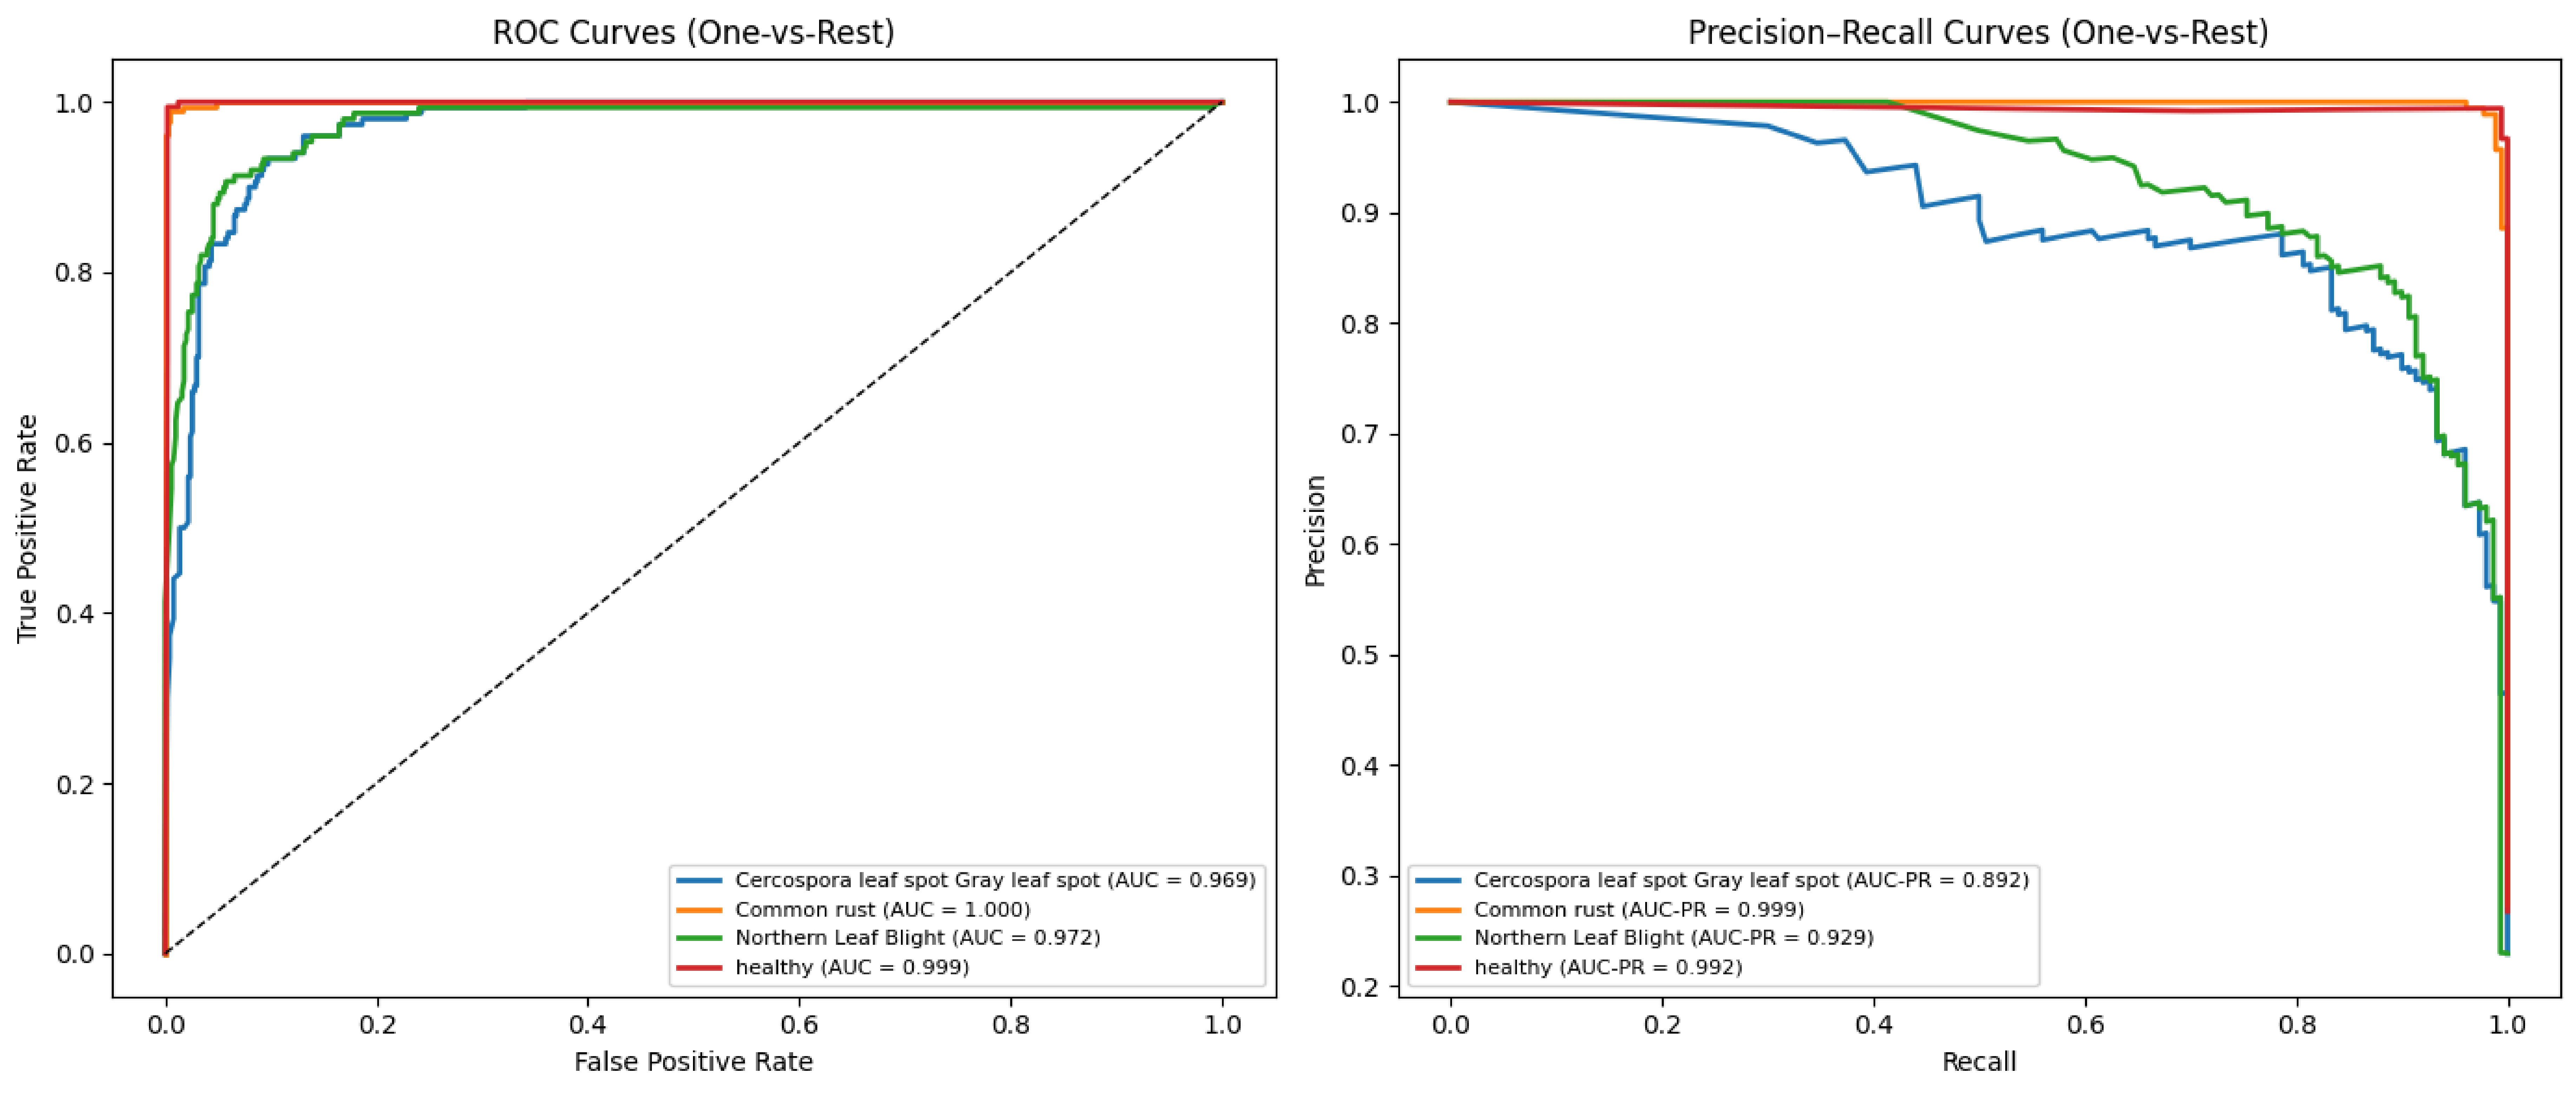

AGROVISION

ABLACIÓN RESNET50

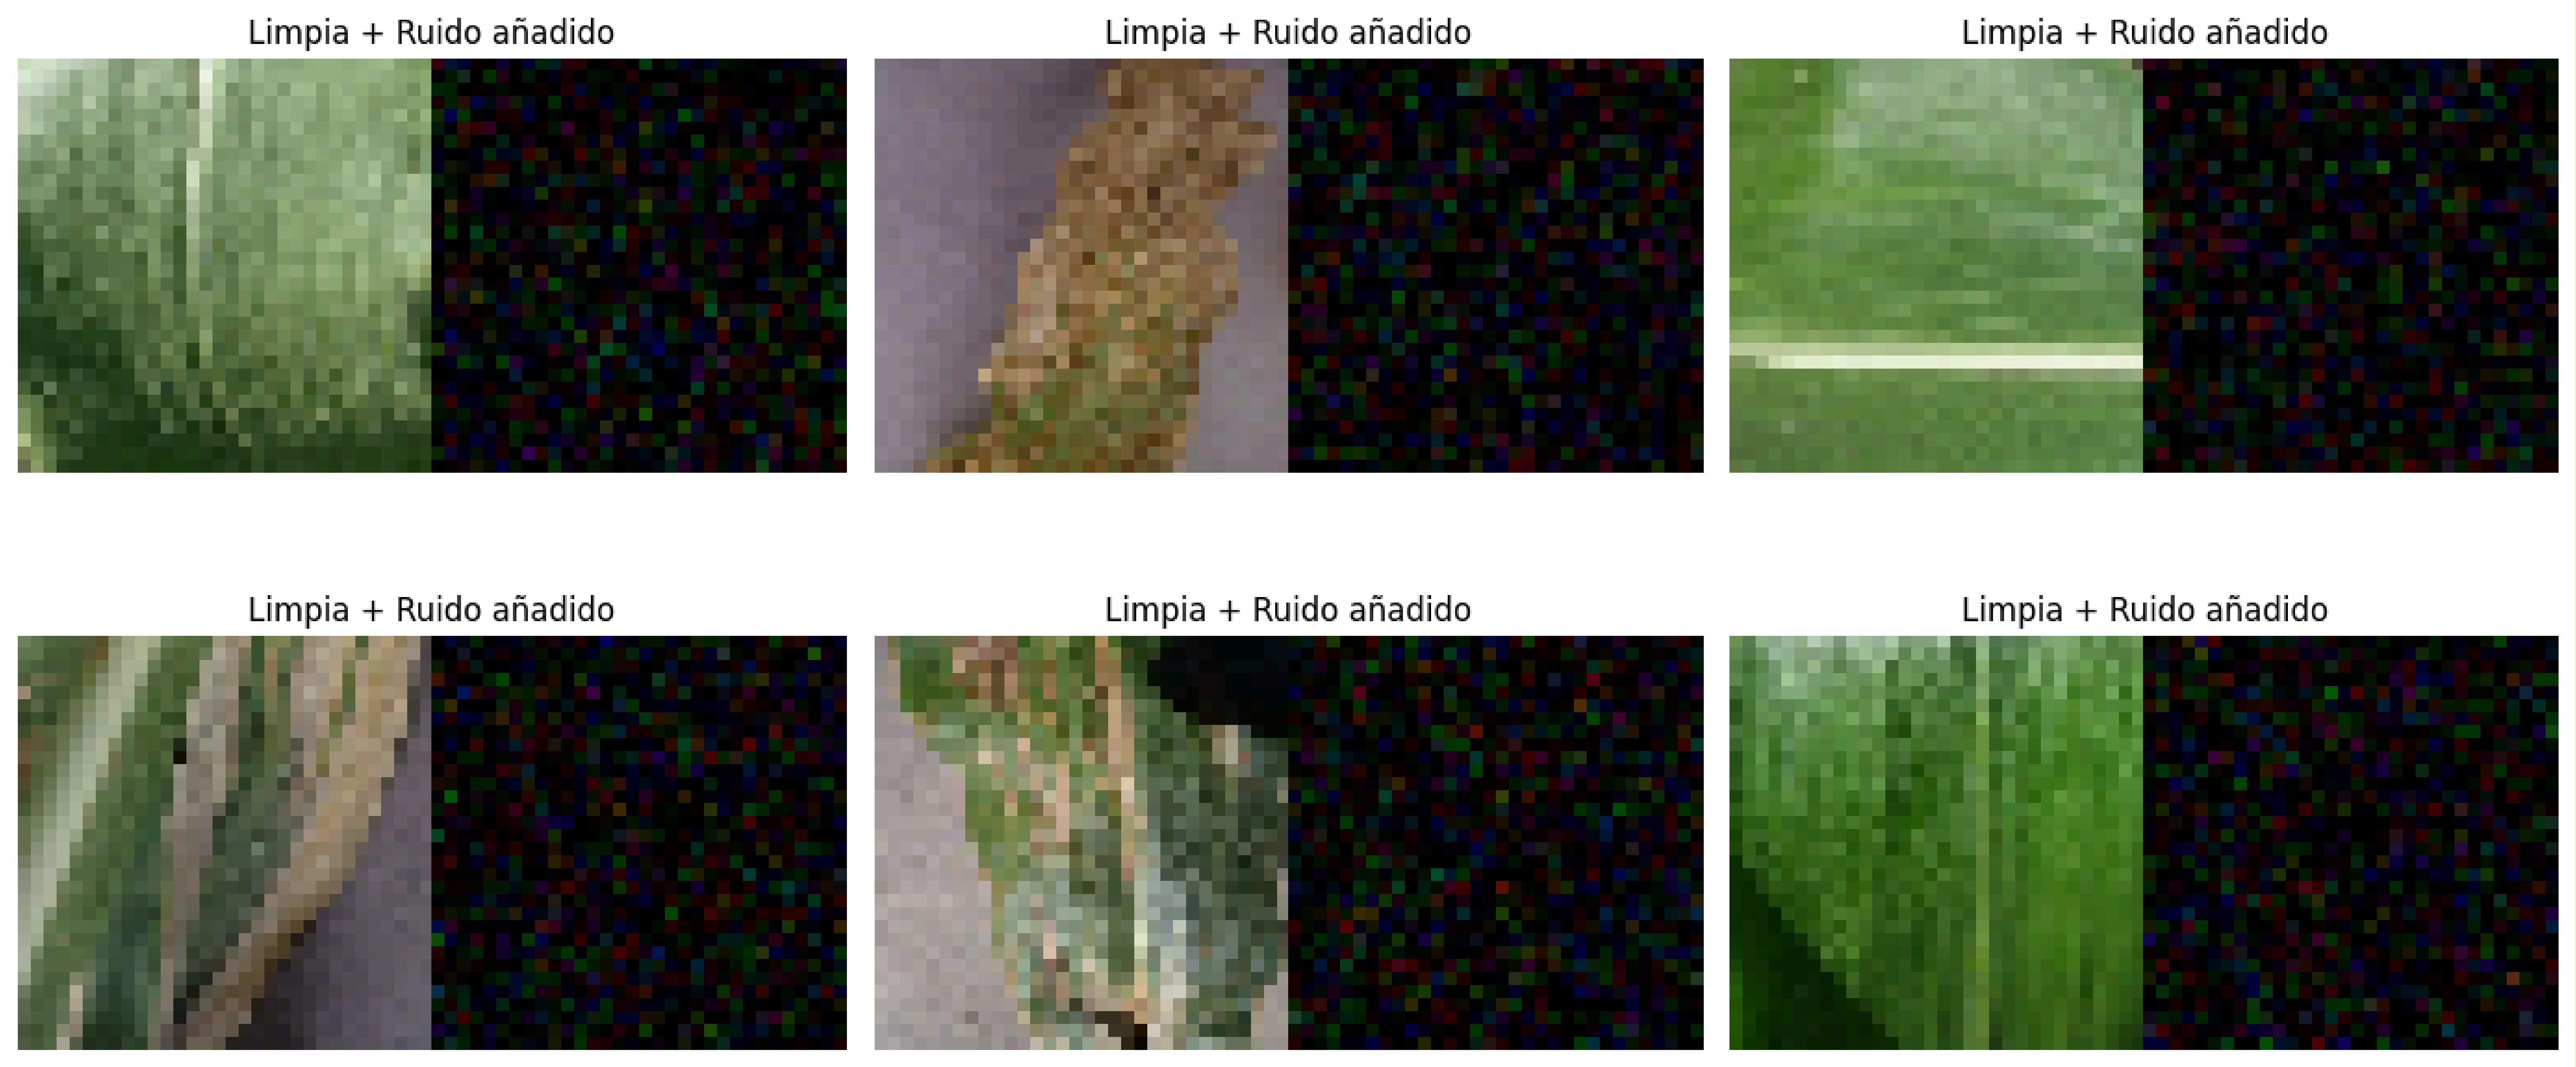

- Se entrenó con un sigma de ruido de 0.1
- Se evaluó con imágenes limpias

AGROVISION

ABLACIÓN RESNET50

Accuracy

0.79

Macro AUC (OvR)

0.96

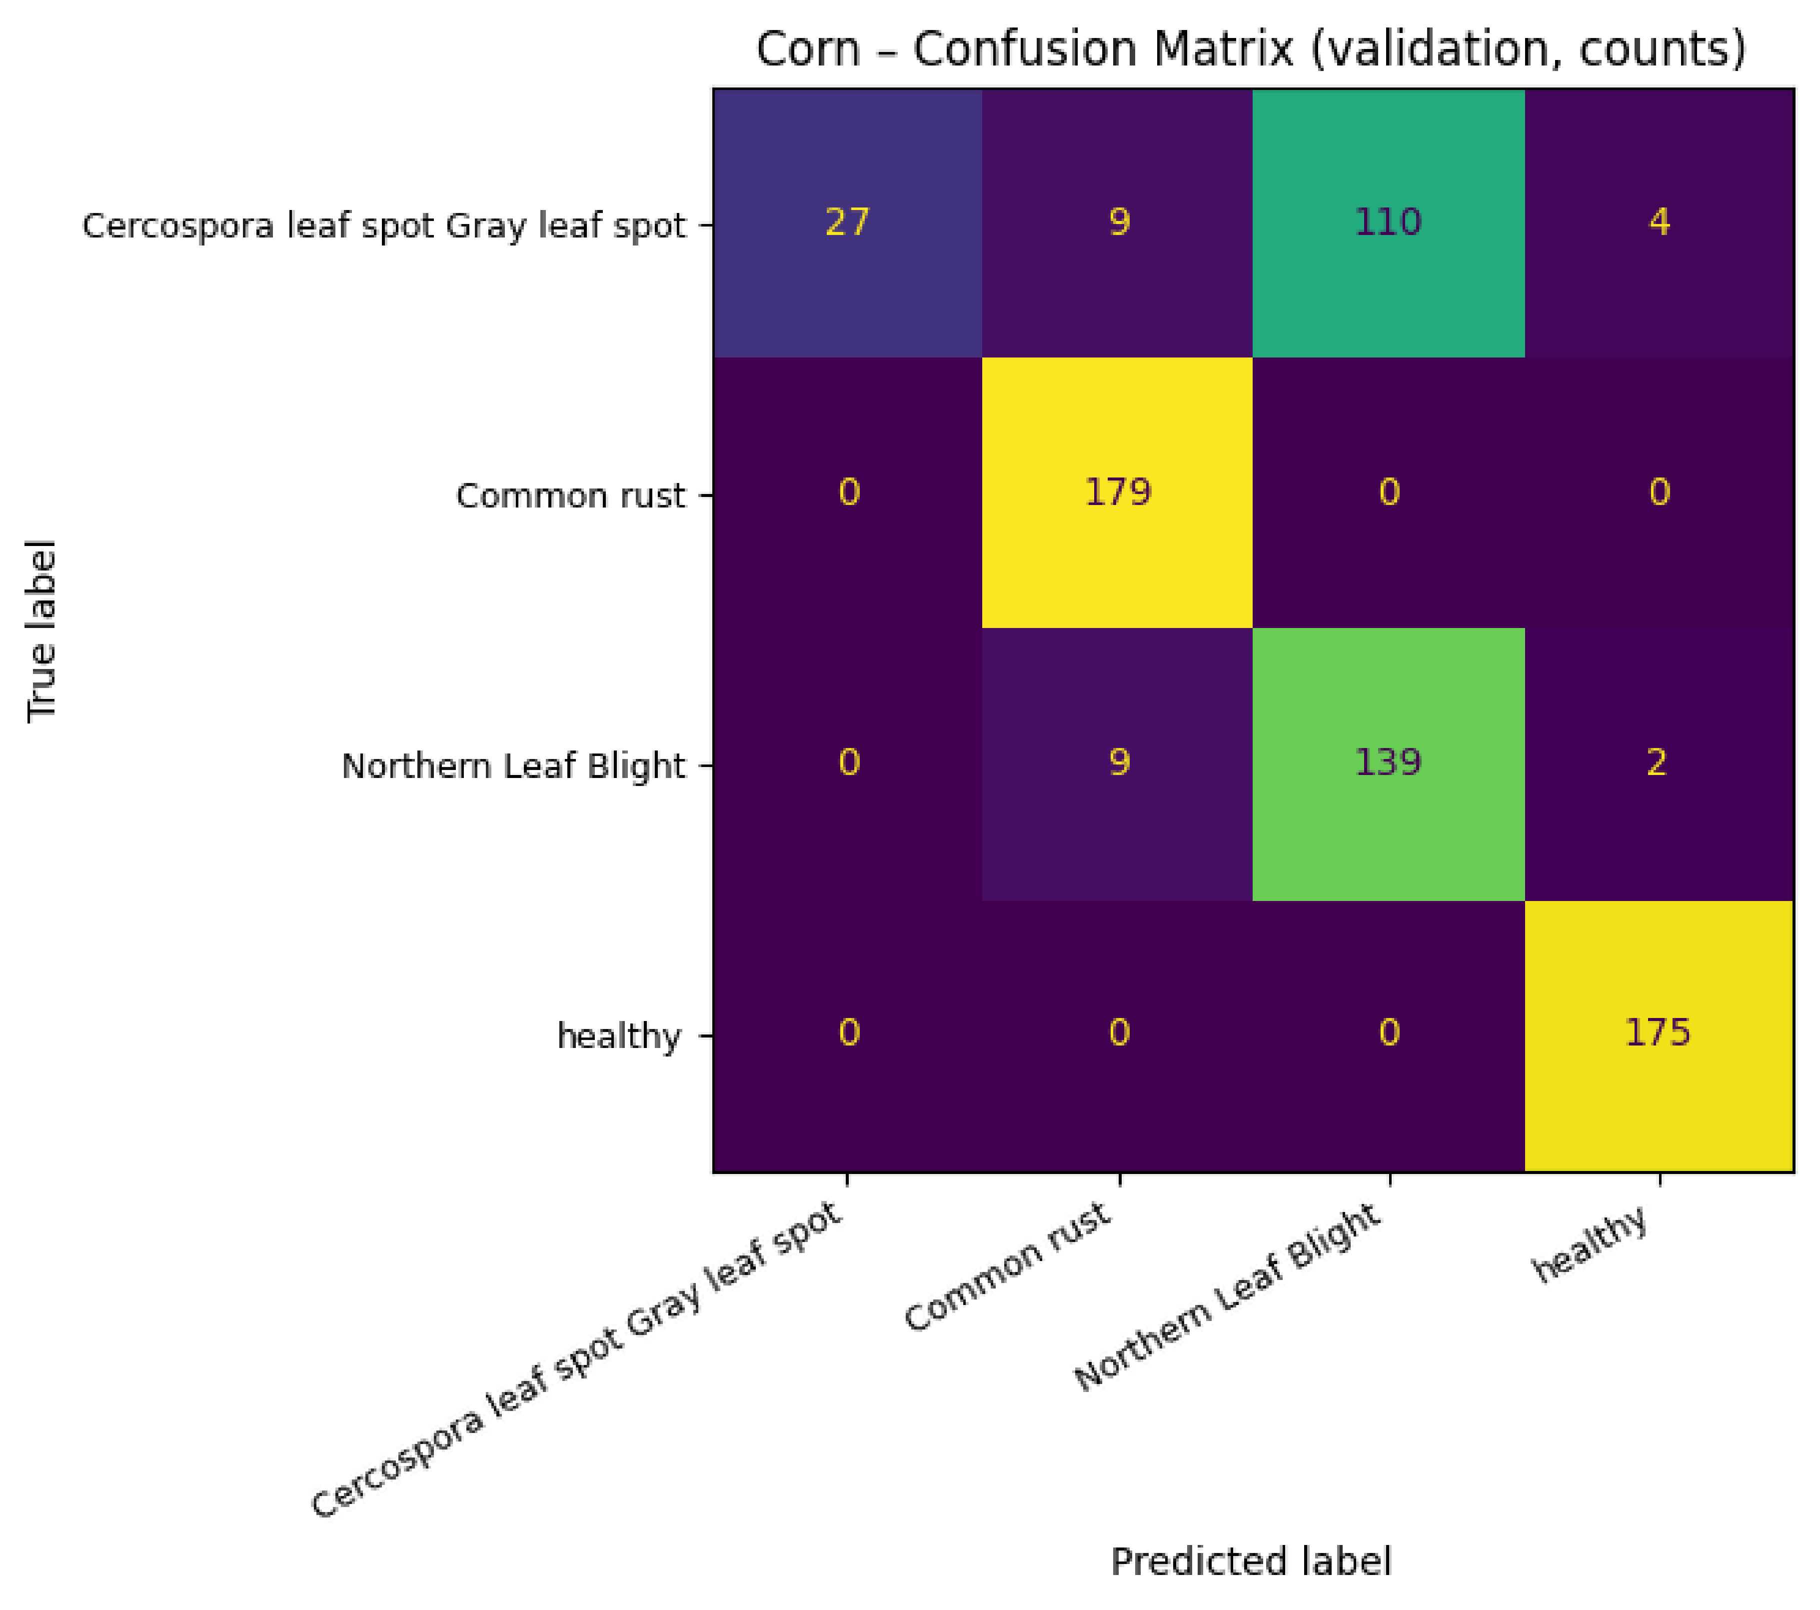

AGROVISION

ABLACIÓN RESNET50

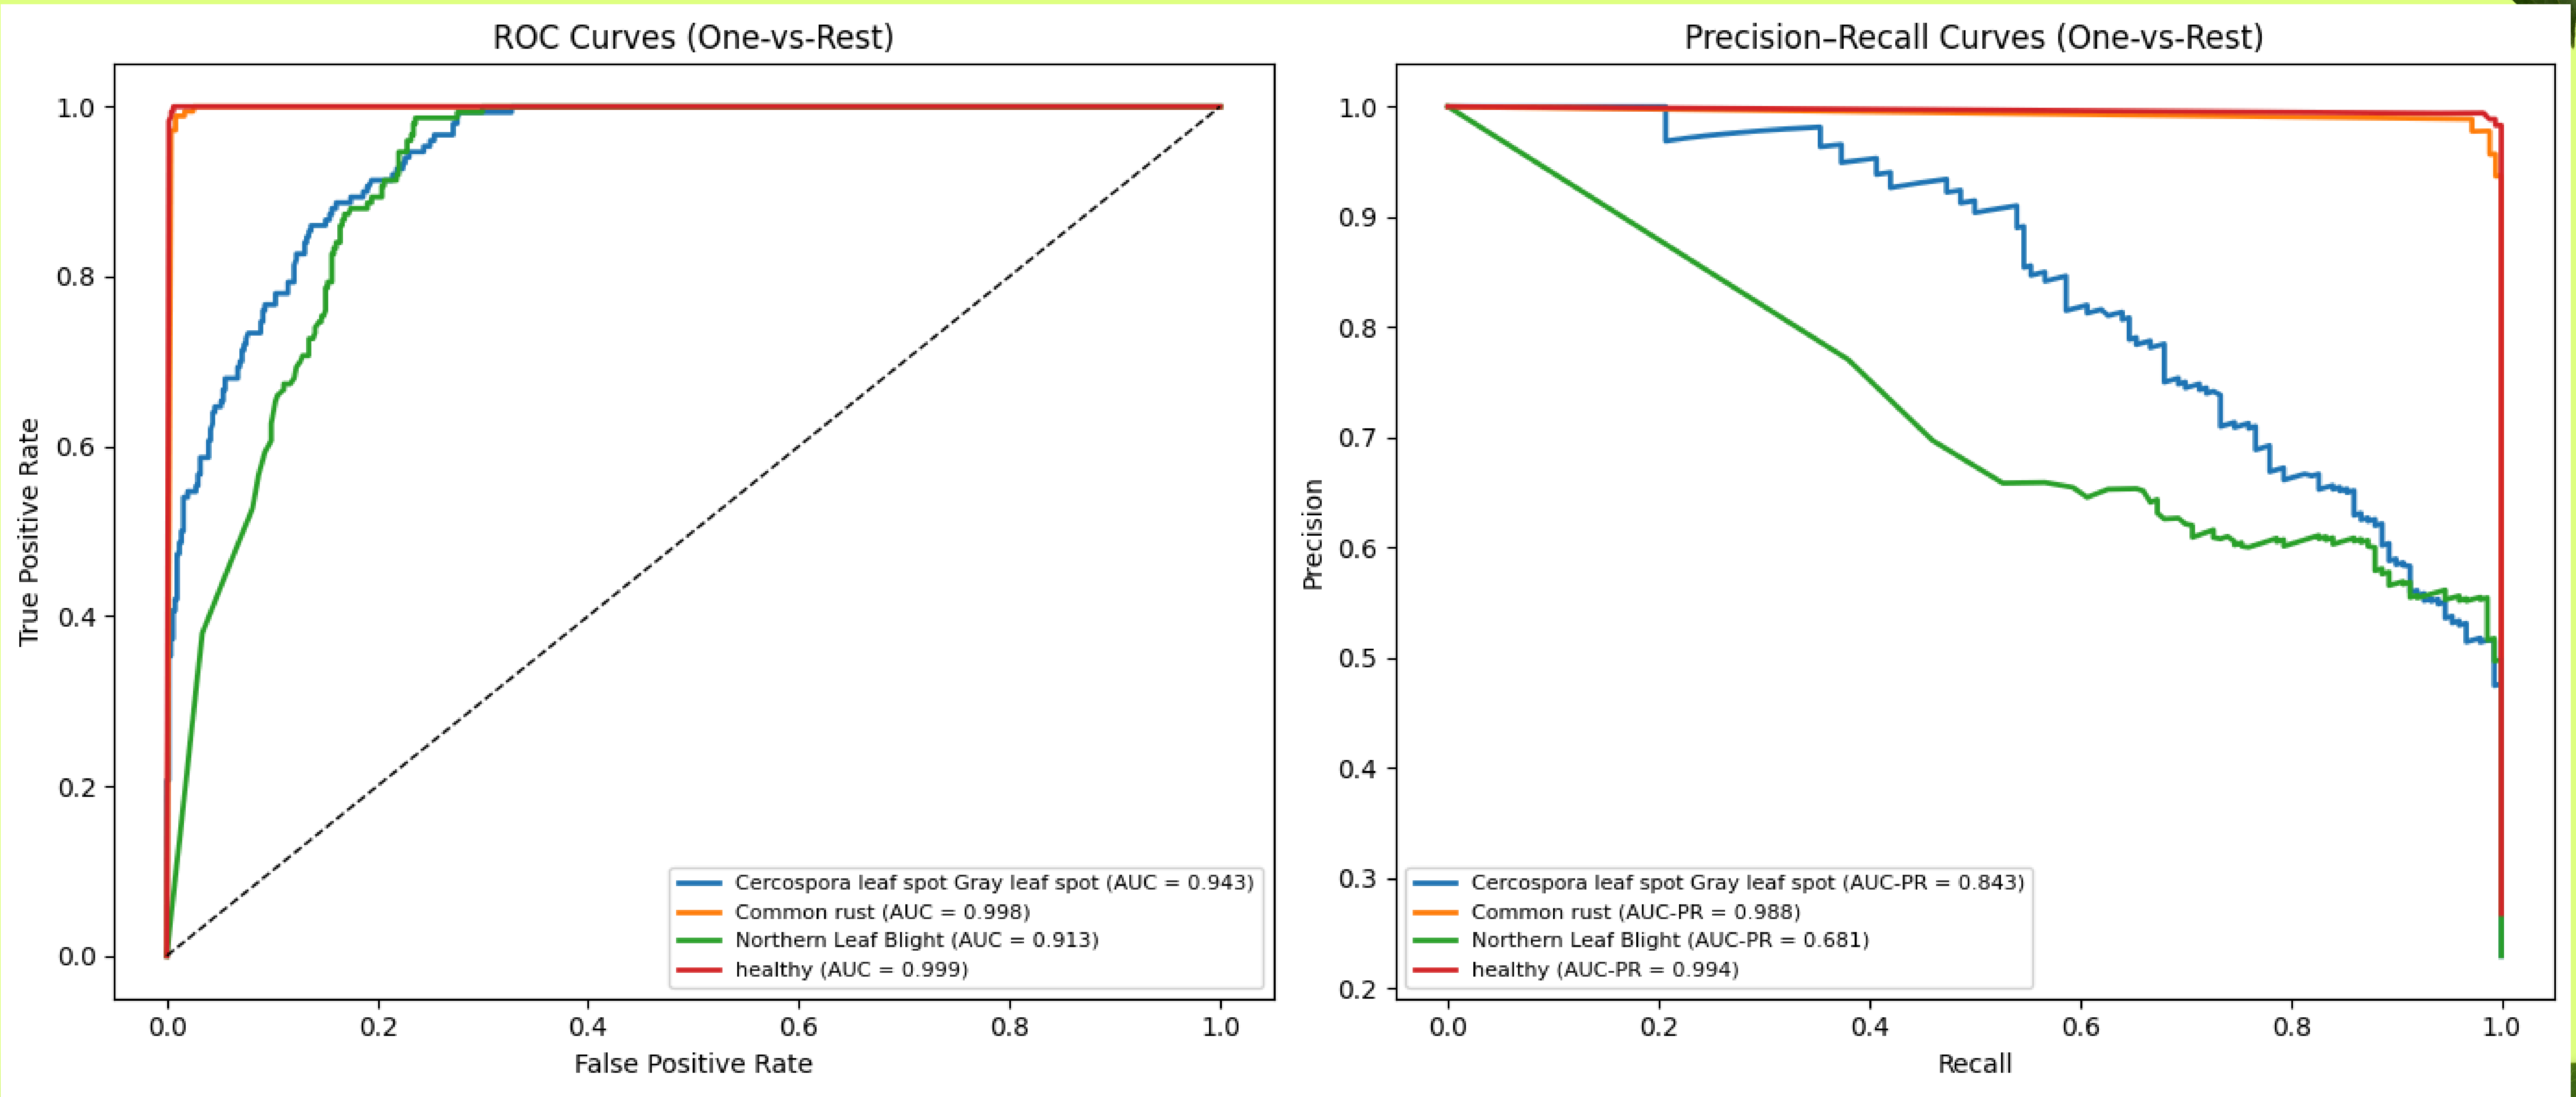

AGROVISION

ABLACIÓN RESNET50

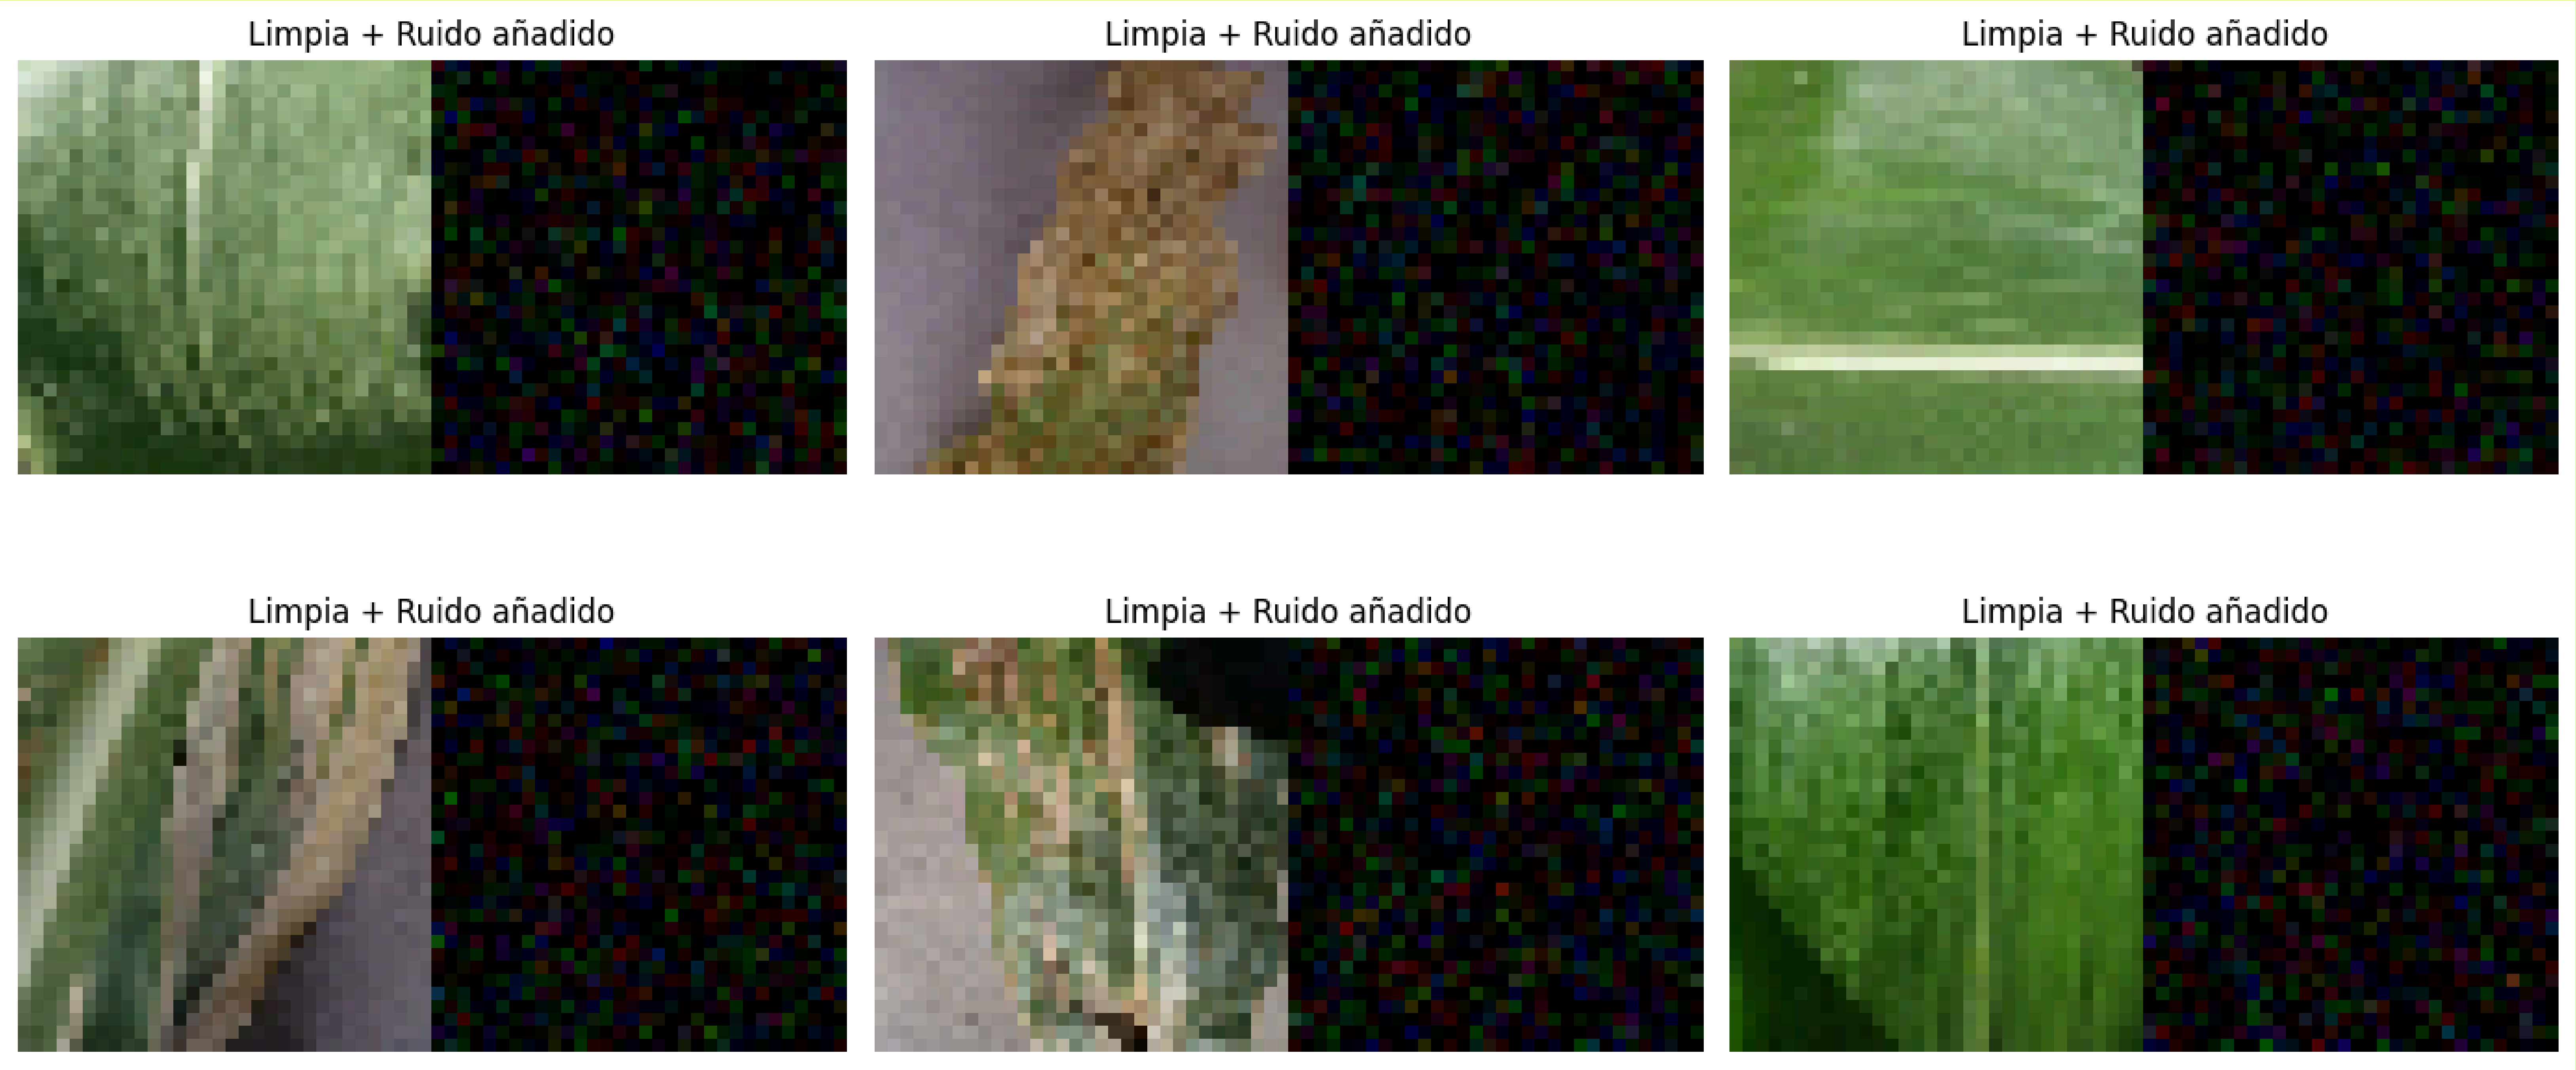

- Se entrenó con un sigma de ruido de 0.1
- Se evaluó con imágenes ruidosas

ABLACIÓN RESNET50

Accuracy

0.92

Macro AUC (OvR)

0.99

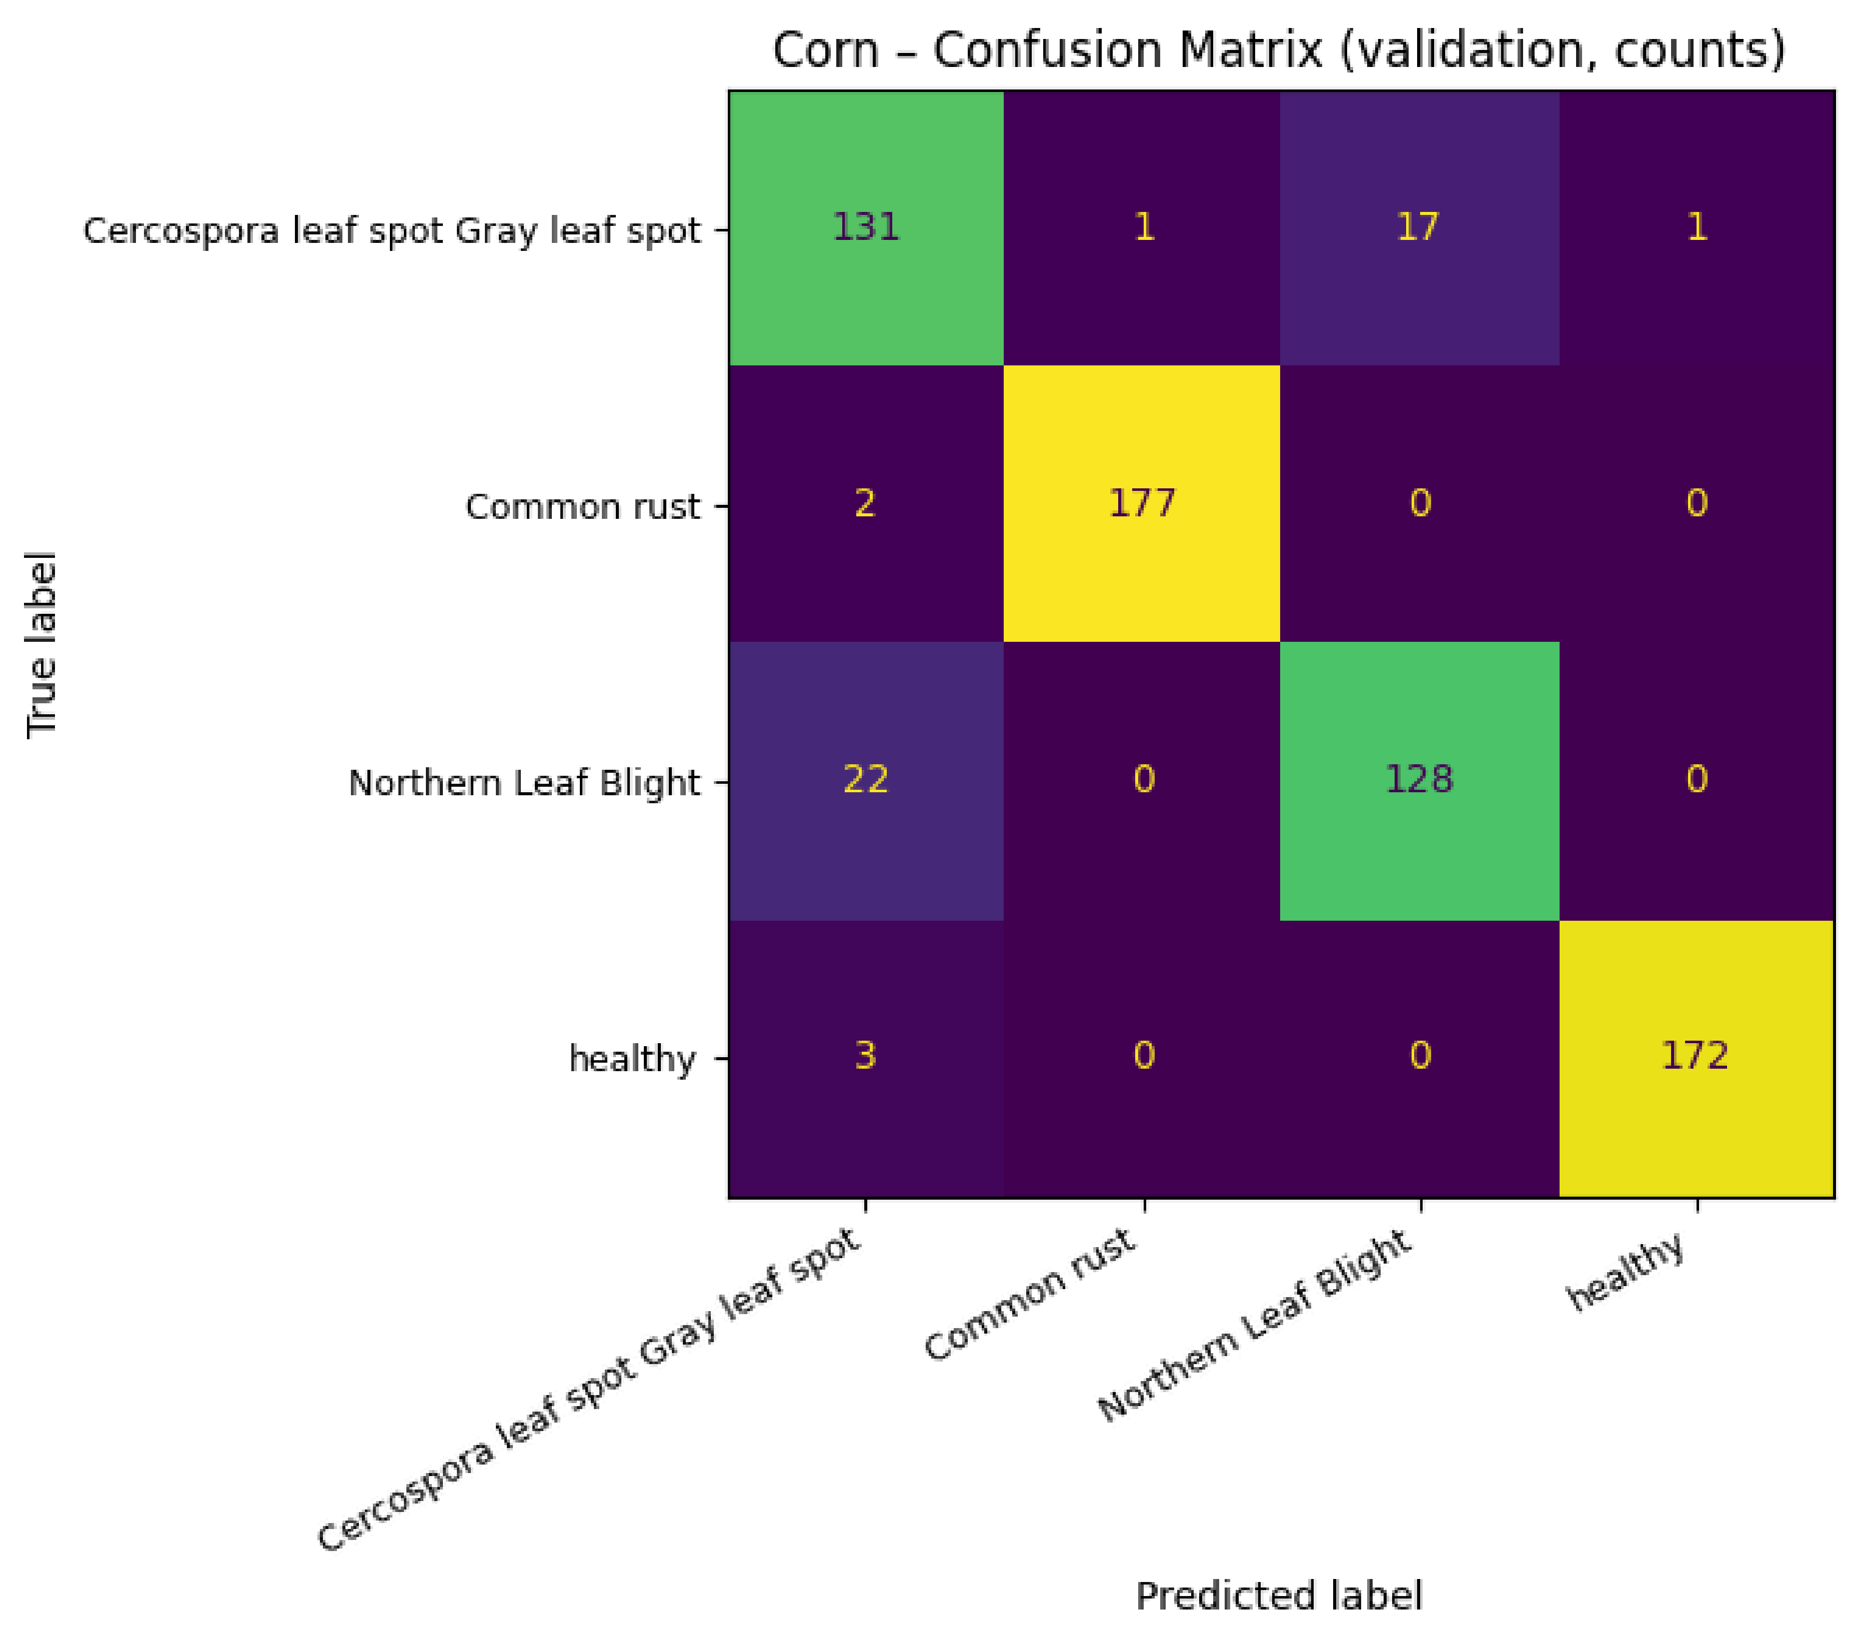

AGROVISION

ABLACIÓN RESNET50

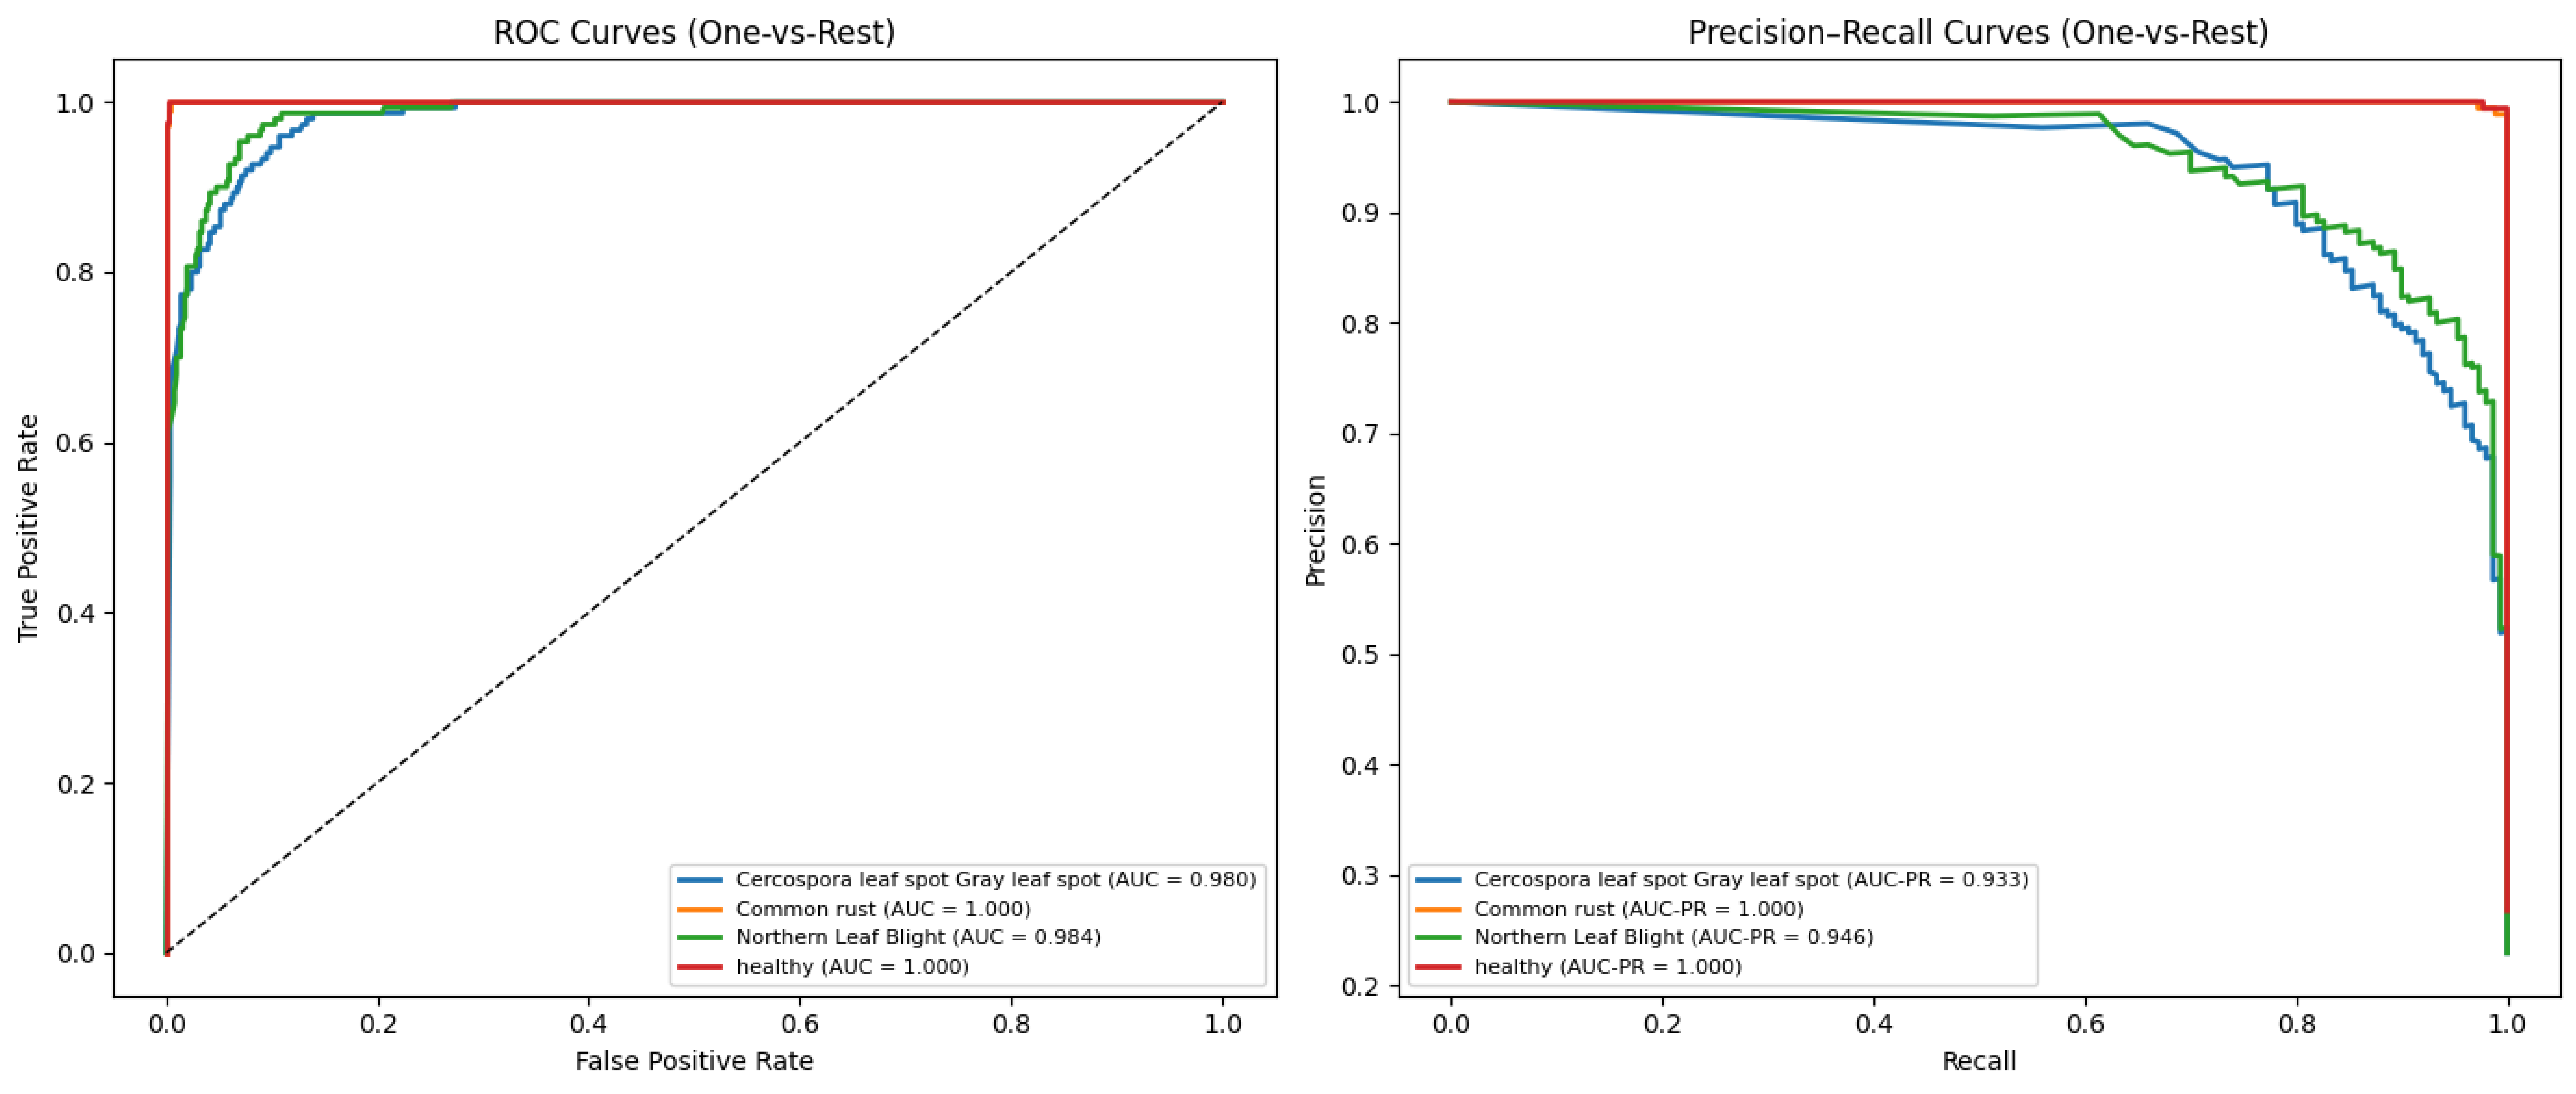

AGROVISION

NUESTRAS PROPUESTAS

METRICS MACRO	1. DNN	2. CNN 1.0	3. ResNet50	4. EffNetB0
LOSS (Sparse Categ Cross)	0.3791	0.2323	0.2356	0.3159
PRECISION	84.94%	91.26%	94.54%	92.04%
ACCURACY	84.57%	91.90%	94.60%	92.51%
AUC	96.18%	98.30%	99.21%	98.47%

AGROVISION

NUESTRAS PROPUESTAS

5. Autoencoder

LOSS (Sparse Categ Cross)	0.0324
MSE	0.0482


AGROVISION
GRACIAS